

Santiago de Cali, 16 de junio de 2025

Señores:

Comité de evaluación de proyectos
Maestría en Ciencia de Datos
Pontificia Universidad Javeriana Cali


Asunto: Segunda entrega Anteproyecto de Grado

Con el fin de cumplir con los requisitos exigidos por la Universidad para llevar a cabo el Proyecto Aplicado y posteriormente optar por el título de Magíster en Ciencia de Datos, nos permitimos presentar a su consideración para *segunda* revisión el anteproyecto de Trabajo de Grado denominado “*DESARROLLO DE UN MODELO DE ANÁLISIS DE CARGA NO INTRUSIVA PARA EFICIENCIA ENERGÉTICA BASADO EN TÉCNICAS DE MACHINE LEARNING*” realizado por los estudiante Meidy Lizeth Moreno Guzman con código 9026822, Jose Luis Munévar Diaz con código 9027646, Julian Javier Jaimes Otero con código 8969620 pertenecientes a la Maestría en Ciencia de Datos, bajo la dirección del profesor David Arango Londoño. De acuerdo con el acta de evaluación de anteproyecto de proyecto de grado del 9 de junio de 2025 donde se evaluó la primera entrega del mismo, las siguientes son las observaciones subsanadas:

- Formulación del Problema
 - Para la tercera pregunta de sistematización no se encuentra relación directa con los problemas establecidos en el planteamiento del problema; es más, en el planteamiento no se habla de este proceso de reconciliación.
- Justificación
 - No es claro si las bases de datos son públicas o privadas. Tampoco información suficiente que permita deducir si se tiene permiso para el uso de los datos. No hay información acerca de la cantidad de datos que disponen.
- Cronograma
 - Las tareas en el cronograma no corresponden con las de la metodología. Sugiero darle un número a cada tarea de la metodología y usar esa numeración en el cronograma.

Cordialmente,

Atentamente,



Meidy Lizeth Moreno Guzman
C.C. 1014223269 de Bogotá.



Jose Luis Munévar Diaz
C.C. 1036646650 de Medellín.



Julian Javier Jaimes Otero
C.C 91505906 de Bucaramanga.



David Arango Londoño
C.C. 1036646650 de Cali.

Documentación anexa:

Una copia digital (PDF) del Anteproyecto del Proyecto de Grado con Modificaciones solicitadas.



Pontificia Universidad
JAVERIANA
Cali

**DESARROLLO DE UN MODELO DE ANÁLISIS DE CARGA NO INTRUSIVA PARA
EFICIENCIA ENERGÉTICA BASADO EN TÉCNICAS DE MACHINE LEARNING**

*Meidy lizeth Lizeth Moreno
Jose Luis Munévar Díaz
Julian Javier Jaimes Otero*

*Anteproyecto del Proyecto Aplicado para optar al título de
Magíster en Ciencia de Datos*

Director(a)
David
Arango
Londoño

FACULTAD DE INGENIERÍA Y CIENCIAS
MAESTRÍA EN CIENCIA DE DATOS
SANTIAGO DE CALI, MAYO 18 DE 2025

FICHA RESUMEN

ANTEPROYECTO DE TRABAJO DE GRADO

POSIBLE TÍTULO: Desarrollo De Un Modelo De Análisis De Carga No Intrusiva Para Eficiencia Energética Basado En Técnicas De Machine Learning.

1. ÁREA DE TRABAJO: Eficiencia Energética
2. TIPO DE PROYECTO: Aplicado
3. ESTUDIANTE(S): Meidy lizeth Lizeth Moreno, Jose Luis Munévar Diaz, Julian Javier Jaimes Otero
4. CORREO ELECTRÓNICO: morenoguzm1@javerianacali.edu.co,
joseluis281@javerianacali.edu.co, jotajaimes@javerianacali.edu.co.
5. DIRECCIÓN Y TELÉFONO: Cra 17 98-03 Bucaramanga - 3118218420
6. DIRECTOR: David Arango
7. VINCULACIÓN DEL DIRECTOR:
8. CORREO ELECTRÓNICO DEL DIRECTOR: david.arango@javerianacali.edu.co
9. CO-DIRECTOR (Si aplica): NA
10. GRUPO O EMPRESA QUE LO AVALA (Si aplica): NA
11. OTROS GRUPOS O EMPRESAS: NA
12. PALABRAS CLAVE (al menos 5): Carga No Intrusiva, Eficiencia Energética, Machine Learning.
13. FECHA DE INICIO: Mayo 18 de 2025
14. DURACIÓN ESTIMADA (En meses): 12

RESUMEN

El proyecto propone el desarrollo de un sistema de monitoreo de carga no intrusivo (NILM) basado en técnicas de inteligencia artificial (IA), enfocado en mejorar la eficiencia energética en entornos comerciales. La creciente demanda energética, sumada al aumento de dispositivos eléctricos conectados a la red eléctrica, ha generado un consumo desmesurado y poco eficiente, debido en gran parte a la falta de información detallada sobre el comportamiento energético de los equipos eléctricos. Los medidores tradicionales solo reportan el consumo total, sin permitir identificar qué equipos eléctricos consumen más, en qué momentos y en qué condiciones, lo que dificulta implementar acciones de ahorro y sostenibilidad. Aunque existen sistemas de monitoreo intrusivo que instalan sensores en cada dispositivo, estos resultan costosos, difíciles de mantener y poco escalables. Ante este panorama, se plantea la creación de un sistema NILM que, a partir de una única medición de energía en el punto de entrada, pueda identificar patrones de consumo y clasificar cargas por categorías mediante modelos de aprendizaje automático. El objetivo general del proyecto es diseñar e implementar una solución que permita analizar y desagregar el consumo energético sin intervención física directa sobre los dispositivos, mejorando la accesibilidad a la información útil para los usuarios. Entre los objetivos específicos se incluyen la selección y evaluación de modelos de IA apropiados para el análisis de datos provenientes de señales eléctricas, la preparación de datos etiquetados para entrenamiento, la implementación de algoritmos de clasificación de carga y la validación del desempeño del sistema desarrollado. Como resultado, se espera obtener un modelo funcional capaz de identificar el funcionamiento de equipos eléctricos, detectar consumos anómalos o ineficientes y entregar reportes desagregados de uso energético. Esta solución contribuirá significativamente a la gestión energética eficiente, brindando a los usuarios herramientas para reducir su consumo, detectar fallos tempranos en equipos eléctricos y promover una cultura de sostenibilidad. Además, sus posibles aplicaciones incluyen su integración en sistemas inteligentes, plataformas de gestión energética en edificios, así como su uso en programas de monitoreo de consumo para empresas distribuidoras de energía o entes reguladores que requieran información precisa sin recurrir a soluciones invasivas o costosas.

TABLA DE CONTENIDO

	Pág.
INTRODUCCIÓN	5
1. DEFINICIÓN DEL PROBLEMA	6
1.1 PLANTEAMIENTO DEL PROBLEMA	7
1.2 FORMULACIÓN DEL PROBLEMA	8
2. OBJETIVOS DEL PROYECTO	9
2.1 OBJETIVO GENERAL	9
2.2 OBJETIVOS ESPECÍFICOS	9
2.3 RESULTADOS ESPERADOS	9
3. ALCANCE	10
4. JUSTIFICACIÓN	11
5. MARCO DE REFERENCIA	12
5.1 MARCO TEÓRICO	
5.2 ANTECEDENTES	16
6. METODOLOGÍA	17
7. RECURSOS A EMPLEAR	20
7.1 HUMANOS	20
7.2 OTROS RECURSOS	
8. CRONOGRAMA DE ACTIVIDADES (Diagrama de Gantt)	21
9. REFERENCIAS BIBLIOGRÁFICAS (Estilo IEEE)	22

LISTA DE FIGURAS
LISTA DE TABLAS
LISTA DE ANEXOS

INTRODUCCIÓN

En la era de la revolución tecnológica, las empresas dependen cada vez más de sistemas eléctricos que les permitan mantenerse conectadas, garantizar la seguridad y, en esencia, operar de manera continua. En este contexto, el consumo de energía eléctrica ha crecido de forma exponencial en los últimos años, una tendencia que probablemente continuará debido a esta creciente dependencia. Sin embargo, los sistemas de medición tradicionales instalados en la mayoría de los entornos empresariales proporcionan únicamente datos agregados del consumo total, sin permitir identificar qué equipos o sistemas son responsables de los mayores consumos.

La eficiencia energética se ha convertido en una prioridad para las organizaciones que buscan optimizar sus recursos, reducir costos operativos y contribuir a la sostenibilidad ambiental. No obstante, la desagregación del consumo eléctrico para identificar oportunidades de ahorro suele requerir inversiones significativas en infraestructura, como la instalación de medidores individuales en cada dispositivo, lo cual no siempre es viable técnica o económicamente.

En este contexto, las tecnologías de inteligencia artificial y ciencia de datos ofrecen nuevas oportunidades para abordar este desafío. En particular, la desagregación de carga no intrusiva mediante modelos de machine learning permite estimar el consumo eléctrico por tipo de carga (por ejemplo, iluminación, computadores o sistemas de climatización) a partir de datos agregados previamente almacenados. Esto evita la necesidad de instalar sensores en cada equipo y proporciona información detallada que puede ser utilizada para detectar patrones de uso, identificar ineficiencias energéticas y predecir el comportamiento del consumo futuro.

Este proyecto propone el desarrollo de un modelo basado en técnicas de machine learning que permita desagregar el consumo eléctrico por categorías en un edificio de oficinas. El objetivo es generar información que facilite a las empresas una gestión energética más eficiente, mediante predicciones que sustenten la toma de decisiones orientadas a la reducción de costos y al consumo sostenible.

1. DEFINICIÓN DEL PROBLEMA

El desperdicio energético y el envejecimiento o mal estado de los equipos eléctricos representan factores claves en el incremento del consumo innecesario de energía. La demanda de energía ha incrementado un 3.5% en promedio en los últimos 30 años, por su parte la población se ha expandido un 1,2% y el PIB del mundo un 6% anual (BBVA Research, Sector eléctrico colombiano), lo que se traduce en facturas más elevadas para los usuarios. Esta situación no solo repercute en los costos económicos, sino que también contribuye significativamente al aumento de la demanda en la generación de energía eléctrica y, por ende, a mayores emisiones de dióxido de carbono (CO₂), intensificando el impacto ambiental [1].

1.1. PLANTEAMIENTO DEL PROBLEMA

En la actualidad, el consumo energético se ha convertido en un factor crítico tanto a nivel ambiental como económico. Muchas edificaciones comerciales utilizan energía de manera ineficiente, lo que genera un aumento innecesario en el gasto energético y contribuye al deterioro del medio ambiente debido a la elevada emisión de gases de efecto invernadero. A pesar de la existencia de tecnologías y prácticas que permiten un uso más racional de la energía, su adopción es todavía limitada por falta de información, inversión inicial o conciencia sobre los beneficios a largo plazo [2].

Una de las principales barreras para mejorar la eficiencia energética es la falta de información detallada sobre cómo, cuándo y cuánto consumen los diferentes equipos eléctricos conectados a una red. Los sistemas de medición convencionales brindan datos generales del consumo total, pero no permiten identificar patrones de uso específicos ni detectar cargas ineficientes o mal funcionamiento de equipos eléctricos. Por otro lado, los sistemas de monitoreo intrusivos requieren sensores físicos en cada dispositivo, lo cual resulta costoso, complejo de instalar y poco escalable, llevando a los usuarios a no poder tener un control o análisis detallado de cual o cuales dispositivos pueden estar incrementando dicho consumo. Sin embargo, los datos recolectados por estos sistemas intrusivos pueden ser los insumos necesarios para realizar iteraciones entre modelos de machine learning que nos permitan desagregar el consumo eléctrico. En este contexto, resulta fundamental establecer un proceso de reconciliación entre las estimaciones generadas por los modelos y los datos reales agregados, con el fin de validar la consistencia de los resultados, ajustar los modelos y garantizar una representación fiel del comportamiento energético. Los modelos de deep learning en particular las redes neuronales recurrentes, nos permiten modelar series temporales y entender dichos patrones de consumo [3].

El desarrollo de un sistema de análisis de carga no intrusivo basado en modelos de machine learning con redes neuronales recurrentes, contribuiría significativamente a mejorar la eficiencia energética en diversos entornos, reducir los costos operativos y minimizar el impacto ambiental, al mismo tiempo que empodera a los usuarios con información útil para la toma de decisiones.

A través del aprendizaje automático, es posible descomponer el consumo eléctrico total registrado en un único punto de medición en estimaciones por tipo de carga, sin necesidad de instalar medidores individuales en cada equipo eléctrico. Esto se logra gracias a la capacidad de los modelos de machine learning para identificar patrones característicos de consumo asociados a distintas categorías de dispositivos. Como resultado, se mejora la visibilidad del consumo energético desagregado, permitiendo decisiones más precisas y fundamentadas en datos reales.

El análisis conjunto de datos agregados y desagregados posibilita la detección de picos de consumo inusuales, uso de equipos eléctricos fuera del horario laboral y la identificación de categorías con consumos innecesarios o ineficientes. Esto contribuye directamente a la optimización del uso de energía, permitiendo intervenir en los puntos críticos del sistema eléctrico de manera focalizada.

Adicionalmente, los modelos predictivos permiten anticipar el comportamiento energético futuro de las oficinas, facilitando la planificación de la demanda y el diseño de estrategias de eficiencia adaptadas a las condiciones operativas específicas de cada entorno.

En conjunto, el uso de IA y ciencia de datos en este contexto no solo permite monitorear el consumo energético de manera más inteligente, sino que transforma datos en conocimiento útil para promover una cultura organizacional orientada a la sostenibilidad y la eficiencia operativa.

1.2. FORMULACIÓN DEL PROBLEMA

¿Cómo podemos analizar la eficiencia energética desagregando el consumo a través de un modelo de machine learning, sin recurrir a sistemas de medición intrusivos?

- ¿Qué tipos de datos permiten identificar patrones para la desagregación de equipos eléctricos de consumo eléctrico por dispositivo?
- ¿Qué tipo de algoritmos de machine learning resultan más efectivos para reconocer patrones de consumo eléctrico, y cómo puede garantizarse su precisión en entornos reales con múltiples cargas conectadas?
- ¿Cómo podemos generar un proceso de reconciliación que permita mejorar la coherencia y presión entre los modelos de desagregación por categorías?

- ¿Qué métricas permiten evaluar la precisión del modelo en la disagregación de consumo por dispositivo?
- ¿Es posible a partir de los resultados del modelo contribuir a la toma de decisiones para la eficiencia energética?

2. OBJETIVOS DEL PROYECTO

2.1 OBJETIVO GENERAL

Desarrollar un modelo de análisis de carga no intrusivo basado en técnicas de machine learning que permita desagregar el consumo energético de los equipos.

2.2 OBJETIVOS ESPECÍFICOS

1. Procesar los datos de carga energética y consumo eléctrico a través del análisis exploratorio y correlaciones.
2. Evaluar diferentes modelos de machine learning para la desagregación e implementación de un modelo capaz de identificar y categorizar las cargas de los equipos eléctricos.
3. Desarrollar un mecanismo de reconciliación para alinear las predicciones de consumo generadas por distintos modelos según las categorías de carga, para coherencia y precisión en la desagregación.
4. Evaluar la precisión y eficiencia del modelo considerando diferentes tipos de cargas eléctricas.

2.3 RESULTADOS ESPERADOS

1. Desarrollo funcional de un modelo de análisis de carga no intrusivo, capaz de registrar y procesar datos de consumo energético en relación con los dispositivos.
2. Entrenamiento e implementación de modelos de machine learning capaces de identificar y desagregar correctamente el consumo de cargas individuales con un nivel aceptable de precisión.
3. Generación de reportes energéticos detallados que permitan visualizar el consumo desagregado.
4. Una base técnica para futuras aplicaciones o escalamiento, como su integración con sistemas domóticos, plataformas de gestión energética, o implementación en edificios comerciales.
5. Contribución al conocimiento en el campo de la eficiencia energética y ciencia de datos, mediante documentación del proceso, resultados obtenidos y análisis de desempeño del sistema.

3. ALCANCE

El presente proyecto se enfoca en el desarrollo e implementación de un modelo de machine learning que permita desagregar el consumo eléctrico a partir de los datos de carga energética recolectados en un edificio de oficinas. Este modelo deberá identificar el consumo de al menos 5 categorías de equipos eléctricos en oficinas, agrupados de acuerdo con características comunes y seleccionados por el mayor impacto que puedan tener.

Para desarrollar este modelo de machine learning se deben recolectar los datos mediante medidores de consumo instalados en diferentes dispositivos de oficina que recolectan información de manera constante y alimentan la base de datos inicial. Así mismo se recolectarán datos de los fabricantes y del consumo general de todo el edificio. Estos datos no son de acceso público y sólo se utilizarán en proyectos académicos o en investigaciones. Se realizará un análisis del dataset mediante técnicas exploratorias de datos y de correlación para la su preparación y procesamiento incluyendo limpieza y estructuración.

Se deberán realizar pruebas con diferentes modelos de aprendizaje, para desagregar el consumo energético, clasificar las cargas por tipo de equipo y realizar predicciones agregadas que permitan establecer el modelo con mayor precisión.

Se implementará un componente de reconciliación permita ajustar las predicciones generadas por los modelos según las categorías de carga, mejorando la coherencia y la precisión de la desagregación.

Se realizarán pruebas que permitan evaluar precisión, eficiencia y aplicabilidad del modelo final en diferentes escenarios presentes en oficinas para distintos tipos de cargas eléctricas.

Se debe tener en cuenta que el desarrollo de este modelo se limita a entornos de oficinas por lo cual su aplicación no puede generalizarse a entornos industriales ni residenciales. El modelo se entrenará bajo unos datos específicos y para ser aplicables a otros entornos podría requerir ajustes según el entorno si los patrones de uso o cargas eléctricas son diferentes.

4. JUSTIFICACIÓN

Las oficinas, en particular, representan un entorno clave en el que la optimización del uso de la energía eléctrica puede tener un impacto económico y ambiental significativo. El desarrollo de un modelo de machine learning que permita desagregar el consumo eléctrico y estimar la participación de diferentes cargas dentro del consumo total se presenta como una herramienta útil para mejorar la gestión energética. Este tipo de solución permite analizar patrones de consumo, generar estimaciones por tipo de carga y promover prácticas sostenibles sin necesidad de instalar medidores individuales en cada dispositivo ni realizar inversiones económicas elevadas.

Contar con una herramienta de este tipo permitiría a las organizaciones tomar decisiones más informadas en materia de eficiencia energética, al comprender el comportamiento de sus cargas eléctricas, identificar ineficiencias y corregir hábitos de consumo poco sostenibles en sus oficinas.

La propuesta es técnicamente viable, ya que se utilizarán conjuntos de datos públicos, orientados a la investigación y disponibles en repositorios especializados en ciencia de datos, que contienen registros reales de consumo energético en entornos de oficina. Por ejemplo, se consideran bases empleadas en ejercicios educativos sobre series de tiempo y consumo energético compartidas en plataformas como Kaggle o sitios de descarga académica, incluyendo proyectos como los desarrollados por el canal Robik's Cube. Estas bases de datos pueden ser utilizadas libremente con fines académicos, y su estructura permite la aplicación de técnicas avanzadas de machine learning para la desagregación de carga. Además, se cuenta con un volumen suficiente de registros —compuestos por miles de observaciones temporales— que incluyen variables como consumo, fecha y hora, lo que garantiza la robustez del análisis.

No se requiere una intervención física compleja en los sistemas eléctricos existentes, lo que favorece su implementación en escenarios reales. Asimismo, el enfoque metodológico contempla un proceso de reconciliación entre las estimaciones generadas por el modelo y los datos agregados disponibles, con el fin de garantizar consistencia, precisión y validez en los resultados obtenidos.

Este proyecto no solo es pertinente y viable, sino que también genera impactos positivos en distintas dimensiones. Por un lado, contribuirá a optimizar la gestión energética en entornos de oficina y, por otro, fortalecerá el conocimiento aplicado en la intersección entre ciencia de datos, sostenibilidad y eficiencia energética.

5. MARCO DE REFERENCIA

La eficiencia energética es un aspecto clave en el desarrollo sostenible, ya que permite reducir el consumo de energía sin disminuir la calidad de los servicios, contribuyendo así a la mitigación del cambio climático y a la optimización de recursos económicos. Uno de los principales retos para lograrla es la falta de visibilidad sobre el consumo individual de los dispositivos eléctricos, especialmente en entornos donde solo se cuenta con una medición total de energía.

Los sistemas de monitoreo de carga no intrusivo (NILM, por sus siglas en inglés) han surgido como una alternativa tecnológica viable para abordar esta problemática. Estos sistemas permiten descomponer la señal de consumo total registrada por un único medidor eléctrico, e identificar de forma indirecta las cargas conectadas, mediante técnicas avanzadas de procesamiento de señales y modelos de aprendizaje automático. A diferencia de los sistemas intrusivos, no requieren sensores individuales en cada aparato, lo que reduce significativamente los costos y la complejidad de instalación.

En este contexto, la inteligencia artificial (IA) juega un papel fundamental. Algoritmos como redes neuronales artificiales, máquinas de vectores de soporte (SVM), árboles de decisión, k-NN, entre otros, han demostrado ser efectivos para clasificar patrones eléctricos y reconocer firmas de dispositivos a partir de datos agregados. Además, técnicas de aprendizaje profundo, como las redes neuronales convolucionales (CNN) y recurrentes (RNN), están siendo ampliamente utilizadas para tareas de desagregación de energía debido a su capacidad para capturar patrones complejos en series temporales.

Por lo tanto, integrar la IA en sistemas NILM representa una estrategia innovadora y eficiente para proporcionar a los usuarios información detallada sobre su consumo energético, detectar usos ineficientes, e incentivar decisiones más informadas orientadas al ahorro y sostenibilidad.

5.1 EFICIENCIA ENERGÉTICA Y SU IMPORTANCIA

La eficiencia energética se refiere a la capacidad de obtener los mismos resultados o servicios utilizando menos energía. Este concepto ha cobrado relevancia debido al crecimiento de la demanda energética, la dependencia de fuentes fósiles, y la necesidad de mitigar el cambio climático. Según el informe de la Agencia Internacional de Energía (IEA), mejorar la eficiencia energética podría reducir las emisiones de gases de efecto invernadero en un 40% para el año 2040 [4].

En sectores comerciales, una parte significativa del consumo energético ocurre sin control ni análisis específico, lo que genera sobrecostos, ineficiencias y desperdicio energético. Además, el consumidor promedio carece de herramientas efectivas para entender el desglose de su consumo eléctrico, lo que impide acciones informadas para ahorrar energía. En este contexto, surge la necesidad de herramientas tecnológicas que permitan una gestión inteligente del consumo, como los sistemas de monitoreo energético avanzados.

5.2 MONITOREO DE ENERGÍA: DE LO INTRUSIVO A LO INTELIGENTE

El monitoreo del consumo eléctrico puede realizarse mediante dos enfoques:

- Intrusivo (ILM): Requiere sensores en cada dispositivo eléctrico, lo que eleva costos y complica la instalación.
- No intrusivo (NILM): Se basa en el análisis de la señal eléctrica total del inmueble, sin sensores individuales.

El concepto de NILM fue propuesto por Hart en 1992, quien introdujo un sistema que descompone la carga total en consumos individuales a través del análisis de patrones eléctricos [3]. Esta técnica permite identificar la operación de distintos equipos eléctricos mediante sus firmas eléctricas características, como cambios de potencia, picos de arranque, ciclos de funcionamiento y variaciones armónicas.

NILM se ha convertido en una opción viable para proyectos a gran escala y para aplicaciones en edificios inteligentes y sistemas de gestión de energía industrial.

5.3 COMPONENTES TÉCNICOS DEL NILM

Un sistema NILM típicamente requiere los siguientes componentes:

- Sensado centralizado: Medición en el punto de entrada (por ejemplo, con un medidor inteligente).
- Procesamiento de señales: Extracción de características como potencia activa/reactiva, picos, formas de onda.
- Clasificación de cargas: Algoritmos que identifican a qué dispositivo pertenece cada patrón detectado.
- Retroalimentación al usuario: Información visual sobre los dispositivos que consumen más energía, cuándo y cómo.

Estos sistemas requieren capacidad para operar en tiempo real, manejar datos ruidosos,

identificar cargas superpuestas, y adaptarse a nuevos dispositivos. Aquí es donde la inteligencia artificial cobra especial importancia.

5.4 INTELIGENCIA ARTIFICIAL EN NILM

La IA se ha convertido en un componente esencial del NILM moderno. La aplicación de redes neuronales profundas (DNN), modelos de atención, y aprendizaje automático supervisado y no supervisado, ha incrementado la precisión de clasificación y la capacidad de generalización de los sistemas.

Principales técnicas utilizadas:

- HMM y FHMM (Modelos de Markov ocultos y factoriales): son una técnica probabilística en la que se asume que el sistema observado (la señal total del consumo eléctrico) es generado por un conjunto de procesos ocultos (los estados de encendido/apagado de los equipos eléctricos). Los FHMM (Factorial HMM) extienden esta idea al considerar múltiples procesos ocultos que actúan simultáneamente, uno por cada dispositivo [5].
- Redes neuronales convolucionales (CNN): son modelos de aprendizaje profundo diseñados para procesar datos con estructura espacial o secuencial. Aplicadas a NILM, permiten extraer características locales de la señal eléctrica, como picos, saltos o patrones repetitivos de consumo [6].
- Redes recurrentes (RNN, LSTM): son capaces de modelar dependencias a largo plazo en secuencias temporales, siendo ideales para cargas eléctricas que operan en ciclos o presentan estados transitorios prolongados [4].
- Transformers: se basan en mecanismos de autoatención que permiten que el modelo enfoque dinámicamente distintas partes de la secuencia de entrada, sin procesar de manera secuencial como las RNN. Esta técnica ha sido muy exitosa en procesamiento de lenguaje y recientemente se ha trasladado al ámbito energético. [7].
- Modelos de difusión condicional: Los modelos generativos aprenden a simular la distribución de los datos de entrada, permitiendo generar ejemplos sintéticos o descomponer señales de forma más robusta. Las redes de difusión condicional son una técnica reciente que genera señales realistas a partir de ruido estructurado [8].
- Estos modelos requieren bases de datos robustas y representativas, como UK-DALE, REDD, REFIT, o IDEAL, que contienen registros detallados de consumo eléctrico desagregado [9].

5.5 RETOS DEL MONITOREO NO INTRUSIVO

A pesar de los avances, los sistemas NILM enfrentan diversos desafíos:

- Ambigüedad entre dispositivos: Aparatos similares (por ejemplo, varios ventiladores) pueden tener firmas eléctricas casi idénticas.
- Ruidos en la red eléctrica: Variaciones aleatorias y ruido dificultan la detección precisa.
- Cambios en el entorno: Nuevas cargas o dispositivos modifican el patrón total, afectando la precisión del sistema.
- Falta de datos etiquetados: Los modelos supervisados requieren ejemplos reales, lo cual es costoso de obtener.

Soluciones emergentes incluyen el transfer learning, técnicas semi-supervisadas, y entrenamiento con datos sintéticos generados por IA, que permiten adaptar modelos a nuevos contextos sin volver a etiquetar manualmente los datos.

5.5 APLICACIONES PRÁCTICAS Y BENEFICIOS

La implementación de un sistema NILM con inteligencia artificial permite:

- Optimizar el consumo energético en edificaciones comerciales.
- Detectar equipos eléctricos defectuosos o ineficientes.
- Promover hábitos de consumo consciente en los usuarios.
- Facilitar esquemas de respuesta a la demanda (Demand Response).
- Apoyar políticas públicas de sostenibilidad energética.
- Desarrollar sistemas de domótica o automatización adaptativos.

Además, es posible integrar estas tecnologías en plataformas IoT, dashboards inteligentes o aplicaciones móviles para una experiencia de usuario interactiva y educativa.

5.7 ESTADO DEL ARTE Y TENDENCIAS

Los estudios más recientes se enfocan en:

- Aplicación de transformers NILM multiclase para cargas [5].

- Reducción de error en entornos con datos incompletos mediante modelos generativos [6].
- Optimización de consumo en tiempo real con NILM integrado a plataformas IoT [10].
- Aplicaciones NILM para detectar fallas eléctricas tempranas en ambientes industriales.

Estas líneas marcan el camino hacia soluciones NILM más robustas, accesibles y escalables.

6. ANTECEDENTES

El monitoreo no intrusivo de cargas (NILM, por sus siglas en inglés) ha sido objeto de creciente interés en los últimos años, como una estrategia efectiva para mejorar la eficiencia energética sin recurrir a instalaciones costosas o invasivas. Diversos estudios han explorado enfoques que combinan técnicas de procesamiento de señales eléctricas con algoritmos de inteligencia artificial, con el objetivo de identificar y clasificar el consumo de dispositivos individuales a partir de mediciones agregadas. En esta sección se presentan trabajos relevantes que han abordado el problema de la desagregación energética desde distintas perspectivas metodológicas, incluyendo redes neuronales profundas, modelos estadísticos, y revisiones sistemáticas del estado del arte. Cada estudio es analizado en términos de su contribución específica, su enfoque técnico y sus diferencias con el proyecto que se propone, permitiendo identificar oportunidades para avanzar hacia una solución más práctica, escalable y centrada en el usuario.

- Es el artículo *A Survey on Non-Intrusive Load Monitoring Methods and Techniques for Energy Disaggregation Problem* se presenta una revisión detallada de las metodologías empleadas en NILM, desde técnicas estadísticas como los modelos ocultos de Markov hasta algoritmos de machine learning supervisados y no supervisados. El trabajo proporciona una visión amplia del estado del arte, discutiendo las fortalezas, limitaciones y desafíos como la necesidad de datos etiquetados y la evaluación estandarizada. Si bien es una fuente teórica fundamental que permite entender el desarrollo histórico y técnico del NILM, no propone un sistema práctico ni soluciones aplicadas. En este sentido, el proyecto actual se apoya en este análisis para tomar decisiones informadas sobre qué modelos usar, pero avanza hacia la implementación real de un sistema de monitoreo energético basado en inteligencia artificial, aplicable a usuarios finales [10].
- El trabajo *Non-intrusive load monitoring by using active and reactive power in additive factorial hidden Markov models* propone un enfoque NILM utilizando tanto potencia

activa como reactiva, modeladas mediante factorial hidden Markov models (FHMM), para mejorar la identificación de dispositivos eléctricos en ambientes donde múltiples cargas están activas simultáneamente. Se demuestra que incluir variables adicionales como la potencia reactiva mejora la precisión del modelo frente a métodos que consideran solo la potencia activa. Aunque se trata de una solución efectiva desde el punto de vista técnico, su aplicación práctica puede ser limitada por la necesidad de mayor complejidad en el monitoreo de señales y procesamiento de datos. A diferencia de esta propuesta centrada en modelos estadísticos, el presente proyecto opta por aprovechar redes neuronales profundas que requieren menos ingeniería manual de características, con el objetivo de construir un sistema adaptable y escalable que pueda ser desplegado en escenarios reales con menor costo de instalación [11].

- El estudio ***Neural NILM: Deep Neural Networks Applied to Energy Disaggregation*** es pionero aplica redes neuronales profundas, como CNNs y LSTMs, al problema de NILM, utilizando datasets públicos como REDD y UK-DALE. Se demuestra que estos modelos pueden superar a métodos tradicionales en precisión al modelar relaciones temporales y espaciales complejas dentro de las señales de consumo eléctrico. Los autores prueban diferentes arquitecturas y analizan su capacidad para desagregar la señal total en consumos individuales de equipos eléctricos. Aunque este trabajo representa un avance clave en la aplicación de deep learning, se limita a experimentos de laboratorio y no considera la adaptación del sistema a entornos con datos limitados, ruidos o variaciones no controladas. Nuestro proyecto, en cambio, busca llevar estos avances al terreno práctico, combinando modelos de IA con estrategias de adquisición de datos y despliegue en entornos reales, incluso con restricciones de hardware o calidad de datos [12].

7. METODOLOGÍA

La metodología planteada para este proyecto de grado está diseñada para abordar de manera estructurada y sistemática el logro del objetivo general y los objetivos específicos definidos, basándose en un enfoque metodológico que nos permita cumplir con cada objetivo propuesto.

1: Procesamiento y recolección de datos de carga energética y consumo eléctrico a través del análisis exploratorio y correlaciones.

- A. Recolección de datos de consumo energético provenientes de fuentes confiables, como medidores inteligentes relacionados con el consumo eléctrico.
- B. Limpieza de los datos recolectados, eliminando valores atípicos, inconsistencias y datos faltantes.
- C. Realización de un análisis exploratorio de datos (EDA) para identificar patrones, tendencias y distribuciones en los datos de consumo energético.
- D. Cálculo de correlaciones entre variables relevantes para determinar relaciones significativas que puedan ser útiles en la modelación.

2: Evaluar diferentes modelos de machine learning para desagregar el consumo energético.

- A. Selección de técnicas de machine learning adecuadas para la desagregación de consumo energético, tales como algoritmos supervisados y no supervisados.
- B. Implementación inicial de modelos base, como regresión lineal, árboles de decisión y redes neuronales, para evaluar su desempeño preliminar.
- C. Comparación de los modelos implementados utilizando métricas de evaluación estándar, como precisión, recall, F1-score y error cuadrático medio (MSE).
- A. Ajuste de los modelos seleccionados modificando los parámetros de entrada para la adquisición de mejores resultados
- B. Entrenamiento de los modelos con los datos procesados, asegurando la implementación de técnicas de regularización para evitar sobreajuste y permitirnos la clasificación de al menos 4 categorías de equipos eléctricos susceptibles a la desagregación energética.

3: Desarrollar un mecanismo de reconciliación para alinear las predicciones de consumo generadas por distintos modelos según las categorías de carga, para coherencia y precisión en la desagregación.

- A. Diseño e implementación de un modelo basado en técnicas avanzadas de machine learning, como redes neuronales profundas (deep learning) o modelos híbridos.
- B. Clasificación de las cargas eléctricas según categorías predefinidas, como equipos de cómputo, iluminación, sistemas de climatización y data centers.
- C. Validación del modelo implementado utilizando un conjunto de datos etiquetados para medir su capacidad de clasificación.

4: Evaluar la precisión y eficiencia del modelo considerando diferentes tipos de cargas eléctricas.

- A. Aplicación del modelo final a diferentes conjuntos de datos que representen diversos tipos de cargas eléctricas.
- B. Medición de la precisión y eficiencia del modelo utilizando métricas específicas, como exactitud global, tiempo de procesamiento.

La metodología descrita asegura un enfoque integral para el desarrollo del modelo de análisis de carga no intrusivo basado en técnicas de machine learning, permitiendo alcanzar los objetivos y permitiendo un adecuado seguimiento al cumplimiento de los objetivos que se propusieron.

8. RECURSOS A EMPLEAR

8.1 RECURSOS HUMANOS

Para la ejecución de este proyecto, resulta fundamental contar con un equipo interdisciplinario y capacitado que garantice el cumplimiento de los objetivos planteados durante los 2 semestres dispuestos a la ejecución del proyecto. En este sentido, se requiere la participación activa de los integrantes del equipo principal, quienes aportarán sus conocimientos, habilidades y experiencia en el desarrollo de las diferentes etapas del proyecto. El equipo está conformado por: Meidy Lizeth Moreno, Jose Luis Munévar Díaz, Julián Javier Jaimes Otero.

Cada uno de ellos desempeñará roles específicos según sus competencias, contribuyendo al análisis, diseño y ejecución de las estrategias necesarias para alcanzar los resultados esperados.

Adicionalmente, el proyecto contará con la orientación y supervisión del tutor David Arango Londoño, quien posee una sólida formación académica y profesional. El profesor Arango es egresado de la Universidad del Valle, maestro en Economía Aplicada de la misma institución, y también estadístico de la Universidad Nacional. Su experiencia y conocimientos serán esenciales para guiar al equipo en la toma de decisiones metodológicas, garantizar la rigurosidad científica del trabajo y proporcionar apoyo técnico durante todo el proceso.

1. CRONOGRAMA DE ACTIVIDADES

[illegible]

9. REFERENCIAS BIBLIOGRÁFICAS

- [1] M. P. Castañeda, A. Reyes, y M. Cardozo, «Sector eléctrico colombiano: retos y oportunidades», 1 de mayo de 2021.
- [2] «Trends and Projections in Europe 2023». Accedido: 26 de mayo de 2025. [En línea]. Disponible en: <https://www.eea.europa.eu/en/analysis/publications/trends-and-projections-in-europe-2023>
- [3] G. W. Hart, «Nonintrusive appliance load monitoring», *Proc. IEEE*, vol. 80, n.º 12, pp. 1870-1891, dic. 1992, doi: 10.1109/5.192069.
- [4] «Energy Efficiency 2022 – Analysis», IEA. Accedido: 22 de mayo de 2025. [En línea]. Disponible en: <https://www.iea.org/reports/energy-efficiency-2022>
- [5] J. Z. Kolter y T. Jaakkola, «Approximate Inference in Additive Factorial HMMs with Application to Energy Disaggregation», en *Artificial Intelligence and Statistics*, PMLR, mar. 2012, pp. 1472-1482. Accedido: 22 de mayo de 2025. [En línea]. Disponible en: <https://proceedings.mlr.press/v22/zico12.html>
- [6] C. Zhang, M. Zhong, Z. Wang, N. Goddard, y C. Sutton, «Sequence-to-point learning with neural networks for nonintrusive load monitoring», 18 de septiembre de 2017, *arXiv*: arXiv:1612.09106. doi: 10.48550/arXiv.1612.09106.
- [7] M. I. Azad, R. Rajabi, y A. Estebarsari, «Sequence-to-Sequence Model with Transformer-based Attention Mechanism and Temporal Pooling for Non-Intrusive Load Monitoring», 8 de junio de 2023, *arXiv*: arXiv:2306.05012. doi: 10.48550/arXiv.2306.05012.
- [8] R. Sun, K. Dong, y J. Zhao, «DiffNILM: A Novel Framework for Non-Intrusive Load Monitoring Based on the Conditional Diffusion Model», *Sensors*, vol. 23, n.º 7, Art. n.º 7, ene. 2023, doi: 10.3390/s23073540.
- [9] J. Kelly y W. Knottenbelt, «The UK-DALE dataset, domestic appliance-level electricity demand and whole-house demand from five UK homes», *Sci. Data*, vol. 2, n.º 1, p. 150007, mar. 2015, doi: 10.1038/sdata.2015.7.
- [10] A. Faustine, N. H. Mvungi, S. Kaijage, y K. Michael, «A Survey on Non-Intrusive Load Monitoring Methodies and Techniques for Energy Disaggregation Problem», *arXiv.org*. Accedido: 22 de mayo de 2025. [En línea]. Disponible en: <https://arxiv.org/abs/1703.00785v3>
- [11] R. Bonfigli, E. Principi, M. Fagiani, M. Severini, S. Squartini, y F. Piazza, «Non-intrusive load monitoring by using active and reactive power in additive Factorial Hidden Markov Models», *Appl. Energy*, vol. 208, pp. 1590-1607, dic. 2017, doi: 10.1016/j.apenergy.2017.08.203.
- [12] J. Kelly y W. Knottenbelt, «Neural NILM: Deep Neural Networks Applied to Energy Disaggregation», en *Proceedings of the 2nd ACM International Conference on Embedded Systems for Energy-Efficient Built Environments*, en BuildSys '15. New York, NY, USA: Association for Computing Machinery, nov. 2015, pp. 55-64. doi: 10.1145/2821650.2821672.
- [13] O. Krystalakos, C. Nalmpantis, y D. Vrakas, «(PDF) Sliding Window Approach for Online Energy Disaggregation Using Artificial Neural Networks», en *ResearchGate*, 2018. doi: 10.1145/3200947.3201011.
- [14] M. Berges, E. Goldman, H. S. Matthews, y L. Soibelman, «(PDF) Learning Systems for Electric Consumption of Buildings», en *ResearchGate*, 2009. doi: 10.1061/41052(346)1.
- [15] R. Sun, K. Dong, y J. Zhao, «DiffNILM: A Novel Framework for Non-Intrusive Load Monitoring Based on the Conditional Diffusion Model», *Sensors*, vol. 23, n.º 7, Art. n.º 7, ene. 2023, doi: 10.3390/s23073540.