



Pontificia Universidad
JAVERIANA
Cali

**PREDICCIÓN DE PRODUCCIÓN DE POZOS PETROLEROS USANDO TÉCNICAS DE
INTELIGENCIA ARTIFICIAL APLICACIÓN EN UN YACIMIENTO COLOMBIANO**

Joan Sebastian García Villa
Código 8985142

*Proyecto Aplicado para optar al título de
Magister en Ciencia de Datos*

Director
PhD Julian Gil Gonzalez

Codirector
Msc Danuil Elias Dueñas

FACULTAD DE INGENIERÍA Y CIENCIAS
MAESTRÍA EN CIENCIA DE DATOS
SANTIAGO DE CALI, ENERO DE 2026

TABLA DE CONTENIDO

INTRODUCCIÓN	6
1. CONTEXTUALIZACIÓN DEL PROYECTO	7
1.1 Definición del problema	7
1.2 Objetivos.....	8
1.3 Marco de Referencia	9
2. CONJUNTO DE DATOS Y ANALISIS EXPLORATORIO.....	21
2.1 Campo 1.....	21
2.2 Campo 2.....	28
2.3 Campo 3.....	34
3 MODELO PREDICTIVO.....	39
3.1 Preprocesamiento de variables.....	41
3.2 División del conjunto de datos	41
3.3 Optimización de Hiperparámetros	41
3.4 Transformación de variable objetivo	43
3.5 Flujograma y desarrollo de modelos	44
4 RESULTADOS.....	47
4.1 Resultados Campo 1	47
4.2 Resultados Campo 2	56
4.3 Resultados Campo 3	65
5 CONCLUSIONES.....	74
6 LIMITACIONES.....	76
7 TRABAJOS FUTUROS.....	77
6 REFERENCIAS BIBLIOGRÁFICAS.....	78
7 ANEXOS.....	82
7.1 ESPACIOS DE HIPERPARAMETROS.....	82

LISTA DE FIGURAS

Figura 1: Representación de la estructura del Random Forest [36]	14
Figura 2: Representación de la estructura del XGBoost [42]	16
Figura 3: Histograma y boxplot variable objetivo Campo 1	24
Figura 4: Matriz de correlación de Pearson y Spearman Campo 1	26
Figura 5: Matriz de correlación mixta campo 1, librería dython.....	26
Figura 6: Diagrama de caja y bigote para diferentes variables numéricas campo 1	28
Figura 7: Histograma y boxplot variable objetivo Campo 2	30
Figura 8: Matriz de correlación de Pearson y Spearman Campo 2	32
Figura 9: Matriz de correlación mixta campo 2, librería dython.....	32
Figura 10: Variables numéricas con mayor correlación con variable objetivo, campo 2	33
Figura 11: Correlación de variables categóricas con bopd, campo 2	33
Figura 12: Histograma y boxplot variable objetivo Campo 3	36
Figura 13: Matriz de correlación de Pearson y Spearman Campo 3	38
Figura 14: Matriz de correlación mixta campo 3, librería dython.....	38
Figura 15: Flujograma metodología experimental de predicción de producción empleando algoritmos de machine learning para cada campo	46
Figura 16: Grafico de dispersión predicción vs real, tres mejores casos Campo 1	56
Figura 17: Grafico de dispersión predicción vs real, tres mejores casos Campo 2	64
Figura 18: Grafico de dispersión predicción vs real, tres mejores casos Campo 3	72

LISTA DE TABLAS

Tabla 1: Variables empleadas en modelos de machine learning para la predicción de productividad en literatura y disponibilidad en campos estudio	18
Tabla 2: Métricas empleadas para medir el desempeño de modelos de machine learning para la predicción de productividad.....	20
Tabla 3: Descripción de variables en el conjunto de datos	22
Tabla 4: Estadística descriptiva variables cuantitativas conjunto de datos campo 1	23
Tabla 5: Variables categóricas y numero de categorías	23
Tabla 6: Porcentaje de outliers por variable campo 1, valor de correlación Spearman y matriz dython para categóricas.....	27
Tabla 7: Descripción de variables en el conjunto de datos campo 2	28
Tabla 8: Estadística descriptiva variables cuantitativas conjunto de datos campo 2	29
Tabla 9: Porcentaje de outliers por variable campo 2, valor de correlación Spearman y matriz dython para categóricas.....	33
Tabla 10: Descripción de variables en el conjunto de datos campo 3	35
Tabla 11: Estadística descriptiva variables cuantitativas conjunto de datos campo 3	35
Tabla 12: Porcentaje de outliers por variable campo 3, valor de correlación Spearman y matriz dython para categóricas.....	39
Tabla 13: Técnicas de machine learning aplicadas en problemas similares de predicción de productividad.....	40
Tabla 14: Espacio de hiperparametros fase de búsqueda	42
Tabla 15: Mejores resultados fases búsqueda + Optimización RandomSearch + MedAE campo 1	47
Tabla 16: Mejores resultados fases búsqueda + Optimización 1 y 2 RandomSearch + Huber campo 1	49
Tabla 17: Mejores resultados fases búsqueda + Optimización BayesSearch + MedAE campo 1	51
Tabla 18: Mejores resultados fases búsqueda + Optimización 1 y 2 de BayesSearch + Huber campo 1	53
Tabla 19: Mejores resultados globales fases Búsqueda + Optimización campo 1.....	54
Tabla 20: Mejores resultados fases búsqueda + Optimización 1 y 2, RandomSearch + MedAE campo 2.....	57
Tabla 21: Mejores resultados fases Búsqueda + Optimización RandomSearch + Huber campo 2	58
Tabla 22: Mejores resultados fases búsqueda + Optimización 1 y 2 BayesSearch + MedAE, campo 2	60
Tabla 23: Mejores resultados fases Búsqueda, Optimización 1 y 2, BayesSearch + Huber campo 2	61
Tabla 24: Mejores resultados globales fases Búsqueda + Optimización campo 2.....	63
Tabla 25: Mejores resultados fases Búsqueda + Optimización 1 y 2, RandomSearch + MedAE campo 3.....	65
Tabla 26: Mejores resultados fases Búsqueda + Optimización RandomSearch + Huber campo 3	67

Tabla 27: Mejores resultados fases Búsqueda + Optimización 1 y 2, BayesSearch + MedAE campo 3	68
Tabla 28: Mejores resultados fases Búsqueda + Optimización BayesSearch + Huber campo 3	69
Tabla 29: Mejores resultados globales fases Búsqueda + Optimización campo 3.....	71
Tabla 30: Espacio de hiperparametros fase de búsqueda versus Optimizado 1 RandomSearch + MedAE Campo 1	82
Tabla 31: Espacio de hiperparametros Optimizado 2 RandomSearch + MedAE Campo 1 ..	82
Tabla 32: Espacio de hiperparametros fase de búsqueda versus Optimizado 1 RandomSearch + Huber Campo 1	83
Tabla 33: Espacio de hiperparametros Optimizado 2 RandomSearch + Huber Campo 1....	84
Tabla 34: Espacio de hiperparametros fase de búsqueda versus Optimizado 1 BayesSearch + MedAE Campo 1	85
Tabla 35: Espacio de hiperparametros Optimizado 2 BayesSearch + MedAE Campo 1	86
Tabla 36: Espacio de hiperparametros fase de búsqueda versus Optimizado 1 BayesSearch + Huber Campo 1	86
Tabla 37: Espacio de hiperparametros Optimizado 2 BayesSearch + Huber Campo 1	87
Tabla 38: Espacio de hiperparametros fase de búsqueda versus Optimizado 1 RandomSearch + MedAE Campo 2	88
Tabla 39: Espacio de hiperparametros Optimizado 2 RandomSearch + MedAE Campo 2 ..	88
Tabla 40: Espacio de hiperparametros fase de búsqueda versus Optimizado RandomSearch + Huber Campo 2	89
Tabla 41: Espacio de hiperparametros Optimizado 2 RandomSearch + Huber Campo 2....	90
Tabla 42: Espacio de hiperparametros fase de búsqueda versus Optimizado 1 BayesSearch + MedAE Campo 2	91
Tabla 43: Espacio de hiperparametros Optimizado 2 BayesSearch + MedAE Campo 2	92
Tabla 44: Espacio de hiperparametros fase de búsqueda versus Optimizado BayesSearch + Huber Campo 2	92
Tabla 45: Espacio de hiperparametros Optimizado 2 BayesSearch + Huber Campo 2	93
Tabla 46: Espacio de hiperparametros fase de búsqueda versus Optimizado 1 RandomSearch + MedAE Campo 3	94
Tabla 47: Espacio de hiperparametros Optimizado 2 RandomSearch + MedAE Campo 3 ..	95
Tabla 48: Espacio de hiperparametros fase de búsqueda versus Optimizado RandomSearch + Huber Campo 3	95
Tabla 49: Espacio de hiperparametros Optimizado 2 RandomSearch + Huber Campo 3....	96
Tabla 50: Espacio de hiperparametros fase de búsqueda versus Optimizado BayesSearch + MedAE Campo 3	97
Tabla 51: Espacio de hiperparametros Optimizado 2 BayesSearch + MedAE Campo 3	98
Tabla 52: Espacio de hiperparametros fase de búsqueda versus Optimizado BayesSearch + Huber Campo 3	98
Tabla 53: Espacio de hiperparametros Optimizado 2 BayesSearch + Huber Campo 3	99

INTRODUCCIÓN

La predicción precisa de producción es una tarea básica pero primordial para la evaluación económica y de estrategias de desarrollo de los campos petroleros, y las técnicas comúnmente usadas son de dos tipos: modelos numéricos de simulación con base a los fenómenos físicos y los modelos analíticos para reconocer patrones y extrapolar estos comportamientos [1]. Sin embargo, estas metodologías tradicionales presentan dificultades como requerir un amplio conocimiento del campo, un nivel de experiencia alto en la temática, tiempos de construcción extensos de incluso meses y años, técnicas que no toman en cuenta la física de los yacimientos de petróleo, en algunos casos alta subjetividad de cada profesional evaluador y, por otro lado, son técnicas con baja aplicabilidad al solo trabajar bajo varios supuestos de idealidad. Estas dificultades ralentizan la toma de decisiones y la restringen a escenarios contruidos con información, posiblemente desactualizada, lo cual implica un requerimiento mayor de horas-hombre de profesionales para realizar la actualización y generar los pronósticos. Este trabajo de investigación implementa modelos de machine learning para predecir la producción de crudo de pozos de un campo petrolero colombiano usando información de subsuelo y superficie. El proyecto se desarrolla con base a actividades que permitan el cumplimiento de cinco objetivos específicos y tomando buenas prácticas de “Lean Design Thinking Methodology”, estas actividades se resumen en: 1) revisión de estado del arte y selección del campo petrolero objetivo, 2) análisis exploratorio y limpieza de los datos, 3) revisión de atributos y su impacto en la producción de hidrocarburos, 4) selección de métodos de aprendizaje automático a ser empleados en la investigación que han sido empleados en otras investigaciones, 5) implementación de los modelos de machine learning y 6) una evaluación del desempeño de estos frente a diferentes métricas. El resultado de esta investigación es la implementación de cuatro modelos de machine learning que permitan la predicción de producción de pozos de petróleo, impactando la planificación y evaluación de los campos de hidrocarburos y reducir los tiempos empleados por los profesionales en estas actividades.

1. CONTEXTUALIZACIÓN DEL PROYECTO

1.1 Definición del problema

1.1.1 Planteamiento del problema

La predicción precisa de producción es una tarea básica pero primordial para la evaluación económica y de estrategias de desarrollo de los campos petroleros, y las técnicas comúnmente usadas son de dos tipos: establecer un modelo numérico de simulación el cual se basa en los fenómenos físicos y la recopilación de información del yacimiento, y las técnicas donde se emplean modelos analíticos para reconocer patrones y extrapolar estos comportamientos empleando un menor volumen de información del yacimiento de hidrocarburos [1]. Sin embargo estas metodologías tradicionales presentan dificultades como las siguientes [2], [3]: 1) son técnicas que requieren un amplio conocimiento del campo, un nivel de experiencia alto en la temática para construir modelos físicos en softwares específicos y tiempos de construcción que pueden ser de seis meses o más (ejemplo modelos de simulación numérica de yacimientos), 2) metodologías que no requiere un alto grado de conocimiento del campo que se basa en la evaluación por parte de un profesional de las tendencias históricas de producción pozo a pozo para realizar una proyección de esta pero que sin embargo son estimados de origen matemático-estadístico que puede no honrar ni tomar en cuenta la física de los yacimientos de petróleo y su proyección puede variar entre la experiencia y subjetividad de cada profesional evaluador al ser principalmente gráfica (ejemplo Decline Curve Analysis), 3) técnicas basadas en comportamiento histórico y datos físicos (como los balances de materia), que pueden ser sencillas e implementables de manera rápida, pero con baja aplicabilidad en campos que presentan alta heterogeneidad o un gran volumen de pozos productores con tendencias muy diversas (ejemplo Balances de materia). Estas dificultades ralentizan la toma de decisiones y la restringen a escenarios contruados con información, posiblemente desactualizada, lo cual implica un requerimiento mayor de horas-hombre de profesionales para realizar la actualización y generar los pronósticos.

Por lo anterior, en este proyecto, se aborda la problemática actual que enfrentan los ingenieros de yacimientos, quienes al realizar sus pronósticos aplicando técnicas que combinan heurísticas y criterios que pueden resultar subjetivos o individuales, terminan invirtiendo grandes cantidades de tiempo en revisiones pozo a pozo, para posteriormente consolidar un pronóstico a nivel de campo. Para efectos del presente proyecto se desarrollaron modelos de machine learning para la predicción de producción de crudo empleando variables disponibles: número de inyectoros activos de primera línea, número de productores activos de primera línea, acumulado de

inyección, acumulado de producción, propiedades petrofísicas y geológicas (porosidad, permeabilidad, contenido de arcillas, espesor cañoneado), corte de agua, formación productora.

1.1.2 Formulación del problema

¿Es posible obtener una metodología alternativa que reduzca las problemáticas previamente mencionadas empleando algoritmos de machine learning y permita predecir el desempeño de producción de cada pozo empleando no solo la información histórica de producción, sino también la información de características y variables físicas cercanas de cada pozo?

1.1.3 Sistematización

¿Qué atributos o características presentan mayor influencia en el pronóstico de producción de un pozo de crudo?, ¿Cuáles técnicas de inteligencia artificial han sido aplicados en la resolución de este tipo de problemas en otros campos de producción de crudo del mundo?, ¿Es posible implementar un modelo predictivo para un campo petrolero colombiano con la información disponible?, ¿Cuáles son las métricas adecuadas para valorar el desempeño de los modelos de acuerdo con la calidad de los resultados obtenidos? ¿Cómo se comparan los modelos de aprendizaje automático entre sí?

1.2 Objetivos

1.2.1 Objetivo General

Implementar un algoritmo/modelo de machine learning para predecir la producción de crudo de pozos de un campo petrolero colombiano usando información histórica, de subsuelo y superficie.

1.2.2 Objetivos Específicos

- Realizar el análisis de datos exploratorio de los datos de producción y geología del campo seleccionado.
- Seleccionar los atributos/características con mayor influencia en la producción de crudo.
- Seleccionar las técnicas de inteligencia artificial que serán utilizadas para el análisis.
- Implementar/construir un modelo predictivo de producción de pozos de crudo usando las técnicas de inteligencia artificial seleccionadas.
- Evaluar el desempeño de los modelos implementados.

1.3 Marco de Referencia

La predicción de producción en pozos petroleros constituye un insumo central para la evaluación económica, la definición de estrategias de desarrollo y la planeación operativa de los campos, en consecuencia, los equipos de ingeniería requieren metodologías que permitan construir pronósticos confiables, comparables y actualizables con oportunidad, especialmente en escenarios donde existen múltiples pozos con comportamientos heterogéneos y condiciones dinámicas de operación.

Bajo este marco, históricamente se han consolidado enfoques que pueden agruparse en metodologías basadas en física del yacimiento como los modelos numéricos y metodologías basadas en el comportamiento histórico tales como modelos analíticos/empíricos, cada una con ventajas y restricciones prácticas. A continuación, se describen estos enfoques y, posteriormente, se introduce la transición hacia técnicas de inteligencia artificial, que constituyen el eje metodológico de este proyecto.

1.3.1 Enfoques tradicionales de pronóstico de productividad

Modelos numéricos de simulación

Esta técnica se basa en la construcción de un modelo geológico, para posteriormente realizar un ajuste de la información existente del yacimiento y posteriormente al resolver ecuaciones físicas y químicas predecir el comportamiento de los pozos productores de un yacimiento. Sin embargo, esta metodología requiere tiempos altos de ejecución [1].

En la práctica, cuando se requiere iterar rápidamente, incorporar cambios frecuentes o cubrir grandes volúmenes de pozos, la alta demanda de tiempo y especialización de los modelos numéricos suele limitar su uso como herramienta de pronóstico operativo continuo. En este punto adquieren relevancia metodologías alternativas más livianas, basadas en el análisis de tendencias históricas como el DCA descrito a continuación.

Análisis de curvas de declinación - DCA

Los métodos estadísticos son una forma de predecir la producción de pozos analizando los datos experimentales utilizando un método matemático estadístico. Estos métodos son sencillos de usar y proporcionan velocidades de cálculo rápidas, pero suelen adaptarse mal y logran bajas precisiones de cálculo. La técnica clásica y más ampliamente aplicada es el Análisis de Curvas de Declinación, DCA, [4], es un método de previsión de la producción de petróleo y gas que se basa en el historial de producción anterior. Este método es el más utilizado en la industria debido a su relativa sencillez y flexibilidad, se basa en el ajuste de una curva a los datos de producción históricos, la cual puede tener un comportamiento exponencial, hiperbólico o armónico, y

posterior al ajuste se proyecta este comportamiento y se emplea esta proyección como la producción futura del pozo. Ejemplos de las ecuaciones se encuentra a continuación:

$$q = \frac{q_i}{(1 + ba_i \Delta t)^{\frac{1}{b}}} \quad (1)$$

$$a_i = \frac{1}{b} [(1 - d_i)^{-b} - 1] \quad (2)$$

En estas ecuaciones b es una constante adimensional que se mueve entre 0 y 1, q_i es la tasa de producción inicial, Δt es el delta de tiempo, d_i es la tasa de declinación.

Aunque el DCA es ampliamente utilizado por su sencillez y flexibilidad, su dependencia del comportamiento histórico, patrones históricos extensos y supuestos, resulta restrictivo cuando existen cambios operacionales, alta heterogeneidad o interferencias entre pozos. En ese contexto, se han adoptado estrategias intermedias que buscan representar “familias” de comportamiento mediante agrupación o pozos tipo.

Pozos tipo

El análisis de pozo tipo implica la evaluación de la producción histórica de varios pozos para posteriormente ser clasificados y agrupados en función de su comportamiento de declinación. Cada una de estas agrupaciones se busca representar por una sola curva que pasa a llamarse “curva tipo” y puede ser empleada para predecir la producción futura de los pozos productores siempre y cuando las características físicas entre ellos sean similares [5]. Sin embargo, presenta limitaciones y es que se basa en datos históricos y asume que la producción futura seguirá tendencias similares en cada uno de los grupos de pozos, adicionalmente la precisión de los pronósticos depende de la calidad de los datos, la identificación adecuada de los pozos tipo y la consideración de posibles incertidumbres.

1.3.2 Motivación para enfoques en ciencia de datos: limitaciones y oportunidades

La predicción de la productividad de los pozos petroleros es una tarea fundamental en la gestión de yacimientos, siendo crucial para la formulación de planes de desarrollo y ajuste, la toma de decisiones de inversión y la maximización del retorno del capital [10], [11], [12]. Tradicionalmente, se han empleado métodos empíricos, analíticos, de análisis de declinación de la producción y de simulación numérica para este fin. Sin embargo, estos enfoques presentan limitaciones significativas, como una alta dependencia de la experiencia del ingeniero, una gran incertidumbre en los resultados, y ser complicados y lentos [13], [14], [15]. Los modelos basados en la física, por su parte, son difíciles de construir y resolver, requiriendo una modelización geológica y numérica

precisa, así como un ajuste de historial exhaustivo, lo que consume mucho tiempo y demanda amplios conocimientos profesionales.

Ante estos desafíos, el campo de la ciencia de datos, y en particular el aprendizaje automático (Machine Learning, ML), ha emergido como una solución prometedora para la predicción de la productividad de pozos. Los métodos de ML pueden procesar grandes volúmenes de datos, explorar patrones y tendencias complejos, e identificar la conectividad intrincada entre diversas variables que afectan la productividad [15], [16], [17]. A diferencia de los métodos convencionales, las aproximaciones basadas en datos no requieren suposiciones subyacentes o simplificaciones de la física del flujo de fluidos, ya que aprenden directamente de los datos de campo reales [17]. Esto permite manejar problemas de optimización de predicción multifactoriales y no lineales, sin las limitaciones de los modelos geológicos, lo que resulta en una mejora significativa de la precisión y eficiencia en la creación de modelos de predicción fiables.

Con esta motivación, resulta necesario precisar los conceptos de inteligencia artificial y sus subcampos, y establecer cómo se conectan con el objetivo del proyecto: construir modelos predictivos de producción que aprovechen información histórica, de subsuelo y de superficie.

1.3.3 Fundamentos de Inteligencia artificial

Inteligencia Artificial

John McCarthy define a la inteligencia artificial como la ciencia y el proceso de ingeniería de fabricar maquinas inteligentes, especialmente programas inteligentes sin confinarse a los métodos biológicamente observables [6]. Con base a esta definición IBM define a la inteligencia artificial como el campo que combina la ciencia computacional y bases de datos robustos para habilitar la resolución de problemas [7]. La inteligencia artificial de manera clásica se clasifica en dos campos internamente:

- Machine Learning: este subcampo de la inteligencia artificial corresponde a las técnicas en donde se analizan los datos para aprender de ellos los patrones existentes y tomar decisiones o realizar predicciones de manera automática con base a la información pasada [8].
- Deep learning: esta subrama de Machine learning basa su aprendizaje en el análisis de datos no etiquetados (no procesados) sin la necesidad de la intervención humana, este aprendizaje es iterativo y los algoritmos clasifican los datos en función de los patrones o características observadas en diferentes categorías [8].

Técnicas Machine Learning

Diferentes autores subdividen los algoritmos de machine learning en supervisado y no supervisado a continuación, una descripción rápida de estas clasificaciones:

- **Aprendizaje Supervisado:** En esta clase de machine learning se involucran además de atributos de entrada predeterminados, atributos de salida definidos. En esta los algoritmos buscan clasificar y posteriormente predecir el atributo predeterminado, con base a un set de datos de entrenamiento [9]. Esta misma clasificación puede dividirse en algoritmos de Regresión o Clasificación, en función de la información de entrenamiento, es decir, si son variables continuas o de clases (discreta).
- **Aprendizaje no supervisado:** En esta clase a diferencia de la anterior el reconocimiento de los patrones sucede sin un atributo objetivo o etiqueta, de esta forma todas las variables son usadas como información de entrada y los algoritmos de machine learning realizan el etiquetado o clasificación para posteriormente realizar las predicciones basándose en estos [9]. Esta clasificación se llama entonces no supervisado, debido a que la etiqueta de los atributos no es realizada por el ser humano sino por el propio algoritmo.

Modelos de Machine Learning

Con los conceptos anteriores, el siguiente paso es revisar cómo la literatura ha aplicado ML (en ciertos casos, Deep Learning) a problemas de predicción de productividad, qué familias de modelos predominan y cómo ese panorama sustenta la selección metodológica del presente trabajo.

En la literatura reciente, se han utilizado una amplia gama de algoritmos de aprendizaje automático para la predicción de la productividad de pozos petroleros, cada uno con sus propias fortalezas y aplicaciones:

- **Modelos de Regresión Tradicionales:** Se han implementado regresión lineal (LR) y regresión lineal robusta, sin embargo, se ha observado que los resultados de LR pueden verse muy afectados por datos de pozos de alta productividad [10], [11], [12], [13], [14].
- **Máquinas de Soporte Vectorial (SVM) y Regresión de Vectores de Soporte (SVR):** Estos modelos son ampliamente utilizados. Se ha demostrado que SVR funciona mejor con muestras pequeñas y datos no lineales complejos, y en algunos casos ha exhibido una mayor precisión que otras técnicas [12], [13], [14], [15], [16], [17], [18].
- **Modelos Basados en Árboles:** Incluyen árboles de decisión y Random Forest (RF), este último se destaca por su capacidad para manejar datos multidimensionales y prevenir el

sobreajuste, y a menudo se utiliza para determinar la importancia de las características [11], [16], [17], [18], [19], [20], [21], [22], [23].

- **Algoritmos de Boosting:** Como XGBoost (Extreme Gradient Boosting) y Light Gradient Boosting Machine (LightGBM), el primero ha demostrado ser el de mejor rendimiento en algunas comparaciones, mientras que LightGBM ha superado a otros modelos en estudios de predicción de productividad [10], [11], [12], [13], [16], [22], [23], [24], [25].
- **Redes Neuronales Artificiales (ANN) y Deep Learning (DL):** Las ANN, incluyendo Multi-Layer Perceptron (MLP) y Back Propagation (BPNN), son comunes, frecuentemente las ANN superan a modelos más simples en precisión de pronóstico, mientras que las Redes Neuronales Profundas (DNN), utilizan estructuras de red más profundas para extraer información más detallada de las características y mejorar la predicción o clasificación [10], [11], [12], [20], [25], [26].
- **Redes Neuronales Recurrentes (RNN) y Modelos de Secuencia:** Incluyen Long Short-Term Memory (LSTM) y Gated Recurrent Units (GRU), estos modelos son particularmente adecuados para el análisis de datos de series temporales, como los datos históricos de producción. LSTM ha demostrado una gran eficacia en la predicción de la producción en pozos con datos históricos acumulados [12], [15], [18], [20], [23], [26], [27], [28], [29], [30].
- **Modelos Híbridos y Avanzados:** Se han desarrollado combinaciones de arquitecturas de DL, como CNN-LSTM, que integran la capacidad de las Redes Neuronales Convolucionales (CNN) para extraer características espaciales con la habilidad de LSTM para manejar dependencias temporales, logrando resultados superiores a modelos individuales [26], [29], [31]. Otros modelos híbridos incluyen LSTM-BP y GCN-LSTM (Graph Convolutional Network-LSTM), que captura interacciones espaciales entre pozos además de correlaciones temporales [31], [32]. La regresión de procesos gaussianos (GPR) también se ha aplicado con éxito, especialmente para conjuntos de datos pequeños [13]. Los Bayesian Neural Networks (BNN), se han utilizado para generar pronósticos probabilísticos y cuantificar la incertidumbre en la predicción de la producción [33].

Para el objetivo y desarrollo de este trabajo se emplearon 4 algoritmos en específicos: Random Forest (RF), XGBoost, Support Vector Machine (SVM) y Multilayer Perceptron (MLP), razón por la cual a continuación se realizará una descripción más a profundidad de estos que sirva como base para el desarrollo de este documento.


Bosques Aleatorios (Random Forest)

El algoritmo de Bosques Aleatorios o Random Forest (RF) es una metodología de aprendizaje

supervisado de tipo ensamble que se utiliza tanto para tareas de clasificación como de regresión, la premisa fundamental de este modelo es que un conjunto "aprendices débiles" o árboles de decisión individuales puede superar el rendimiento de cualquier árbol único y complejo, siempre que estos no se encuentren correlacionados entre sí. Operativamente el RF opera bajo el principio de "bagging" o agregación por "Bootstrap", que consiste en entrenar cada árbol de decisión en un subconjunto de datos seleccionado aleatoriamente con reemplazo del conjunto de entrenamiento original [34]. Una característica distintiva de este algoritmo, que lo diferencia del bagging tradicional, es la introducción de la aleatoriedad en la selección de características, en cada nodo del árbol se selecciona un subconjunto aleatorio de variables para determinar la mejor combinación aumentando los que podría llamarse la diversidad del modelo y reducir significativamente la correlación entre los árboles individuales, lo que reduce el riesgo de sobreajuste y una mejor capacidad de generalización [11], [35].

En problemas de regresión, la predicción final del bosque se obtiene calculando el promedio aritmético de las predicciones de todos los árboles componentes, mientras que en clasificación se utiliza un mecanismo de votación por mayoría. Una de las grandes ventajas de este algoritmo es su capacidad para manejar grandes conjuntos de datos con miles de variables de entrada sin necesidad de reducción de dimensionalidad previa, además de baja sensibilidad a valores atípicos y al ruido, además de facilitar la interpretación del modelo en entornos industriales y científicos [36], [37].

Figura 1: Representación de la estructura del Random Forest [36]




Máquinas de Vectores de Soporte (Support Vector Machine)

La Máquina de Vectores de Soporte (SVM) es un modelo de aprendizaje supervisado diseñado originalmente para la clasificación binaria y extendido posteriormente para regresión y detección de valores atípicos, el objetivo principal de una SVM es encontrar el hiperplano de separación óptimo en un espacio n-dimensional que divida las clases con el margen máximo posible, la SVM busca maximizar la distancia entre el hiperplano decisor y los puntos de datos más cercanos de cada clase, denominados vectores de soporte [12], [38]. Lo que se refleja en que un margen más amplio reduce el error de generalización del clasificador y previene el sobreajuste. Para manejar datos que no son linealmente separables en su espacio original, la SVM utiliza funciones de núcleo que proyectan los vectores de entrada a un espacio de características de alta dimensionalidad donde la separación lineal se vuelve posible. Entre los núcleos más utilizados en la literatura se encuentran el lineal, el polinómico y la función de base radial (RBF) [38] .

XGBoost (eXtreme Gradient Boosting)

El XGBoost o eXtreme Gradient Boosting es una implementación optimizada y escalable del algoritmo de potenciación del gradiente (gradient boosting) para árboles de decisión, con alta velocidad y precisión predictiva, el cual a diferencia de los métodos de bagging, este construye el ensamble de forma secuencial, donde cada nuevo árbol se entrena específicamente para corregir los errores residuales del modelo acumulado anteriormente [39], [40]. El algoritmo incorpora una función objetivo regularizada que penaliza la complejidad del modelo, número de hojas y pesos de estas, lo que ayuda activamente a prevenir el sobreajuste y mejora la estabilidad del aprendizaje. Aunque es más sensible al ajuste de hiperparámetros que el Random Forest, su capacidad para iterar rápidamente mediante técnicas de parada temprana o early stopping lo convierte en una herramienta sumamente eficiente en entornos de producción [40], [41].

Figura 2: Representación de la estructura del XGBoost [42]



Perceptrón Multicapa (MLP)

El Perceptrón Multicapa (MLP) es la arquitectura clásica de una red neuronal artificial conformada por múltiples capas de unidades de procesamiento llamadas neuronas y estructuralmente, consta de una capa de entrada que recibe los datos, una o más capas ocultas que realizan transformaciones no lineales, y una capa de salida que genera la predicción final, cada conexión entre neuronas tiene un peso sináptico asociado y cada unidad posee un término de sesgo, *bias* y una función de activación que introduce la no linealidad necesaria para procesar datos linealmente inseparables [15], [38]. El proceso de aprendizaje implica el ajuste iterativo de estos pesos y sesgos mediante el cálculo de gradientes de una función de pérdida. A diferencia de los modelos lineales tradicionales, el MLP destaca por su capacidad de autoaprendizaje y memoria de información, permitiéndole descubrir patrones ocultos en datos complejos y ruidosos sin suposiciones previas sobre la distribución de estos [38], [40].

Propiedades y Entradas Utilizadas en los Modelos

La precisión de los modelos de ML depende en gran medida de la cantidad y calidad de los datos de entrada y abarcan una amplia gama de factores geológicos, de ingeniería y de producción, a continuación, un resumen, también en la Tabla 1 un consolidado resultado de la revisión del

estado del arte y en la última columna si se encuentra disponible para el campo/yacimiento objetivo de este proyecto:

- **Factores Geológicos:** Incluyen la porosidad, permeabilidad, espesor del yacimiento, saturación de gas, contenido de carbono orgánico total (TOC), profundidad estructural, espesor de la formación, contenido de lutitas, densidad del petróleo, grado API y espesor vertical.
- **Factores de Ingeniería y Terminación (Completion):** Se consideran parámetros de fracturación (incluyendo el tiempo de remojo, el corte de agua estable, el volumen de líquido de fracturación y el volumen de propante), el número de clústeres y etapas, la longitud lateral, la presión en la cabeza del pozo y el porcentaje del tamaño del estrangulador, así como la ubicación del pozo (latitud, longitud, coordenadas x, y) y el espaciamiento entre pozos. También se utilizan las propiedades mecánicas de la roca.
- **Datos de Producción y Dinámicos:** Estos abarcan los datos históricos de producción de petróleo, gas y agua, las horas en operación, la presión y temperatura promedio en el fondo del pozo, las variaciones de producción de líquido e inyección de agua de pozos vecinos, y la tasa de producción inicial. Los datos de series temporales son particularmente importantes para los modelos recurrentes.

Tabla 1: Variables empleadas en modelos de machine learning para la predicción de productividad en literatura y disponibilidad en campos estudio

Variable/Referencia	[11]	[14]	[21]	[43]	[10]	[16]	[20]	[44]	[18]	[26]	[24]	[31]	[28]	[45]	[46]	Total	Campo 1	Campo 2	Campo 3
Porosidad	X		X	X	X	X	X		X			X		X		9	Disponible	Disponible	No disponible
Permeabilidad	X	X	X	X	X	X	X	X	X	X		X		X		12	Disponible	Disponible	No disponible
Saturación aceite o gas	X			X	X	X	X		X							6	Disponible	Disponible	No disponible
Saturación de agua												X		X		2	Disponible	Disponible	No disponible
Ubicación X Y										X				X		2	Disponible	Disponible	Disponible
Contacto OGW fracción										X						1	No disponible	No disponible	No disponible
Gamma Ray									X			X				2	No disponible	No disponible	No disponible
Tiempo Tránsito												X				1	No disponible	No disponible	No disponible
Coefficiente estratigráfico									X							1	No disponible	No disponible	No disponible
Densidad Roca									X			X				2	No disponible	No disponible	No disponible
Resistividad									X			X				2	No disponible	No disponible	No disponible
Profundidad									X						X	2	Disponible	Disponible	Disponible
Presión de yacimiento							X									1	No disponible	No disponible	Disponible
Radio pozo												X				1	Disponible	Disponible	Disponible
Aceite Original	X									X						2	No disponible	No disponible	No disponible
Espesor			X	X	X	X		X	X			X				7	Disponible	Disponible	Disponible
Producción de agua			X													1	Disponible	Disponible	Disponible
Inyección de agua vecinos			X													1	Disponible	Disponible	No disponible
Producción de agua vecinos			X													1	Disponible	No disponible	No disponible
Volumen arena de fractura	X						X		X							3	No Aplica	No Aplica	No Aplica
Volumen líquido de fractura	X			X		X	X		X							5	No Aplica	No Aplica	No Aplica
Presión de fractura						X										1	No Aplica	No Aplica	No Aplica
FlowBack						X			X							2	No Aplica	No Aplica	No Aplica
Tasa de bombeo Fractura						X										1	No Aplica	No Aplica	No Aplica
Fracción de arena fractura	X						X		X					X	X	5	No Aplica	No Aplica	No Aplica
Fracción de líquido fractura	X													X	X	3	No Aplica	No Aplica	No Aplica
Corte de agua	X														X	2	Disponible	Disponible	Disponible
Tiempo remojo de fractura	X															1	No Aplica	No Aplica	No Aplica
Etapas de fractura															X	1	No Aplica	No Aplica	No Aplica
Espaciamiento entre pozos				X			X									2	No Aplica	No Aplica	No Aplica
Longitud fractura				X				X							X	3	No Aplica	No Aplica	No Aplica
Net to Gross		X	X													2	No disponible	No disponible	No disponible
GOR		X			X					X						3	Disponible	Disponible	Disponible
Volumen de shale					X	X						X				3	Disponible	Disponible	No disponible
Viscosidad crudo yacimiento					X							X				2	No disponible	No disponible	No disponible
Viscosidad crudo superficie					X											1	No disponible	No disponible	No disponible
Movilidad					X											1	No disponible	No disponible	No disponible
SKIN								X				X				2	No disponible	No disponible	No disponible
Delta de Presión								X		X						2	No disponible	No disponible	Disponible
API					X											1	No disponible	No disponible	No disponible

Con las variables definidas, la comparación entre modelos requiere métricas consistentes que capturen tanto la magnitud del error como el ajuste global, por ende a continuación se resumen las métricas más empleadas en investigaciones publicadas recientemente y adoptadas en esta investigación como referencia para la evaluación del desempeño

Métricas de Evaluación de Modelos

Para evaluar el rendimiento de los modelos predictivos, se utilizan varias métricas clave en las investigaciones precedentes, entre las cuales se encuentran las siguientes a continuación, en la Tabla 2:

- **Error Cuadrático Medio (RMSE):** Mide la magnitud promedio de los errores, indicando la desviación entre los valores predichos y reales. Un valor menor indica un mejor rendimiento.
- **Error Absoluto Medio (MAE):** Representa el promedio de las diferencias absolutas entre las predicciones y los valores reales.
- **Coeficiente de Determinación (R^2):** Indica la proporción de la varianza en la variable dependiente que es predecible a partir de las variables independientes. Un valor más cercano a 1 sugiere una mejor correlación y menor error.
- **Error Porcentual Absoluto Medio (MAPE):** Expresa el error en términos de porcentaje del valor real, útil para comparar el rendimiento entre conjuntos de datos de diferentes escalas.
- **Puntuación de Varianza Explicada (EV):** Similar a R^2 , proporciona una medida de qué tan bien el modelo explica la varianza de la variable objetivo.
- **Error Relativo Medio (MRE):** Evalúa la precisión del modelo en términos de error relativo.
- **Root Mean Squared Log Error (RMSLE):** Utilizado para cuantificar la precisión, especialmente cuando las variables objetivo pueden tener una distribución sesgada.
- **Mean Continuous Ranked Probability Score (mean CRPS):** Empleado para evaluar la precisión de los pronósticos probabilísticos, considerando tanto la precisión puntual como la incertidumbre.
- **Error Absoluto Mediano (MedAE):** Representa la mediana (el valor central) de las diferencias absolutas entre las predicciones y los valores reales. Es destacable por su alta robustez frente a valores atípicos (outliers).

- **Métrica de Huber (Huber Loss):** Combina las propiedades del RMSE y el MAE. Actúa de forma cuadrática (como RMSE) para errores pequeños y de forma lineal (como MAE) para errores grandes, logrando un equilibrio entre sensibilidad a outliers y precisión cerca del objetivo.

Tabla 2: Métricas empleadas para medir el desempeño de modelos de machine learning para la predicción de productividad

Métricas /Referencias	[11]	[14]	[21]	[43]	[10]	[16]	[20]	[44]	[18]	[26]	[24]	[31]	[28]	[45]	[46]	Total
RMSE	X	X			X		X	X	X	X		X	X	X	X	11
MAE	X	X			X		X			X	X	X	X			8
R2	X	X	X		X		X		X	X	X	X		X		10
MAPE					X							X	X	X		4
MSE		X				X					X					3
MEDAE														X		1
Perdida de Huber														X		1
EV Score											X					1

Desafíos y Perspectivas Futuras

A pesar de los avances significativos, la aplicación de ML en la predicción de la productividad de pozos no está exenta de desafíos. La escasez de datos en algunas formaciones o el tamaño limitado de los conjuntos de datos pueden afectar la precisión de los resultados, aunque ciertos modelos como SVR y GPR demuestran un buen rendimiento con datos pequeños [11], [13], [18]. La falta de talentos híbridos con experiencia tanto en ML como en la industria del petróleo y gas representa una barrera para desarrollar modelos efectivos y aplicables [22], [23]. Además, los modelos de DL puramente basados en datos pueden sufrir de alta demanda de datos, inestabilidad predictiva y una débil capacidad de generalización si no se consideran las leyes físicas inherentes a los datos. La predicción a largo plazo también presenta un desafío, ya que los modelos de ML pueden generar resultados "no físicos" o requerir ajustes constantes para mantener la precisión [2], [47].

Las futuras investigaciones podrían enfocarse en la integración de enfoques basados en datos y modelos físicos (fusión de datos y física), lo que podría conducir a soluciones híbridas más robustas y precisas [23], [27]. La exploración de técnicas de aprendizaje de transferencia también podría ser beneficiosa para aplicar el conocimiento adquirido en yacimientos con datos abundantes a aquellos con datos limitados [48]. Además, la mejora continua en las técnicas de selección de características de alta dimensión y la optimización de parámetros de ingeniería

mediante métodos como Grid Search y Bayesian Optimization, pueden aumentar aún más la producción y reducir los costos operativos [11].

En conclusión, el aprendizaje automático ha transformado la predicción de la productividad de pozos al ofrecer una metodología más eficiente, precisa y capaz de manejar la complejidad de los yacimientos de hidrocarburos. La adopción de diversos algoritmos, la consideración de múltiples factores de entrada y la validación rigurosa han demostrado el valor de esta tecnología como una herramienta indispensable para la optimización de las operaciones y la planificación estratégica en la industria petrolera [11].

2. CONJUNTO DE DATOS Y ANALISIS EXPLORATORIO

Debido a la confidencialidad de los datos, no se suministra el nombre de los 3 campos estudio y tampoco sus localizaciones, sin embargo, se hace una descripción general de los mismos a continuación.

Los 3 campos campo se encuentra en Colombia, descubiertos entre las décadas de 1950 y 1990, sus principales areniscas productoras, para los dos primeros campos de interés se encuentran clasificadas en tres grupos principales Grupo A, Grupo B y Grupo C, que producen de manera conjunta o de manera individual y se encuentran bajo procesos de inyección de agua como método de recobro secundario. El campo tres del estudio presenta 18 agrupaciones de areniscas y también se encuentra sometido a un proceso de recobro secundario. Debido al proceso de inyección de agua en el campo, la complejidad estructural, producción irregular y sedimentológico del yacimiento dificultan la predicción de la producción en los 3 campos.

2.1 Campo 1

2.1.1 Conjunto de datos y análisis descriptivo

El conjunto de datos de 29 columnas y 264 pozos del campo evaluado, Las variables categóricas son 'zona', 'formation' y 'sla', una variable identificadora 'well_id', la variable objetivo es 'bopd' y no hay datos faltantes en este conjunto de datos. Estos datos se encuentran divididos en 3 grupos:

- Original: son las variables originales del conjunto de datos y no han sido modificados.
- Alterna: son variables originales, pero con un tratamiento diferente desde la fuente, y representan una variable del conjunto original, por ejemplo, phi_sum y phi_avg representan la misma información sin embargo fueron exportados con dos métodos de cálculo diferentes: el primero obtiene el promedio geométrico de los datos pie a pie de

los registros de pozos excluyendo las zonas donde no se cumple el criterio de roca yacimiento productiva es decir porosidad, contenido de arena y saturación de aceite mayores a un límite técnico; el segundo suma esas mismas propiedades teniendo estos mismos criterios excluyentes del método anterior sin embargo no calcula un promedio solo una sumatoria. Los pares son: ϕ_{sum}/ϕ_{avg} , sw_{sum}/sw_{avg} , $vshale_{sum}/vshale_{avg}$, $kperm_{sum}/kperm_{avg}$.

- Calculada: las variables son el resultado de la combinación de otras variables originales y/o alternas entre ellas buscando representar una fórmula física relacionada con la industria.

A continuación, una tabla especificando el nombre de la variable, su definición y tipo de dato de este conjunto de datos, Tabla 3.

Tabla 3: Descripción de variables en el conjunto de datos

#	Variable	Tipo de dato	Significado
1	bopd	Cuantitativa	Caudal de Producción de crudo promedio año
2	Well_id	Cualitativa	Identificador del pozo
3	X	Cuantitativa	Coordenada X
4	Y	Cuantitativa	Coordenada Y
5	PMP	Cuantitativa	Profundidad punto medio de cañoneos abiertos ft
6	Hnet	Cuantitativa	Sumatoria Espesor neto del pozo
7	ϕ_{sum}	Cuantitativa	Promedio de porosidad de todos los cañoneos abiertos original
8	ϕ_{avg}	Cuantitativa	Promedio de porosidad de todos los cañoneos abiertos alternativa
9	sw_{sum}	Cuantitativa	Promedio de saturación de agua de todos los cañoneos abiertos original
10	sw_{avg}	Cuantitativa	Promedio de saturación de agua de todos los cañoneos abiertos alternativa
11	Niny	Cuantitativa	Número de inyectores activos de primera línea circundantes al pozo productor
12	Nprod	Cuantitativa	Número de productores activos de primera línea circundantes al pozo productor
13	Winjcum	Cuantitativa	Acumulado inyección pozos cercanos
14	Bsw	Cuantitativa	Fracción de agua producida
15	Hpunz	Cuantitativa	Espesor cañoneado
16	Vshale_sum	Cuantitativa	Volumen de shale promedio original
17	Vshale_avg	Cuantitativa	Volumen de shale promedio alternativa
18	unitsopen	Cuantitativa	Conteo de Unidades abiertas a producción
19	formation	Cualitativa	Formación productora
20	sla	Cualitativa	Sistema de levantamiento artificial
21	pwf	Cuantitativa	Presión de fondo fluyente
22	$kperm_{sum}$	Cuantitativa	Permeabilidad promedio original
23	$kperm_{avg}$	Cuantitativa	Permeabilidad promedio alternativa
24	zona	Cualitativa	Agrupaciones de pozos separadas por zonas de fallas
25	kh_{sum}	Cuantitativa	Variable calculada a partir de $kperm_{sum}$ y Hnet
26	kh_{avg}	Cuantitativa	Variable calculada a partir de $kperm_{avg}$ y Hnet
27	$kh_{sumabsw}$	Cuantitativa	Variable calculada a partir de $kperm_{sum}$, Hnet, bsw
28	$kh_{sumabswpwf}$	Cuantitativa	Variable calculada a partir de $kperm_{sum}$, Hnet, bsw, pwf
29	$hnet\phi_{sum}sw_{sum}$	Cuantitativa	Variable calculada a partir de Hnet, ϕ_{sum} , sw_{sum}

A continuación, se presenta la Tabla 4 mostrando el resumen de los estadísticos descriptivos de las variables cuantitativas previamente mencionadas, para las coordenadas debido a la limitación de confidencialidad no se muestran en esta tabla.

Tabla 4: Estadística descriptiva variables cuantitativas conjunto de datos campo 1

#	Variable \ Descriptor	Tipo	Media	std	min	25%	50%	75%	Max
1	bopd	Original	28,37	18,84	4,84	15,91	23,20	35,66	127,94
2	bsw	Original	0,81	0,19	0,12	0,76	0,90	0,93	0,99
5	niny	Original	5,25	3,18	1,00	2,00	5,00	7,00	15,00
6	nprod	Original	14,29	9,15	1,00	6,00	13,50	20,00	45,00
7	winjcum	Original	11.320.283,30	9.124.275,54	30.643,37	4.140.490,65	9.732.553,82	15.985.630,30	44.166.035,90
8	pmp	Original	4.350,29	1.052,84	2.747,00	3.618,75	3.960,25	4.825,25	6.637,50
9	hpunz	Original	269,33	151,29	22,33	168,66	253,82	340,75	1.312,84
10	unitsopen	Original	10,42	3,45	4,00	8,00	10,00	12,25	20,00
11	hnet	Original	361,33	217,19	14,00	200,00	312,00	489,75	1.382,25
12	phi_sum	Original	9,29	5,88	0,28	4,35	8,47	13,28	28,38
13	sw_sum	Original	14,37	8,69	0,00	8,07	12,49	19,09	52,84
14	vshale_sum	Original	5,42	3,45	0,02	2,81	4,65	7,35	18,18
15	kperm_sum	Original	8.897,87	7.149,31	0,00	3.532,64	6.746,03	12.558,00	41.407,45
16	pwf	Original	470,86	232,74	19,22	318,52	472,45	592,40	1.647,83
17	phi_avg	Alterna	0,22	0,03	0,13	0,21	0,23	0,24	0,28
18	sw_avg	Alterna	1,18	13,11	0,00	0,28	0,33	0,44	213,43
19	vshale_avg	Alterna	0,13	0,04	0,02	0,11	0,13	0,15	0,39
20	kperm_avg	Alterna	228,96	329,76	0,00	141,44	191,46	252,18	5.065,72
21	kh_sum	Calculada	78.664,29	61.739,77	0,00	31.017,12	61.271,31	113.722,74	373.080,20
22	kh_avg	Calculada	2.163,79	4.587,10	0,00	1.178,66	1.626,72	2.182,00	70.920,08
23	kh_sumabsw	Calculada	99.451,50	80.660,58	0,00	42.114,28	83.169,22	137.021,96	644.724,02
24	kh_sumabswpwf	Calculada	51.153.677,13	53.582.460,15	0,00	12.850.255,87	34.160.577,94	68.760.582,62	334.613.476,20
25	hnetphi_sum_sw_sum	Calculada	114.215,13	274.246,01	0,00	7.648,53	29.733,66	129.792,03	3.530.544,74

Existen en este conjunto de datos 4 variables categóricas: well_id, zona, formation, y sla. La primera corresponde al nombre de pozo (confidencial) y no representa un uso para este estudio al representar solo un identificador, las otras tres variables se encuentran descritas en el siguiente cuadro con el conteo por cada categoría interna, ver Tabla 5.


Tabla 5: Variables categóricas y numero de categorías

Variable	Número de categorías
zona	3
formation	5

sla	4
-----	---

La variable objetivo como se mencionó previamente es “bopd”, el caudal de producción de crudo de cada pozo, la cual sigue un comportamiento de asimetría positiva marcada ($\text{skew} \approx 2.14$), colas pesadas ($\text{kurtosis} \approx 6.73$), presencia de valores altos los cuales se observan en el histograma y boxplot a continuación, en este último no se observa un número alto de outliers, ver Figura 3.

Figura 3: Histograma y boxplot variable objetivo Campo 1



De la Existen en este conjunto de datos 4 variables categóricas: well_id, zona, formation, y sla. La primera corresponde al nombre de pozo (confidencial) y no representa un uso para este estudio al representar solo un identificador, las otras tres variables se encuentran descritas en el siguiente cuadro con el conteo por cada categoría interna, ver Tabla 5.

Tabla 5, evaluando los datos por separado se observan los siguientes comportamientos para algunas de las variables:

- **bopd:** existe un rango amplio entre mínimo y máximo, con P50 cercano a 23,2; el histograma y el boxplot evidencian sesgo positivo y outliers altos mayores a 70, mientras que la producción se concentra en niveles bajos-medios, 16–36 bopd.
- **bsw:** la mayor parte de los pozos presenta altos cortes de agua con P25 de 0,76, sin embargo, existen valores bajos por debajo de 0.15 poco habituales en sistemas con inyección de agua.
- **niny:** presenta una media de 5,25 y mediana cercana de 5, su distribución es casi simétrica con presencia de casos altos de hasta 15 inyectores, por encima del patrón clásico de cinco puntos.
- **Pmp:** presenta una media por encima de la mediana y un IQR moderado sugieren una distribución relativamente plana con posibles sub-modos por áreas.

- **hpunz:** media y mediana relativamente cercanas, 269 vs 254, pero con máximo por encima de 1.300 que se aleja del IQR, señalando outliers altos.
- **hnet:** presenta media y medianas cercanas, lo que sugiere cierta simetría, no obstante, el máximo por encima de 1.300 excede ampliamente el IQR permitiendo identificar outliers en el extremo superior.
- **pwf:** presenta un P50 y media muy cercanos con IQR de 319 a 592, lo cual muestra un comportamiento estable con algunos máximos que amplían la dispersión.

2.1.2 Análisis de correlación

Se emplean los métodos de correlación de Pearson, que evalúa relaciones lineales, Spearman, que evalúa relaciones no lineales, y la matriz de correlación mixta de la librería dython, con el objetivo de analizar el comportamiento entre las variables del conjunto de datos y su relación con la variable objetivo '*bopd*' buscando identificar redundancias, multicolinealidad y posibles variables con bajo o alto impacto en la predicción del target, ver Figura 4, Figura 5.

Teniendo como base la información previa y con un cutoff para este campo de una correlación mínima de 0.1, este valor es relativamente bajo sin embargo solo dos variables categóricas superaron una correlación absoluta de 0.2, formation y sla. Se les dio priorización a las variables originales para evitar multicolinealidad entre las alternas y calculadas se seleccionaron 7 variables: bsw, Hnet, Sw_sum, pwf, formation, zona, sla. De la tabla a continuación se descartaron las variables calculadas "hnetphi_sum_sw_sum" y "kh_sumabsbw" para evitar multicolinealidad con las variables originales también incluidas por estar encima del límite. Se confirma el uso de las tres variables categóricas por encontrarse por encima de este mismo límite.

Figura 4: Matriz de correlación de Pearson y Spearman Campo 1





Figura 5: Matriz de correlación mixta campo 1, librería dython



2.1.3 Análisis de Outliers


Se realizó un análisis de outliers con la metodología IQR, Figura 6, encontrando un porcentaje bajo en las variables seleccionadas para el entrenamiento del modelo, razón la cual se decide no realizar un tratamiento, adicionalmente debido a que el conjunto de datos solo comprende de 264 pozos la eliminación de registros puede afectar fuertemente el desempeño de un modelo.

Este riesgo se identificó como alto para bsw, el cual correspondía a alterar 9.47% de los registros, el porcentaje de las otras variables seleccionadas era demasiado bajo y se decide continuar sin tratamiento a los mismos, ver Tabla 6.

Tabla 6: Porcentaje de outliers por variable campo 1, valor de correlación Spearman y matriz dython para categóricas

#	Variable	Tipo	Corr Spearman o mixta	Numero de outliers IQR	% outliers
1	bsw	Original	-0,18	25	9,47
2	x	Original	0,06	22	8,33
3	hnetphi_sum_sw_sum	Calculada	0,14	22	8,33
4	vshale_avg	Alternativa	-0,02	17	6,44
5	kh_avg	Calculada	-0,03	17	6,44
6	kperm_avg	Alternativa	-0,04	14	5,3
7	phi_avg	Alternativa	-0,01	13	4,92
8	kh_sumabswpwf	Calculada	0,01	12	4,55
9	bopd	Original	1,00	11	4,17
10	kh_sumabsw	Calculada	0,10	7	2,65
11	kperm_sum	Original	0,04	7	2,65
12	sw_sum	Original	0,17	7	2,65
13	sw_avg	Alternativa	0,06	7	2,65
14	winjcum	Original	0,01	7	2,65
15	hpunz	Original	0,03	6	2,27
16	pwf	Original	-0,16	6	2,27
17	vshale_sum	Original	0,08	6	2,27
18	unitsopen	Original	0,01	5	1,89
19	kh_sum	Calculada	0,07	5	1,89
20	hnet	Original	0,14	4	1,52
21	y	Original	0,05	4	1,52
22	niny	Original	0,04	2	0,76
23	nprod	Original	0,01	1	0,38
24	pmp	Original	0,05	1	0,38
25	phi_sum	Original	0,08	1	0,38
26	zona	Original	0,10	0	0,00
27	formation	Original	0,24	0	0,00
28	sla	Original	0,25	0	0,00

Figura 6: Diagrama de caja y bigote para diferentes variables numéricas campo 1



2.2 Campo 2

2.2.1 Conjunto de datos y análisis descriptivo

El conjunto de datos contiene 110 pozos y 27 variables. Las variables categóricas son 'formation' y 'sla', una variable identificadora 'well_id', la variable objetivo es 'bopd' y no hay datos faltantes en este dataset. Estos datos se encuentran divididos en 3 grupos:

- Original: son las variables originales del conjunto de datos y no han sido modificados.
- Alterna: son variables originales, pero con un tratamiento diferente desde la fuente, y representan una variable del conjunto original, por ejemplo, phi_sum y phi_avg representan la misma información sin embargo fueron exportados con dos modelos de cálculo diferentes. Los pares son phi_sum/phi_avg, sw_sum/sw_avg, vshale_sum/vshale_avg, kperm_sum/kperm_avg.
- Calculada: las variables son el resultado de la combinación de otras variables originales y/o alternas entre ellas buscando representar una fórmula física relacionada con la industria.

A continuación, una tabla especificando la definición de cada variable y tipo de dato de este conjunto de datos, Tabla 7.

Tabla 7: Descripción de variables en el conjunto de datos campo 2

#	Variable	Tipo de dato	Detalle
1	bopd	Cuantitativa	Caudal de Producción de crudo promedio año
2	Well_id	Cualitativa	Identificador del pozo

3	X	Cuantitativa	Coordenada X
4	Y	Cuantitativa	Coordenada Y
5	PMP	Cuantitativa	Profundidad punto medio de cañoneos abiertos ft
6	Hnet	Cuantitativa	Sumatoria Espesor neto del pozo
7	phi_sum	Cuantitativa	Promedio de porosidad de todos los cañoneos abiertos original
8	phi_avg	Cuantitativa	Promedio de porosidad de todos los cañoneos abiertos alternativa
9	sw_sum	Cuantitativa	Promedio de saturación de agua de todos los cañoneos abiertos original
10	sw_avg	Cuantitativa	Promedio de saturación de agua de todos los cañoneos abiertos alternativa
11	Niny	Cuantitativa	Número de inyectores activos de primera línea circundantes al pozo productor
12	Winjcum	Cuantitativa	Acumulado inyección pozos cercanos
13	Bsw	Cuantitativa	Fracción de agua producida
14	Hpunz	Cuantitativa	Espesor cañoneado
15	Vshale_sum	Cuantitativa	Volumen de shale promedio original
16	Vshale_avg	Cuantitativa	Volumen de shale promedio alternativa
17	unitsopen	Cuantitativa	Conteo de Unidades abiertas a producción
18	formation	Cualitativa	Formación productora
19	sla	Cualitativa	Sistema de levantamiento artificial
20	pwf	Cuantitativa	Presión de fondo fluyente
21	kperm_sum	Cuantitativa	Permeabilidad promedio original
22	kperm_avg	Cuantitativa	Permeabilidad promedio alternativa
23	kh_sum	Cuantitativa	Variable calculada a partir de kperm_sum y Hnet
24	kh_avg	Cuantitativa	Variable calculada a partir de kperm_avg y Hnet
25	kh_sumabsw	Cuantitativa	Variable calculada a partir de kperm_sum, Hnet, bsw
26	kh_sumabswpwf	Cuantitativa	Variable calculada a partir de kperm_sum, Hnet, bsw, pwf
27	hnetphi_sum_sw_sum	Cuantitativa	Variable calculada a partir de Hnet, phi_sum, sw_sum

A continuación, se presenta la mostrando el resumen de los estadísticos descriptivos de las variables cuantitativas previamente mencionadas, para las coordenadas debido a la limitación de confidencialidad no se muestran en esta tabla.

Tabla 8: Estadística descriptiva variables cuantitativas conjunto de datos campo 2


#	Variable \ Descriptor	Tipo	Media	std	min	25%	50%	75%	Max
1	bopd	Original	108,44	81,64	2,10	45,53	91,40	158,40	365,50
2	bsw	Original	0,66	0,31	0,00	0,52	0,80	0,90	1,00
3	y	Original	1306812,06	1989,98	1303301,00	1305102,50	1306903,00	1308327,75	1311193,00
4	x	Original	1018129,65	1164,02	1015113,00	1017209,25	1018158,50	1019071,00	1020355,00
5	niny	Original	1,58	1,34	0,00	0,00	2,00	2,75	5,00
6	winjcum	Original	2099566,04	2826877,41	0,00	0,00	936443,50	3296878,50	14503770,00
7	pmp	Original	7448,85	678,40	4938,00	7094,25	7566,00	7946,00	8761,00
8	hpunz	Original	356,47	226,84	15,00	177,25	297,75	498,50	1096,00
9	unitsopen	Original	4,89	2,53	1,00	3,00	5,00	6,00	15,00
10	pwf	Original	1408,61	606,19	83,20	1011,05	1369,60	1811,85	2955,33
11	hnet	Original	844,68	548,50	10,50	414,88	759,63	1167,50	2545,50
12	phi_sum	Original	11,78	7,51	0,58	6,30	10,12	15,99	37,76
13	sw_sum	Original	25,84	15,32	0,96	15,30	23,10	32,89	81,57
14	vshale_sum	Original	10,52	7,28	0,29	5,01	9,63	15,37	31,53

15	kperm_sum	Original	5226,07	5037,48	182,56	1943,96	3649,12	6396,08	28479,89
16	phi_avg	Alternativa	0,19	0,02	0,15	0,17	0,19	0,20	0,24
17	sw_avg	Alternativa	0,43	0,09	0,27	0,36	0,42	0,49	0,65
18	vshale_avg	Alternativa	0,16	0,06	0,04	0,14	0,16	0,19	0,36
19	kperm_avg	Alternativa	84,18	54,00	13,50	43,53	74,84	112,37	286,35
20	kh_sum	Calculada	1720,02	1197,51	21,00	813,09	1405,50	2256,07	5744,89
21	kh_avg	Calculada	26,48	10,85	7,00	18,77	24,61	31,73	64,14
22	kh_sumabsw	Calculada	24249,57	168782,03	21,25	1185,61	2089,49	4022,92	1750394,25
23	kh_sumabswpwf	Calculada	17959198,02	97794785,79	47738,38	1733046,06	2878979,06	4663664,86	866095072,20
24	hnetphi_sum_sw_sum	Calculada	538147,37	928617,12	5,82	40065,43	177054,47	571644,98	5229365,11

Existen en este conjunto de datos 3 variables categóricas: well_id, formation, y sla. La primera corresponde al nombre de pozo (confidencial) y no representa un uso para este estudio al representar solo un identificador, las otras dos variables presentan 5 y 3 categorías respectivamente.

La variable objetivo como se mencionó previamente es “bopd”, la cual sigue un comportamiento de asimetría positiva y presencia de valores altos, visualmente se observa en el histograma y boxplot a continuación, en este último no se observa un número alto de outliers, *Figura 7*.

Figura 7: Histograma y boxplot variable objetivo Campo 2



De la Existen en este conjunto de datos 4 variables categóricas: well_id, zona, formation, y sla. La primera corresponde al nombre de pozo (confidencial) y no representa un uso para este estudio al representar solo un identificador, las otras tres variables se encuentran descritas en el siguiente cuadro con el conteo por cada categoría interna, ver Tabla 5.

Tabla 5, evaluando los datos por separado se observan los siguientes comportamientos para algunas de las variables:

- **bopd:** existe un rango amplio de 2 a 366 bopd, registrando a su vez un sesgo positivo y presencia de pocos outliers, pero elevados por encima de 300, mientras que la mayor

densidad de datos se concentra entre 45 y 160 bopd como rango intercuartil.

- **bsw**: predominan altos cortes de agua con P50 igual a 0.8 y P75 igual a 0.9, aunque existen valores bajos por debajo de 0.1 inusuales en sistemas con fuerte inyección.
- **niny**: la mayoría de los pozos se asocia a 0–3 inyectores y algunos registros presentaron un máximo de 5, su distribución se encuentra sesgada a la derecha, pero sin extremos severos.
- **winjcum**: distribución fuertemente asimétrica; P50≈0,93 M y P75≈3,30 M frente a máximo≈14,5 M. Se prevé cola derecha larga y alta variabilidad histórica de inyección.
- **pmp**: presenta un comportamiento con tendencia a simetría.
- **hpunz**: la media y mediana son 356 y 298, indicando que no es simétrica al igual que se observa presencia de outliers altos por encima de 1000 que se alejan del IQR, sugiriendo intervalos muy amplios en algunos pozos.
- **unitsopen**: esta variable se encuentra centrada con media y mediana cercanos a 5 y cercana a la normalidad operativa.
- **hnet**: presenta un sesgo positivo y presencia de espesores altos llegando a valores superiores de 2500.
- **phi_sum / phi_avg**: media y mediana muy próximas ($\phi_{avg} \approx 0.19$), IQR estrecho 0.17–0.22, baja dispersión y no se evidencian outliers relevantes.
- **sw_sum / sw_avg**: aunque P50 de sw_{avg} es aproximado a 0.36, la media de 0,43 revela sesgo a la derecha.
- **vshale_sum / vshale_avg**: la media y mediana se encuentran cercanos pudiendo indicar que se aproxima a simetría, presenta un IQR estrecho de 0.14 a 0.19) y extremos moderados.
- **kperm_sum / kperm_avg**: asimetría positiva y presenta colas altas con picos de permeabilidad indicando heterogeneidad en el reservorio.

2.2.2 Análisis de correlación

De igual forma al campo anterior se emplean los métodos de correlación de Pearson, Spearman, y la matriz de correlación mixta de la librería dython, con el objetivo de analizar el comportamiento entre las variables del conjunto de datos y su relación con la variable objetivo '*bopd*', ver Figura 8, Figura 9.

Teniendo como base la información previa y con un cutoff para este campo de una correlación mínima de 0.2 y priorizando las variables originales para evitar multicolinealidad entre las alternas y calculadas se seleccionaron 9 variables: Hpunz - unitsopen - Hnet - pwf - phi_sum - Sw_sum - Vshale_sum - Kperm_sum – sla. De los gráficos a continuación se descartaron la variable calculada

“hnetphi_sum_sw_sum” para evitar colinealidad con las variables originales también incluidas por estar encima del límite y “formation” por encontrarse debajo de este mismo límite, ver Figura 10, Figura 11.

Figura 8: Matriz de correlación de Pearson y Spearman Campo 2




Figura 9: Matriz de correlación mixta campo 2, librería dython




Figura 10: Variables numéricas con mayor correlación con variable objetivo, campo 2





Figura 11: Correlación de variables categóricas con bopd, campo 2



2.2.3 Análisis de Outliers

Se realizó un análisis de outliers con la metodología IQR también para el campo 2, encontrando un porcentaje bajo en las variables seleccionadas para el entrenamiento del modelo, razón la cual se decide no realizar un tratamiento de outliers, adicionalmente debido a que el conjunto de datos solo comprende de 110 pozos la eliminación de registros puede afectar fuertemente el desempeño de un modelo, riesgo alto para Kperm_sum, el cual correspondía a alterar 8.18% de los registros, el porcentaje de las otras variables era demasiado bajo y se decide continuar sin tratamiento a los mismos.

Tabla 9: Porcentaje de outliers por variable campo 2, valor de correlación Spearman y matriz

dython para categóricas

Variable	Tipo	Numero de outliers IQR	Corr Spearman o mixta	% outliers
kh_sumabsw	Calculada	15	0,23	13,64
kh_sumabswpwf	Calculada	13	0,16	11,82
hnetphi_sum_sw_sum	Calculada	13	0,35	11,82
vshale_avg	Alternativa	12	0,1	10,91
kperm_sum	Original	9	0,27	8,18
kperm_avg	Alternativa	5	0,05	4,55
kh_avg	Alternativa	4	0,08	3,64
winjcum	Original	3	0,16	2,73
sw_sum	Original	3	0,3	2,73
hnet	Original	2	0,34	1,82
phi_sum	Original	2	0,35	1,82
unitsopen	Original	2	0,25	1,82
bopd	Original	2	1	1,82
pmp	Original	2	0,05	1,82
hpunz	Original	1	0,34	0,91
phi_avg	Alternativa	1	0,06	0,91
kh_sum	Original	1	0,33	0,91
vshale_sum	Original	1	0,31	0,91
y	Original	0	-0,03	0
x	Original	0	-0,03	0
niny	Original	0	0,06	0
bsw	Original	0	-0,06	0
sw_avg	Alternativa	0	-0,12	0
pwf	Original	0	-0,27	0
sla	Original	NA	0,46	0
formation	Original	NA	0,17	0

2.3 Campo 3

2.3.1 Conjunto de datos y análisis descriptivo

El conjunto de datos para el campo 3 contiene 351 pozos (observaciones) y 19 variables de carácter numérico y categórico. Las variables numéricas son 16 y las categóricas son 3, las cuales son 'zona' y 'formation', una variable identificadora 'well_id', la variable objetivo es 'bopd' y no hay datos faltantes en este dataset. El data set se encuentra dividido en 3 grupos:

- Original: son las variables originales del conjunto de datos y no han sido modificados.

- Alternas: son variables originales, pero con un tratamiento diferente desde la fuente, y representan una variable del conjunto original, por ejemplo, 'py' y 'py_datum' representan la misma información sin embargo presentan modelo de cálculo diferentes. Los pares para este dataset son: 'py'/'py_datum', 'pwf'/'pwf_datum'.
- Calculada: las variables son el resultado de la combinación de otras variables originales y/o alternas entre ellas buscando representar una formula física relacionada con la industria.

A continuación, una tabla especificando la definición de cada variable y tipo de dato de este conjunto de datos, Tabla 10.

Tabla 10: Descripción de variables en el conjunto de datos campo 3

#	Variable	Tipo de dato	Detalle
1	bopd	Cuantitativa	Caudal de Producción de crudo promedio año
2	Well_id	Cualitativa	Identificador del pozo
3	X	Cuantitativa	Coordenada X
4	Y	Cuantitativa	Coordenada Y
5	Pmp	Cuantitativa	Profundidad punto medio de cañoneos abiertos ft
6	Hnet	Cuantitativa	Sumatoria Espesor neto del pozo
7	Bsw	Cuantitativa	Fracción de agua producida
8	formation	Cualitativa	Formación productora
9	Pwf	Cuantitativa	Presión de fondo fluyente
10	Py	Cuantitativa	Presión de yacimiento
11	py_datum	Cuantitativa	Presión de yacimiento llevada a datum (presión de referencia)
12	pwf_datum	Cuantitativa	Presión de fondo fluyente llevada a datum (presión de referencia)
13	tvd_top_perf	Cuantitativa	Profundidad del primer cañoneo
14	tvd_depth_pump	Cuantitativa	Profundidad de la bomba
15	kperm_avg	Cuantitativa	Permeabilidad promedio
16	Zona	Cualitativa	Agrupaciones de pozos separadas por zonas de fallas
17	Kh	Cuantitativa	Variable calculada a partir de kperm_sum y Hnet
18	kh_sumabsw	Cuantitativa	Variable calculada a partir de kperm_sum, Hnet, bsw
19	kh_sumapwf	Cuantitativa	Variable calculada a partir de kperm_sum, Hnet, bsw, pwf

A continuación, se presenta la Tabla 11 mostrando el resumen de los estadísticos descriptivos de las variables cuantitativas previamente mencionadas, para las coordenadas debido a la limitación de confidencialidad no se muestran en esta tabla.

Tabla 11: Estadística descriptiva variables cuantitativas conjunto de datos campo 3


#	Variable \ Descriptor	Tipo	Media	std	min	25%	50%	75%	Max
1	bopd	Original	130,1	92,9	2,0	57,5	112,0	178,0	634,0
2	x	Original	1047815,6	2407,7	1043162,0	1045871,0	1047637,0	1049905,0	1052698,0
3	y	Original	919528,9	2427,5	914003,0	917818,0	919593,0	921458,0	923993,0
4	bsw	Original	0,89	0,12	0,15	0,87	0,94	0,97	1,00

5	pmp	Original	7021,0	358,1	6348,2	6740,6	6958,5	7241,1	8012,8
6	hnet	Original	81,6	21,4	18,7	68,6	81,7	95,5	146,5
7	py	Original	1813,1	249,5	1100,0	1624,9	1795,4	2031,2	2369,6
8	pwf	Original	1070,8	346,4	375,6	823,0	1048,0	1281,0	2095,0
9	kperm_avg	Original	1215,4	531,8	66,8	895,2	1112,3	1481,3	4043,3
10	kh	Calculada	99682,4	50085,3	4462,2	67191,9	92381,6	127787,2	334288,5
11	kh_sumabsw	Calculada	113665,2	59898,8	4613,6	74512,1	105436,1	140544,0	508364,9
12	kh_sumapwf	Calculada	64462230,1	40739446,1	412908,4	37389253,2	56432516,0	87047107,6	284549891,7
13	tvd_top_perf	Original	6950,0	365,8	5652,0	6678,0	6906,3	7177,3	7944,4
14	tvd_depth_pump	Original	5911,2	534,1	3936,0	5659,6	5947,2	6211,1	7461,9
15	py_datum	Alterna	1953,4	314,7	1099,4	1776,2	1922,4	2258,4	2566,2
16	pwf_datum	Alterna	1284,3	405,6	297,7	993,2	1271,1	1544,0	2343,7
16	pwf_datum	Alterna	1284,3	405,6	297,7	993,2	1271,1	1544,0	2343,7

Existen en este conjunto de datos 3 variables categóricas: well_id, formation, y zona. La primera corresponde al nombre de pozo (confidencial) y no será empleada para este estudio al representar solo un identificador, las otras dos variables presentan 18 y 7 categorías respectivamente.

La variable objetivo como se mencionó previamente es “bopd”, la cual sigue un comportamiento de asimetría positiva y presencia de valores altos, visualmente se observa en el histograma y boxplot a continuación, en este último no se observa un número alto de outliers. por ello se sugiere trabajar con la transformación log1p para estabilizar varianza y reducir la influencia de valores extremos, ver Figura 12.

Figura 12: Histograma y boxplot variable objetivo Campo 3



De la información previamente expuesta, evaluando los datos por separado se observan los

siguientes comportamientos para algunas de las variables:

- **bopd:** el caudal de producción de crudo, se observa un rango muy amplio de 2 a 634, presenta un sesgo positivo corroborado con un P50 de 112 y una media de 130, se observan outliers altos por encima de 350 que elevan la media y justifican el uso de transformaciones por ejemplo “*log1p*” o “*sqrt*” y métricas de error o pérdidas robustas en el modelado.
- **bsw:** el porcentaje de agua producido, predominan valores altos con una mediana de 0.94, aunque se observan algunos registros con valores bajos por debajo de 0.15.
- **pmp:** el punto medio de la bomba presenta un comportamiento casi simétrico corroborado con un P50 de 6959 y media de 7021, con un IQR moderado.
- **hnet:** el espesor neto de arena presenta una media de 81.6 y mediana de 81.7 demostrando simetría, no obstante, se presentan datos altos que se alejan del IQR.
- **pwf:** la presión de fondo fluyente mostró medias y medianas cercanas entre ellas 1071 versus 1048, con colas derechas moderadas compatible con la variabilidad y heterogeneidad del yacimiento.
- **kperm_avg:** la permeabilidad promedio presenta asimetría positiva y valores máximos elevados, lo que sugiere heterogeneidad en la permeabilidad efectiva y posibles canales de alta conducción.
- **tvd_top_perf / tvd_depth_pump:** las profundidades del tope de cañoneos y de la bomba presentaron distribuciones estables con IQR estrechos, sugiriendo consistencia en los rangos operativos.
- **py_datum:** la presión del yacimiento a una profundidad de referencia presento valores centrales y casi simétricas con una media de 1953 y P50 de 1.922 sin outliers severos.

2.3.2 Análisis de correlación

De igual forma al campo anterior se emplean los métodos de correlación de Pearson, Spearman, y la matriz de correlación mixta de la librería dython, con el objetivo de analizar el comportamiento entre las variables del conjunto de datos y su relación con la variable objetivo ‘*bopd*’, ver *Figura 13*, *Figura 14*.

Figura 13: Matriz de correlación de Pearson y Spearman Campo 3





Figura 14: Matriz de correlación mixta campo 3, librería dython



Las matrices de correlación Pearson y Spearman evidencian alta colinealidad en atributos de transmisibilidad, 'kh' y 'kperm_avg', y relaciones relevantes entre 'pmp' - 'pwf' con la variable 'bopd', indicando que para modelos lineales se debe seleccionar variables, mientras que la fuerza de asociación mixta dython indica relación moderada entre 'zona' y 'formation' con 'bopd'.

Teniendo como base la información previa y con un cutoff para este campo de una correlación mínima de 0.1 ya fuera en Pearson, Spearman o Dython y priorizando las variables originales para evitar multicolinealidad con las calculadas y las alternas que presentaron mejores correlaciones con la variable objetivo, se seleccionaron 9 variables: 'y', 'zona', 'bsw', 'pwf', 'pmp', 'tvd_top_perf', 'tvd_depth_pump', 'py_datum', 'formation'.

2.3.3 Análisis de Outliers

Se realizó un análisis de outliers con la metodología IQR, encontrando un porcentaje bajo en las variables seleccionadas para el entrenamiento del modelo, razón la cual se decide no realizar un tratamiento de outliers. Este riesgo se observó alto solo para 'bsw', el cual correspondía a alterar 9.97% de los registros, el porcentaje de las otras variables era demasiado bajo y se decide continuar sin tratamiento a los mismos, ver Tabla 12.

Tabla 12: Porcentaje de outliers por variable campo 3, valor de correlación Spearman y matriz dython para categóricas

#	Variable	Tipo	Corr Spearman o mixta	Numero de outliers IQR	% outliers
1	bsw	Original	-0,52	35	9,97
2	tvd_depth_pump	Original	-0,13	20	5,7
3	bopd	Original	1	11	3,13
4	kperm_avg	Original	0,06	10	2,85
5	kh	Calculada	0,01	10	2,85
6	kh_sumabsw	Calculada	0,12	10	2,85
7	hnet	Original	-0,04	9	2,56
8	kh_sumapwf	Calculada	0,07	9	2,56
9	pwf	Original	-0,17	4	1,14
10	tvd_top_perf	Original	-0,2	2	0,57
11	pmp	Original	-0,19	1	0,28
12	x	Original	-0,03	0	0
13	py	Original	0,01	0	0
14	y	Original	-0,17	0	0
15	py_datum	Original	0,13	0	0
16	pwf_datum	Original	-0,17	0	0
17	zona	Original	0,32	0	0
18	formation	Original	0,28	0	0

3 MODELO PREDICTIVO

Dentro del estudio del arte del proyecto se encontraron publicaciones recientes con casos similares de predicción de productividad en función de parámetros geológicos, históricos, en la tabla a continuación se detalla cada referencia con las metodologías implementadas, esto con el objetivo de evaluar cuales son técnicas de machine learning empleadas recurrentemente y con resultados promisorios, en esta misma tabla se incluye el número de pozos (muestra) empleados

para el entrenamiento y validación de estas técnicas. De esta información consolidada se decide que los modelos predictivos a usar son: Random Forest (RF), XGBoost, Support Vector Machine (SVM) y Multilayer Perceptron (MLP). De igual forma se realizó esta revisión en estas mismas investigaciones las métricas con las que fueron evaluados los modelos y comparados entre sí, teniendo en cuenta esta información consolidada se toma la decisión de emplear las métricas RMSE, MAE, R2, y MAPE para evaluar el desempeño de los moldeos siendo construidos para este proyecto.

Tabla 13: Técnicas de machine learning aplicadas en problemas similares de predicción de productividad

Variables /Referencias	[11]	[14]	[21]	[43]	[10]	[16]	[20]	[44]	[18]	[26]	[24]	[31]	[28]	[45]	[46]	
# pozos	47	60	468	61	394	224	145	246	189	1968	394	43	1239	464	7311	Total
Random forest	X		X						X	X	X		X		X	7
XGBoost	X				X					X	X		X			5
AdaBoost			X													1
Gradient Boost			X													1
Linear regression	X	X	X	X	X					X	X					7
Generalized Linear Model						X										1
Polynomial regression			X							X						2
Lasso			X													1
Decision Tree										X						1
Ridge Regression			X													1
Elastic Net Regressoin			X													1
Robust Linear Regression		X														1
Support vector machine		X	X	X					X	X	X					6
Cubic Kernel Support vector regression		X														1
Boosted Trees regression		X														1
Multilayer Perceptron			X	X	X		X	X	X		X	X				8
K nearest Neighbor				X												1
Light gradient boosting					X						X	X				3
Long Short-Term Memory Neural					X											1
Artificial Neural Network						X				X			X	X		4
RNN recurrent neural										X						1
Fuzzy Logic - Subtractive clustering								X								1

3.1 Preprocesamiento de variables

El conjunto de datos contiene tanto variables numéricas como categóricas, cada una con necesidades específicas de transformación. Para manejar estas diferencias de manera eficiente y reproducible, se implementó un pipeline de preprocesamiento utilizando ColumnTransformer y Pipeline. Las variables numéricas y categóricas fueron tratadas mediante:

- **Estandarización** mediante StandardScaler, transformando los valores para tener media cero y desviación estándar uno. Esta técnica es particularmente beneficiosa para algoritmos sensibles a la escala como SVM o redes neuronales.
- **Imputación con un valor constante**, asignando la categoría "missing" a entradas vacías.
- **Codificación One-Hot**, generando variables binarias para representar cada categoría sin introducir orden artificial entre ellas.

3.2 División del conjunto de datos

Con el objetivo de evaluar adecuadamente la capacidad de generalización de los modelos de regresión entrenados, se dividió el conjunto de datos en dos subconjuntos: entrenamiento y prueba. Esta separación se realizó de manera aleatoria, utilizando la función `train_test_split` de la biblioteca `scikit-learn`, reservando un 20% de los datos para pruebas. Esta división asegura que el modelo sea entrenado sobre una porción representativa de los datos, mientras que el desempeño se evalúa sobre un subconjunto no visto con el objetivo de obtener una estimación realista del error esperado.

3.3 Optimización de Hiperparámetros

Se evaluaron cinco modelos de regresión avanzados con distintas características y mecanismos de aprendizaje: Random Forest, XGBoost, Regresión Lineal, Support Vector Machine, Multi-Layer Perceptron. Con el objetivo de encontrar la mejor configuración posible de hiperparámetros para cada modelo, se utilizaron dos técnicas: *"RandomizedSearchCV"* y *"BayesSearchCV"*, la primera permite explorar el espacio de hiperparámetros mediante muestreo aleatorio y la segunda aprende basado en un mapa de la zona de hiperparámetros el cual usa después para seleccionar nuevas zonas a evaluar y repetir el proceso, lo cual permite una mayor eficiencia que el anteriormente mencionado.

En cuanto a la métrica principal de medición de esta optimización se seleccionó Huber y MedAE, ambos buscando robustez ante outliers ya que como se mencionó previamente no fueron eliminados los outliers de la variable objetivo de las variables de ingreso. Para cada modelo se

definieron distribuciones de muestreo, para los siguientes hiperparametros de acuerdo con el modelo optimizar:

- **RandomForest:** número de árboles ($n_estimators$), profundidad máxima (max_depth), mínimo de muestras para dividir ($min_samples_split$), mínimo de muestras en una hoja ($min_samples_leaf$), máximo de características ($max_features$), máximo de muestras por árbol ($max_samples$).
- **XGBoost:** número de árboles / iteraciones de boosting ($n_estimators$), profundidad máxima por árbol (max_depth), tasa de aprendizaje ($learning_rate$), fracción de muestras por árbol ($subsample$), fracción de características por árbol ($colsample_bytree$), peso mínimo de instancia por hoja (min_child_weight), reducción mínima de pérdida para dividir ($gamma$), regularización L2 (reg_lambda), regularización L1 (reg_alpha).
- **SVM:** núcleo ($kernel$), parámetro de penalización (C), ancho de la zona de tolerancia ϵ -insensitive ($epsilon$), coeficiente del núcleo ($gamma$).
- **MLP:** tamaños de las capas ocultas ($hidden_layer_sizes$), función de activación ($activation$), método de optimización ($solver$), coeficiente de regularización L2 ($alpha$), tasa de aprendizaje inicial ($learning_rate_init$), política de tasa de aprendizaje ($learning_rate$), tamaño de minibatch ($batch_size$), parada temprana ($early_stopping$), fracción de datos para validación ($validation_fraction$), número de iteraciones sin mejora ($n_iter_no_change$)
- **Regresión lineal:** no requiere ajuste de hiperparametros.

El espacio de hiperparametros inicial se encuentra a continuación, Tabla 14.

Tabla 14: Espacio de hiperparametros fase de búsqueda

Modelo	Hiperparametros	Espacio fase Búsqueda
RandomForest	$n_estimators$	(200, 3000)
	max_depth	(3, 40)
	$min_samples_split$	(2, 50)
	$min_samples_leaf$	(1, 20)
	$max_features$	['sqrt', 'log2']
	$max_samples$	(0.3, 0.7)
XGBoost	$n_estimators$	(200, 3000)
	max_depth	(2, 30)
	$learning_rate$	loguniform (1e-4, 3e-1)
	$subsample$	(0.30–1.0)
	$colsample_bytree$	(0.30, 0.70)

	min_child_weight	(1e-3, 5,0)
	gamma	(1e-5, 1,0)
	reg_lambda	loguniform (1e-3, 1e2)
	reg_alpha	(1e-5, 1e1)
SVM	kernel	['rbf', 'linear']
	C	loguniform (1e-2, 1e3)
	epsilon	loguniform (1e-4, 1e-1)
	gamma	loguniform (1e-6, 1.0)
MLP	hidden_layer_sizes	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]
	activation	['relu', 'tanh']
	solver	['adam']
	alpha	loguniform(1e-6, 1e-1)
	learning_rate_init	loguniform(1e-4, 1e-1)
	learning_rate	['adaptive']
	batch_size	[32, 64, 128, 256]
	early_stopping	[True]
	validation_fraction	[0.15]
	n_iter_no_change	[10, 40]
LinearRegression	—	sin búsqueda ({})

3.4 Transformación de variable objetivo

Con el objetivo de optimizar el desempeño de los modelos previamente mencionados se implementó a su vez un análisis comparativo utilizando diferentes transformaciones matemáticas sobre la variable objetivo, bopd. El enfoque incluyó evaluar la predicción a través de las siguientes transformaciones:

1. Original
2. Transformación logarítmica, *log1p*, efectiva para estabilizar la varianza y atenuar el impacto de grandes valores extremos, $y' = \log(1+y)$.
3. Transformación por raíz cuadrada, *sqrt*, suavizar la dispersión de los datos, menos agresiva que el logaritmo, $y' = \sqrt{y}$.
4. Transformación al cuadrado, *square*, amplificar la sensibilidad del modelo hacia los valores elevados, $y' = y^2$.
5. Transformación al cubo, *cube*, amplificar la sensibilidad del modelo hacia los valores elevados, $y' = y^3$.
6. Transformación inversa o recíproca, *reciprocal*, mejora desempeño en casos donde la relación entre variables independientes y objetivo es inversamente proporcional, $y' = 1/y$.

3.5 Flujograma y desarrollo de modelos


A continuación, se describe el flujo de proceso desarrollado e implementado en código:

1. *Carga y normalización del dataset*: Se implementó un lector que evalúa el tipo de separadores y formatos decimales, y reporte de calidad de datos como faltantes o duplicados.
2. *Exploración descriptiva y diagnóstico del objetivo*: Se genera análisis descriptivo para las variables numéricas y categóricas, se grafica la distribución y *boxplot* de la variable objetivo, con el objetivo de evaluar posibles transformaciones requeridas.
3. *Correlación y selección de variables input de modelo*: Se calcula matrices Pearson, Spearman y de asociación mixta con categóricas usando *dython* para priorizar predictores con mayor relación con “*bopd*”.
4. *Partición del dataset*: Se divide en 80% entrenamiento y 20% prueba, manteniendo la evaluación final fuera de la validación cruzada.
5. *Pipelines de preprocesamiento*: Se configuraron dos flujos, i) escalamiento incluyendo imputación + *StandardScaler* + *One-Hot* para modelos sensibles a escala, como lo son para este trabajo SVM, MLP, *LinearRegression*, ii) no escalamiento incorporando solo imputación + *One-Hot* para *RandomForest* y *XGBoost*.
6. *Modelos candidatos*: Se inicializan y configuran los modelos *LinearRegression*, *RandomForest*, *XGBoost*, *SVM* y *MLP*.
7. *Búsqueda de hiperparametros*: Se generaron códigos diferentes para aplicar tanto *RandomSearchCV* y *BayesSearchCV*, buscando evaluar posibles mejoras tanto en métricas como en tiempos de cómputo. En ambos casos, la evaluación interna se efectuó por *CV*.
8. *Transformaciones del objetivo y métricas robustas*: Se transforma la variable objetivo “*bopd*” en escalas, - log1p, sqrt, square, cube, recíproca -, al finalizar se invierte para reportar en escala original. Para robustecer frente a asimetrías y *outliers* se emplearon *MedAE* (mediana del error absoluto) y *Huber* como funciones de *scoring* en las fases de búsqueda/optimización.
9. *Evaluación externa y re-ranking final*: sobre el consolidado de resultados aplicados con la partición de prueba se calcularon las métricas MAE, RMSE, R^2 y MAPE conforme lo revisado en el estado del arte. Posteriormente, se realiza un re-ranking agregando posiciones por métrica y aplicando penalización a resultados con $R^2 < 0$.
10. *Extracción de hiperparametros ganadores*: Para cada combinación de transformación y modelo se extrajeron los hiperparametros óptimos y se genera un nuevo espacio de búsqueda de hiperparametros buscando mejorar métricas de error.
11. *Iteración de proceso y reajuste de espacio de hiperparametros optimizado*: Los pasos 7 a

9 son repetidos nuevamente con el objetivo de buscar reducción en tiempos de cómputo como un mejor resultado en métricas al acotar el espacio de búsqueda de hiperparametros.

- *Espacio Optimizado global*
- *Espacio optimizado por par algoritmo-transformación*

Figura 15: Flujograma metodología experimental de predicción de producción empleando algoritmos de machine learning para cada campo



4 RESULTADOS

4.1 Resultados Campo 1

4.1.1 RandomSearch + MedAE

Para la primera fase de optimización los modelos tuvieron un recorte en sus espacios sin embargo RandomForest no sufrió mayores cambios, sin embargo para la segunda fase se realizó un ajuste individualizado por par de transformación y modelo teniendo como base los resultados de la fase de búsqueda, ver Tabla 30 y Tabla 31 en Anexos.

A continuación, los resultados comparando la fase de búsqueda, la fase de optimización 1 y la fase de optimización 2, en sombreado verde los mejores resultados de cada métrica:

Tabla 15: Mejores resultados fases búsqueda + Optimización RandomSearch + MedAE campo 1

#	Fase	Transformación	Algoritmo	RMSE	MAE	R2	MAPE	Rank_Final
1	Búsqueda	reciprocal	MLP	13,344	9,045	0,374	38,023	8
2	Optimizado 2	sqrt	XGBoost	13,315	9,287	0,377	43,113	18
3	Búsqueda	log1p	XGBoost	13,982	9,312	0,313	38,738	19
4	Optimizado 2	log1p	RandomForest	14,606	9,108	0,250	41,468	22
5	Optimizado 2	log1p	XGBoost	14,450	9,173	0,266	42,047	24
6	Búsqueda	log1p	RandomForest	14,861	9,138	0,224	41,387	26
7	Búsqueda	sqrt	XGBoost	13,540	9,557	0,356	43,924	31
8	Optimizado	log1p	RandomForest	14,886	9,156	0,221	42,200	32
9	Optimizado	log1p	XGBoost	14,616	9,329	0,249	42,422	33
10	Optimizado	sqrt	XGBoost	14,413	9,711	0,270	44,704	42
11	Optimizado 2	reciprocal	RandomForest	16,476	9,481	0,046	36,550	44
12	Optimizado	log1p	SVM	15,818	9,467	0,120	43,270	45
13	Búsqueda	reciprocal	RandomForest	16,542	9,525	0,038	36,888	50
14	Optimizado 2	sqrt	SVM	16,247	9,446	0,072	44,829	51
15	Optimizado	sqrt	RandomForest	15,321	9,634	0,175	48,934	57
16	Búsqueda	original	SVM	16,413	9,558	0,053	44,732	59
17	Optimizado 2	log1p	SVM	16,258	9,616	0,071	45,568	61
18	Optimizado	square	SVM	16,535	9,566	0,039	44,647	62

- La fase de Búsqueda que contemplo un espacio amplio identificó el mejor caso global del ranking recalculado, lo que sugiere que la exploración extensa fue determinante para capturar regiones del espacio de hiperparametros con mejor desempeño.
- El Optimizado 1 el cual es el espacio recortado general, aplicado por igual a todas las transformaciones y modelos, fue poco efectivo ya que no superó al mejor caso de Búsqueda y, en general, mostró un beneficio limitado. Esto indica que un recorte “único” no representa adecuadamente la heterogeneidad de óptimos entre modelos y transformaciones.

- El Optimizado 2 correspondiente a la fase de donde el espacio fue recortado para cada par transformación–modelo fue el enfoque de optimización más adecuado: aunque no alcanzó el puesto #1, sí logró insertar configuraciones adicionales dentro del Top-5, evidenciando que la especialización del espacio mejora la capacidad de encontrar soluciones competitivas con menor costo de cómputo.
- En términos metodológicos, los resultados apoyan que la estrategia recomendada la cual corresponde a un recorte condicionado por modelo-transformación y no un recorte global, ya que los hiperparámetros óptimos dependen del tipo de modelo y de la transformación aplicada al objetivo.
- La transformación “reciprocal” produjo el mejor desempeño global, lo que sugiere que es particularmente efectiva para este objetivo altamente disperso, probablemente por su efecto de compresión no lineal sobre valores extremos.
- La transformación “log1p” fue la más frecuente en el ranking, mostrando estabilidad transversal a varios modelos, sugiriendo que es una base robusta y que, con una optimización aún más focalizada, podría acercarse o superar el mejor caso global.
- La regresión lineal no ingresó al Top por transformación ni al ranking global, lo que refuerza que el fenómeno subyacente requiere modelos con capacidad no lineal (XGBoost/RandomForest/MLP) para capturar patrones bajo alta dispersión y presencia de outliers.
- A nivel de eficiencia, el recorte del espacio redujo el tiempo de ejecución, la fase de búsqueda requirió 1h 45m 21s, Optimizado 1 presento 53m 43s y Optimizado 2 con 55m 11s, estos 3 valores muestran que la reducción de cómputo solo es “rentable” si el recorte se diseña de forma específica por par transformación–modelo; de lo contrario, puede inducir pérdida de desempeño por sub-exploración.

4.1.2 RandomSearch + Huber

Para la primera fase de optimización todos los modelos tuvieron un recorte en sus espacios sin embargo RandomForest fue el que se le ejecutaron menores cambios, sin embargo para la segunda fase se realizó un ajuste individualizado por par de transformación y modelo teniendo como base los resultados de la fase de búsqueda, ver Tabla 32 y Tabla 33 en Anexos. A continuación, los resultados comparando la fase de búsqueda y ambas fases de optimización, en

sombreado verde los mejores resultados de cada métrica:

Tabla 16: Mejores resultados fases búsqueda + Optimización 1 y 2 RandomSearch + Huber campo 1

#	Fase	Transformación	Algoritmo	RMSE	MAE	R ²	MAPE	Rank_Final
1	Búsqueda	reciprocal	XGBoost	13,227	9,119	0,385	37,001	13
2	Optimizado 2	reciprocal	XGBoost	14,084	9,062	0,303	36,157	17
3	Optimizado 2	log1p	XGBoost	13,496	9,093	0,360	42,116	18
4	Optimizado	log1p	XGBoost	13,711	9,108	0,339	41,658	20
5	Optimizado	reciprocal	XGBoost	14,229	9,034	0,288	36,413	21
6	Optimizado	sqrt	RandomForest	13,976	8,999	0,313	45,037	26
7	Optimizado	log1p	RandomForest	14,435	9,070	0,268	41,666	31
8	Búsqueda	log1p	RandomForest	14,702	9,009	0,240	40,971	32
9	Optimizado 2	log1p	RandomForest	14,438	9,124	0,267	41,877	38
10	Búsqueda	sqrt	XGBoost	13,688	9,515	0,341	47,071	40
11	Búsqueda	log1p	XGBoost	14,370	9,471	0,274	44,750	48
12	Optimizado 2	sqrt	XGBoost	14,209	9,863	0,290	49,489	50
13	Búsqueda	sqrt	RandomForest	14,500	9,266	0,261	46,338	51
14	Optimizado 2	sqrt	SVM	15,018	9,295	0,207	43,183	51
15	Búsqueda	sqrt	SVM	15,283	9,251	0,179	42,699	53
16	Optimizado 2	log1p	SVM	15,260	9,335	0,181	43,321	58
17	Optimizado	sqrt	SVM	15,269	9,313	0,180	43,261	58
18	Optimizado	original	SVM	15,621	9,306	0,142	43,091	59

- Las optimizaciones fueron globalmente exitosas, pero no desplazaron el óptimo absoluto identificado en la primera búsqueda amplia, el caso #1 del ranking continúa siendo la combinación de Búsqueda + reciprocal + XGBoost que presento el mejor RMSE y R², lo que indica que el espacio amplio permitió localizar una región del espacio de hiperparametros que las fases recortadas no superaron.
- Aun así, la optimización sí mejoró la densidad de soluciones competitivas al ingresar 4 configuraciones optimizadas en el Top-5 del ranking, posiciones #2 a #5. Esto evidencia que, aunque no se alcanzó un nuevo máximo global, el recorte de espacios produjo más modelos cercanos a la zona optima.
- La fase Optimizada 1 el cual consistió en un recorte general mostro mejoras parciales pero con penalización en ajuste (R²), se observaron configuraciones con MAE menor e incluso RMSE comparables, pero el R² tiende a caer, lo que es consistente con una optimización

que reduce error absoluto promedio a costa de explicar menos varianza, explicable en datos con variables objetivos altamente dispersos y con outliers.

- La fase Optimizado 2 que consiste en un recorte específico por par transformación–modelo es el enfoque más consistente y eficiente, ya que logra ingresar mejores posiciones relativas, #2 y #3 del ranking, además, mantiene competitividad en las métricas de error con un menor costo computacional.
- La transformación “reciprocal” domina el mejor desempeño global, liderando el ranking final y mostrando los mejores valores de RMSE– R^2 . Esto sugiere que reciprocal es altamente efectiva para conjuntos de datos con objetivos con colas largas, al introducir una compresión no lineal que reduce la influencia de valores extremos sobre el criterio de ajuste.
- La transformación “log1p” es la transformación más frecuente en los mejores resultados, apareciendo repetidamente en el ranking final con XGBoost y RandomForest. Dado su desempeño consistente, es razonable concluir que log1p es una transformación estable y que podría mejorar aún más si se profundiza la optimización específica por par.
- Los mejores valores por métrica se reparten entre fases, confirmando una variación entre el objetivo de cada fase:
 - El mejor RMSE y R^2 se mantienen en el caso de Búsqueda, reciprocal + XGBoost.
 - El mejor MAPE aparece en Optimizado 2, reciprocal + XGBoost, lo que sugiere que el recorte específico favorece desempeño relativo en porcentaje, aunque no maximice R^2 .
 - El MAE mínimo aparece en un caso optimizado, sqrt + RandomForest, reforzando que la optimización puede reducir error absoluto aunque el ranking global castigue por R^2 .
- La transformación “cube” no aparece entre los mejores resultados mostrando un bajo desempeño general, esto se debe a que para valores bajos, elevar al cubo puede deteriorar estabilidad y separabilidad, amplificando problemas de ajuste bajo y alta dispersión.
- La regresión lineal no ingresa al Top por transformación ni al ranking global, lo que respalda que el fenómeno requiere capacidad no lineal para capturar interacciones y heterogeneidad inducida por outliers.
- En cuanto mejoras de eficiencia de cómputo el recorte específico de la fase Optimizado 2 ofrece el mejor balance costo–beneficio, el tiempo de Optimizado 1 vs Búsqueda muestra una reducción marginal, ~1h44m vs ~1h46m, mientras que Optimizado 2 reduce el tiempo a ~52m, cercano a una disminución del 50%, y simultáneamente incorpora configuraciones en el Top-3. Esto respalda que la reducción de espacio es efectiva solo

cuando es condicionada por transformación, modelo y no cuando se aplica como regla general.

4.1.3 BayesSearch + MedAE

Para la primera fase de optimización todos los modelos tuvieron un recorte en sus espacios sin embargo MLP y RandomForest fueron los que tuvieron menores modificaciones, mientras que para la segunda fase si hubo ajuste para cada par transformación-Modelo, ver Tabla 34 y Tabla 35 en Anexos. A continuación, los resultados comparando la fase de búsqueda y ambas fases de optimización, en sombreado verde los mejores resultados de cada métrica:

Tabla 17: Mejores resultados fases búsqueda + Optimización BayesSearch + MedAE campo 1

#	Fase	Transformación	Algoritmo	RMSE	MAE	R ²	MAPE	Rank_Final
1	Optimizado 2	sqrt	XGBoost	13,079	9,193	0,399	42,982	20
2	Optimizado 2	log1p	RandomForest	14,417	9,043	0,269	41,283	20
3	Optimizado	log1p	RandomForest	14,446	9,015	0,266	40,502	20
4	Optimizado	log1p	XGBoost	14,300	9,187	0,281	42,158	22
5	Búsqueda	sqrt	XGBoost	13,209	9,320	0,387	43,529	26
6	Búsqueda	log1p	RandomForest	14,437	9,048	0,267	41,299	26
7	Optimizado 2	log1p	XGBoost	14,421	9,206	0,269	42,348	30
8	Optimizado 2	log1p	SVM	16,132	9,034	0,085	40,921	35
9	Búsqueda	log1p	XGBoost	14,529	9,268	0,258	42,326	36
10	Optimizado	sqrt	XGBoost	14,063	9,800	0,305	45,084	37
11	Búsqueda	log1p	SVM	16,132	9,037	0,085	40,838	37
12	Optimizado	reciprocal	SVM	15,751	9,543	0,128	38,230	38
13	Búsqueda	reciprocal	XGBoost	16,267	9,394	0,070	37,552	44
14	Optimizado	log1p	SVM	15,905	9,514	0,111	43,847	50
15	Optimizado 2	sqrt	RandomForest	15,188	9,653	0,189	49,661	51
16	Optimizado 2	sqrt	SVM	15,925	9,449	0,109	44,781	52

- La fase de optimización puede considerarse exitosa al recalcular el ranking global sobre el conjunto unificado, se observa un empate técnico en el primer lugar entre tres configuraciones, dos de las cuales corresponden a fases optimizadas, Optimizado 2: sqrt + XGBoost y log1p+RandomForest; Optimizado 1: log1p+RandomForest. Esto confirma que el recorte de espacios no solo mejoró resultados puntuales, sino que logró llevar soluciones optimizadas al frente del ranking.
- En este caso de un empate múltiple La selección del modelo más adecuado depende del objetivo operativo:

- $\log_{1p}$ + RandomForest del Optimizado 2 presenta un balance multi-métrica favorable al combinar un MAE bajo, MAPE competitivo y un R^2 intermedio con RMSE moderado, deseable con outliers donde se prioriza estabilidad y robustez.
- $\sqrt{x}$ + XGBoost del Optimizado 2 maximiza R^2 y minimiza RMSE dentro del ranking, preferible para explicar varianza y reducir error cuadrático, aun cuando MAE/MAPE no son los mejores.
- La transformación “ $\log_{1p}$ ” es la dominante en términos de consistencia, al concentrar la mayor cantidad de apariciones en el ranking, 6 de 16 configuraciones, y ocupar posiciones altas con distintos modelos, RandomForest, XGBoost y SVM. Lo cual sugiere que ofrece una varianza estable y favorece la generalización en presencia de alta dispersión.
- La transformación “ $\sqrt{x}$ ” muestra alto potencial cuando se combina con modelos de boosting, ya que $\sqrt{x}$ + XGBoost alcanza el mejor desempeño en RMSE y R^2 , explicable ya que esta reduce asimetría sin comprimir tan agresivamente como “ $\log_{1p}$ ”, preservando una variación útil para que XGBoost explote relaciones no lineales.
- La transformación “reciprocal” no lidera el ranking en este experimento unificado, pero sigue siendo relevante ya que aparece como alternativa en la parte media-baja del ranking, sugiriendo que depende del modelo y del rango efectivo de la variable objetivo. En términos de diseño experimental, esta transformación podría requerir espacios de búsqueda aún más específicos u otros procesos de optimización.
- La transformación “cube” no ingresa a ningún ranking relevante, esto se explica debido a que esta tiende a amplificar extremos y a degradar estabilidad con valores bajos, lo que perjudica la capacidad de ajuste.
- Los modelos lineales y MLP no son competitivos en este escenario, esperado debido a la alta dispersión/no linealidad del conjunto de datos, donde por el contrario los modelos como XGBoost y RandomForest tienden a capturar mejor interacciones y heterogeneidad inducida por outliers.
- Se observa una mejora en eficiencia computacional marginal pero estable, los tiempos resultantes de Búsqueda de 1h 59m 15seg, Optimizado 1 de 1h 56m 31seg y Optimizado 2 de 1h 58m 27seg, muestran una reducción ligera. No obstante, lo relevante es que la optimización logró mejores posiciones en el ranking con tiempos comparables, lo que sugiere una mejora en eficiencia por unidad de cómputo más que una reducción drástica de tiempos de ejecución.

4.1.4 BayesSearch + Huber

Para ambas fases de optimización todos los modelos tuvieron un recorte en sus espacios, mientras que para la segunda fase si hubo ajuste para cada par transformación-Modelo, Tabla

36y Tabla 37 ver anexos. A continuación, los resultados comparando la fase de búsqueda y ambas fases de optimización, en sombreado verde los mejores resultados de cada métrica.

Tabla 18: Mejores resultados fases búsqueda + Optimización 1 y 2 de BayesSearch + Huber campo 1

#	Fase	Transformación	Algoritmo	RMSE	MAE	R ²	MAPE	Rank_Final
1	Búsqueda	log1p	XGBoost	13,738	9,051	0,337	40,991	11
2	Optimizado	log1p	RandomForest	14,023	9,167	0,309	41,802	18
3	Optimizado 2	log1p	RandomForest	14,028	9,165	0,308	41,821	20
4	Optimizado 2	log1p	XGBoost	13,622	9,274	0,348	42,835	20
5	Búsqueda	log1p	RandomForest	14,258	9,143	0,285	41,534	22
6	Optimizado	log1p	XGBoost	13,629	9,331	0,347	44,421	28
7	Búsqueda	reciprocal	XGBoost	14,147	9,695	0,296	39,093	31
8	Optimizado 2	original	SVM	15,254	9,208	0,182	42,778	39
9	Optimizado 2	sqrt	SVM	15,180	9,250	0,190	42,953	40
10	Optimizado 2	sqrt	RandomForest	14,258	9,298	0,285	46,835	40
11	Búsqueda	original	SVM	15,325	9,230	0,174	42,828	43
12	Optimizado 2	log1p	MLP	15,089	9,293	0,200	44,777	43
13	Optimizado	reciprocal	RandomForest	15,428	9,397	0,163	35,951	45
14	Búsqueda	reciprocal	RandomForest	15,625	9,366	0,142	36,021	46
15	Optimizado	log1p	SVM	15,198	9,371	0,188	43,148	49
16	Optimizado	sqrt	RandomForest	14,872	9,692	0,223	48,670	49

- La optimización fue parcialmente exitosa, aun cuando primer caso de ranking final continúa siendo un candidato de la fase de búsqueda, log1p + XGBoost, indicando que un espacio amplio permite encontrar el mejor óptimo global. Sin embargo, la optimización incorporó tres configuraciones optimizadas dentro del Top-5, evidenciando que el recorte de espacios mejoró la concentración de candidatos competitivos y redujo la dispersión del desempeño.
- La elección del modelo optimo depende del criterio operativo ya que si se prioriza el mejor balance global entre métricas, el candidato log1p + XGBoost de la fase de Búsqueda es el referente por su combinación de RMSE bajo, R² alto y MAE mínimo dentro de los primeros lugares.
- La transformación log1p dominó el ranking apareciendo en 10 de 16 configuraciones y ocupa las primeras seis posiciones, gracias a que estabiliza la escala del objetivo y mejora la relación señal-ruido bajo alta dispersión, favoreciendo el ajuste tanto en modelos de ensamble como de boosting.

- Los modelos XGBoost y RandomForest concentran la mayoría de los mejores resultados dentro del Top-10, estos dos modelos representan 11/16 del total de configuraciones, confirmando su consistencia para capturar relaciones no lineales e interacciones bajo alta heterogeneidad para este conjunto de datos y variable objetivo. Aunque SVM aparece, este modelo logró posiciones inferiores, reflejando menor competitividad global bajo el criterio multi-métrica.
- La transformación “cube” no aparece en el ranking, lo que indica desempeño por debajo de lo óptimo, posiblemente por su efecto de amplificación de extremos, deteriorando la calidad del ajuste en escenarios con outliers pronunciados.
- Las demás transformaciones alternativas, “reciprocal”, “sqrt”, “original” se comportan como soluciones que logran buenos resultados pero no dominan el ranking. En cuanto a “reciprocal” y “sqrt” estas aparecen principalmente en posiciones medias-bajas, sugiriendo que su beneficio puede ser más dependiente del modelo o el objetivo ya sea de mejorar predicción en colas u otro, requiriendo optimizaciones adicionales.
- Las fases de optimización reducen tiempos con mejoras en calidad promedio, los tiempos reportados muestran que la fase de Optimización 2 de ~1h 33m y Optimización 1 de ~1h 38m son más eficientes que la Búsqueda que obtuvo ~1h 44m, manteniendo o mejorando múltiples métricas en varios candidatos. Esto sugiere una mejora en calidad por unidad de cómputo, aunque el óptimo del ranking permanezca en la fase de búsqueda.

4.1.5 Análisis de resultados Global fases de búsqueda y optimización

A continuación, los 10 mejores casos obtenidos entre los mejores casos de las diferentes configuración y fases, adicionalmente los 2 casos que obtuvieron mejores métricas de MAE y MAPE.

Tabla 19: Mejores resultados globales fases Búsqueda + Optimización campo 1

#	Configuración	Fase	Transformación	Algoritmo	RMSE	MAE	R ²	MAPE	Final Rank	R2 Train
1	RandomSearch+Medae	Búsqueda	reciprocal	MLP	13,344	9,045	0,374	38,023	27	0,771
2	RandomSearch+Huber	Búsqueda	reciprocal	XGBoost	13,227	9,119	0,385	37,001	29	0,377
3	RandomSearch+Huber	Optimizado	reciprocal	XGBoost	14,229	9,034	0,288	36,413	50	0,141
4	RandomSearch+Huber	Optimizado 2	reciprocal	XGBoost	14,084	9,062	0,303	36,157	50	0,632
5	BayesSearch+Huber	Búsqueda	log1p	XGBoost	13,738	9,051	0,337	40,991	51	0,796
6	RandomSearch+Huber	Optimizado 2	log1p	XGBoost	13,496	9,093	0,360	42,116	54	0,697
7	RandomSearch+Huber	Optimizado	log1p	XGBoost	13,711	9,108	0,339	41,658	59	0,793
8	BayesSearch+Medae	Optimizado 2	sqrt	XGBoost	13,079	9,193	0,399	42,982	67	0,998
9	BayesSearch+Huber	Optimizado	log1p	RandomForest	14,023	9,167	0,309	41,802	77	0,615
10	RandomSearch+Medae	Búsqueda	log1p	XGBoost	13,982	9,312	0,313	38,738	77	0,951


16	RandomSearch+Huber	Optimizado	sqrt	RandomForest	13,976	8,999	0,313	45,037	85	0,662
47	BayesSearch+Huber	Optimizado	reciprocal	RandomForest	16,0527	9,369	0,094	35,730	155	0,316

- EL método XGBoost se confirma como el algoritmo más consistente para el campo 1, en el Top-10 del consolidado concentra 8 de los mejores casos del ranking, lo que evidencia estabilidad ante cambios en función de pérdida (MedAE vs Huber), método de búsqueda (Random vs Bayes) y transformación del objetivo.
- Las transformaciones “log1p” y “reciprocal” domina el desempeño global con 5 y 4 en el Top-10 respectivamente, indicando y confirmando una variable objetivo asimétrica y con colas pesadas donde “log1p” estabiliza varianza y reduce sensibilidad al extremo, favoreciendo consistencia en múltiples modelos, mientras que “reciprocal” comprime fuertemente los extremos y tiende a favorecer MAPE (error relativo), lo cual es particularmente útil cuando se penaliza el error porcentual en escenarios de outliers altos.
- El caso “reciprocal” ilustra el balance que debe ser tenido en cuenta en cuanto a la compresión de extremos, en la tabla de ranking final esta transformación logra algunos de los MAPE más bajos, y con XGBoost mantiene un R^2 competitivo en las primeras 2 posiciones. Lo cual sugiere que la compresión de extremos permite que un modelo no lineal basado en árboles capture mejor la señal relevante sin ser dominado por puntos extremos. No obstante, se observa que la compresión excesiva puede reducir el ajuste explicativo (R^2) si se prioriza únicamente MAPE, por lo que el criterio multi-métrica es necesario.
- La inclusión de la métrica R^2 Train revela comportamientos de generalización, se observan casos de posible sobreajuste, especialmente en la transformación “sqrt” del caso #8, que obtiene el mejor R^2 de prueba (0,399) y RMSE (13.079), pero a costa de un R^2 Train casi perfecto de 0,998 lo que sugiere que el modelo memorizó el set de entrenamiento. El caso #1 basado en algoritmo MLP también muestra una brecha relativamente alta con un R^2 de entrenamiento de 0,771 versus de la fase de prueba de 0,374.
- En contraste, la configuración #2 correspondiente a XGBoost + Reciprocal + Huber destaca por su generalización, con un R^2 de entrenamiento de 0,377 muy cercano al R^2 de la fase de prueba con 0,385 indicando un modelo que no está sobre ajustado y es confiable para datos nuevos.
- Los mejores candidatos se ubican típicamente en $R^2 \sim 0,288-0,399$, lo cual se puede considerar como un ajuste moderado ya que explica una fracción útil de variabilidad, pero deja margen atribuible a ruido, variables omitidas o estructura no lineal adicional no manejada en este estudio.
- Aunque MedAE produjo el Top del ranking, los casos donde se usó Huber tienen una mayor presencia en el Top-10 con 7 posiciones, lo que sugiere que Huber o Pérdida

Robusta mejora la estabilidad global frente a outliers sin depender tanto de una configuración específica.

- La selección más prudente para implementación es el caso #2: XGBoost + Reciprocal + Huber. Aunque es el segundo en la lista visual, es técnicamente superior en estabilidad debido a la ausencia de brecha de generalización, R^2 entrenamiento de 0,377 vs Prueba 0,385 ofreciendo un R^2 alto y un MAPE competitivo sin el riesgo de sobreajuste que presentan el caso #8 o el #10.
- El caso #1 correspondiente a MLP + Reciprocal + MedAE sigue siendo una alternativa válida si se prioriza puramente el ranking de error absoluto, pero debe considerarse con cautela debido a que su R^2 de entrenamiento de 0,771 duplica su desempeño en prueba, señalando una memorización parcial de los datos.

Figura 16: Grafico de dispersión predicción vs real, tres mejores casos Campo 1



4.2 Resultados Campo 2

4.2.1 RandomSearch + MedAE

Para ambas fases de optimización todos los modelos tuvieron un recorte en sus espacios, mientras que para la segunda fase si hubo ajuste para cada par transformación-Modelo, ver Tabla 38 y Tabla 39 ver anexos. A continuación, los resultados comparando la fase de búsqueda y ambas

fases de optimización, en sombreado verde los mejores resultados de cada métrica:

Tabla 20: Mejores resultados fases búsqueda + Optimización 1 y 2, RandomSearch + MedAE campo 2

#	Fase	Transformación	Modelo	RMSE	MAE	R ²	MAPE	Final Rank
1	Optimizado 2	log1p	RandomForest	57,633	45,147	0,315	98,877	8
2	Optimizado	log1p	RandomForest	57,995	45,706	0,307	100,543	14
3	Optimizado 2	sqrt	RandomForest	57,696	46,305	0,314	118,722	22
4	Búsqueda	log1p	RandomForest	59,182	46,210	0,278	102,304	23
5	Optimizado	log1p	XGBoost	59,524	47,561	0,270	89,739	23
6	Optimizado	sqrt	RandomForest	58,172	46,853	0,303	121,217	28
7	Optimizado	reciprocal	XGBoost	60,726	48,979	0,240	88,833	28
8	Búsqueda	sqrt	RandomForest	58,373	46,986	0,298	121,317	32
9	Búsqueda	sqrt	MLP	62,905	47,836	0,184	93,195	43
10	Optimizado 2	log1p	XGBoost	62,454	49,528	0,196	101,966	44
11	Optimizado 2	sqrt	XGBoost	61,007	49,190	0,233	117,620	46
12	Búsqueda	reciprocal	MLP	64,785	48,829	0,135	98,451	50
13	Optimizado 2	log1p	LinearRegression	62,534	50,106	0,194	105,639	51
14	Búsqueda	log1p	LinearRegression	62,534	50,106	0,194	105,639	52
15	Optimizado	log1p	LinearRegression	62,534	50,106	0,194	105,639	52
16	Optimizado 2	sqrt	LinearRegression	60,814	50,393	0,238	125,462	53
17	Optimizado	sqrt	XGBoost	63,981	48,421	0,156	114,493	55
18	Búsqueda	sqrt	LinearRegression	61,084	50,393	0,238	125,462	56

- El mejor candidato global en el re-ranking corresponde a Optimizado 2, log1p + RandomForest, lo que valida que recortar el espacio obtuvo mejora en resultados, nuevamente respaldado por la incorporación del optimizado 1 también en el Top-5, demostrando que la estrategia más efectiva es generar recorte ya sea uniforme o por pares.
- El algoritmo RandomForest domina los primeros puestos por demostrando una mayor robustez entre las métricas de error, concentrado junto a las transformaciones “log1p” y “sqrt”, mostrando un equilibrio consistente entre RMSE, MAE y R², a costa de un MAPE menos favorable.
- La transformación “log1p” es predominante y estructuralmente más estable al aparecer repetidamente en los mejores lugares del ranking fusionado y produce el mejor desempeño global al combinarse con RandomForest. La dominancia de “log1p” sugiere que la variable objetivo presenta asimetría y colas pesadas, y que la estabilización de escala mejora el ajuste general al reducir el peso relativo de los extremos.

- Las transformaciones “sqrt” y “reciprocal” son posibles alternativas plausibles, la primera ofrece un compromiso favorable en RMSE y R^2 ; no obstante, tiende a sostener MAPE alto, consistente con una compresión menos agresiva de extremos; mientras que “reciprocal”, optimiza el error relativo (MAPE), pero sacrifica R^2 reflejando que, aunque mejora el desempeño relativo en magnitudes extremas, puede perder capacidad de explicar variabilidad global del objetivo bajo el criterio multi-métrica.
- Los resultados del ranking son consistentes con el recorte de hiperparámetros observado, al reducir rangos hacia zonas plausibles se generó un desplazamiento hacia regiones de mejor desempeño dentro del espacio paramétrico.
- Los modelos lineales muestran competitividad limitada en este contexto quedando sistemáticamente por debajo de los modelos de ensamble y boosting, mientras que el SVM no aparece entre los mejores, lo cual sugiere que, bajo el set actual de variables y transformaciones, su capacidad competitiva es menor o requeriría un ajuste más especializado.
- El modelo recomendado por un balance global fue, log1p + RandomForest de ambas fases de optimización, por consistencia conjunta en RMSE, MAE y R^2 , con MAPE aceptable. Mientras que una alternativa si se prioriza MAPE es el modelo recíprocal + XGBoost, dado su mejor desempeño relativo frente a extremos o penalizaciones altas por MAPE.
- Los tiempos obtenidos para cada fase fueron 1hr 44m 37seg de la fase de búsqueda, 1h 38m 12.61seg obtenido para el caso optimizado 1 y un tiempo de 48m 5seg para el optimizado 2, este último mantiene e incluso mejora las métricas de error, respaldando el uso de recortes más específicos.

4.2.2 RandomSearch + Huber

Para ambas fases de optimización todos los modelos tuvieron un recorte en sus espacios, mientras que para la segunda fase si hubo ajuste para cada par transformación-Modelo, ver Tabla 40 y Tabla 41 en Anexos.

A continuación, los resultados comparando la fase de búsqueda y las fases de optimización, en sombreado verde los mejores resultados de cada métrica:

Tabla 21: Mejores resultados fases Búsqueda + Optimización RandomSearch + Huber campo 2

#	Fase	Transformación	Algoritmo	RMSE	MAE	R^2	MAPE	Final_Rank
1	Optimizado	log1p	XGBoost	52,839	43,849	0,425	101,284	11
2	Optimizado 2	log1p	XGBoost	55,539	45,448	0,364	99,149	16

3	Optimizado	log1p	RandomForest	56,681	44,336	0,338	99,477	17
4	Búsqueda	log1p	RandomForest	57,171	44,888	0,326	100,537	22
5	Búsqueda	log1p	MLP	55,052	45,618	0,375	108,493	23
6	Búsqueda	log1p	XGBoost	56,664	47,235	0,338	98,577	24
7	Optimizado 2	log1p	RandomForest	57,580	45,579	0,317	101,771	31
8	Optimizado 2	reciprocal	XGBoost	59,564	45,741	0,269	68,004	35
9	Optimizado	sqrt	XGBoost	57,340	45,858	0,322	110,763	36
10	Optimizado	reciprocal	SVM	64,946	45,107	0,131	106,773	47
11	Optimizado 2	sqrt	RandomForest	57,828	47,311	0,311	121,975	48
12	Optimizado	reciprocal	XGBoost	65,663	46,736	0,111	94,443	49
13	Búsqueda	reciprocal	XGBoost	62,168	48,499	0,203	78,777	50
14	Búsqueda	sqrt	RandomForest	58,016	47,406	0,306	122,618	52
15	Optimizado	sqrt	RandomForest	58,032	47,275	0,306	123,295	52
16	Optimizado 2	sqrt	XGBoost	58,820	47,757	0,287	120,306	55
17	Optimizado 2	reciprocal	SVM	65,006	46,970	0,129	105,368	55
18	Búsqueda	sqrt	XGBoost	60,733	48,393	0,240	117,836	59

- La fase de optimización fue parcialmente exitosa, el primer lugar global corresponde a un caso optimizado, log1p + XGBoost, y en el Top-5 se encuentran 3 casos de modelos optimizados, ya que se observan 2 entradas provenientes de la fase de búsqueda.
- EL algoritmo XGBoost se consolida como el que presenta la mayor consistencia al concentrar la mayor proporción de apariciones en la tabla final 9 de 18 y ocupa el primer y segundo lugar. Este patrón sugiere que el fenómeno presenta no linealidades e interacciones que los métodos de boosting capturan de forma más efectiva que los modelos lineales.
- La transformación “log1p” domina al aparecer en todos los cinco primeros puestos, indicando que la estabilización de escala es determinante para reducir error y sostener capacidad explicativa. Esto es coherente con un objetivo asimétrico y con colas pesadas, donde “log1p” reduce la influencia de extremos sin perder completamente resolución en rangos medios.
- El máximo desempeño del modelo número 1 del ranking, $R^2 \approx 0.43$ con $RMSE \approx 53$, evidencia capacidad explicativa significativa, pero deja una fracción importante de varianza sin explicar. Este comportamiento puede deberse a un ruido en mediciones, variables omitidas, u otras dependencias no identificadas que requerirían variables adicionales o modelos por segmentos.
- Las transformaciones “sqrt” y “reciprocal” aportan alternativas, pero no superan a “log1p” en el criterio multi-métrica, el liderazgo de “log1p” indica que el problema se beneficia más de una compresión moderada que preserve estructura en rangos medios.

- EL modelo seleccionado de ser operativizado sería el log1p + XGBoost, por su combinación de menor RMSE, MAE competitivo y mayor R^2 observado, lo que lo posiciona como la opción con mejor desempeño global.

4.2.3 BayesSearch + MedAE

Para ambas fases de optimización todos los modelos tuvieron un recorte en sus espacios, con un menor recorte a los casos con el algoritmo MLP, mientras que para la segunda fase si hubo ajuste para cada par transformación-Modelo, ver Tabla 42 y Tabla 43 en Anexos. A continuación, los resultados comparando la fase de búsqueda y las fases de optimización, en sombreado verde los mejores resultados de cada métrica.

Tabla 22: Mejores resultados fases búsqueda + Optimización 1 y 2 BayesSearch + MedAE, campo 2

#	Fase	Transformación	Modelo	RMSE	MAE	R2	MAPE	Final_Rank
1	Optimizado 2	log1p	XGBoost	55,053	45,377	0,375	97,539	7
2	Optimizado 2	log1p	RandomForest	57,964	45,411	0,308	99,885	14
3	Optimizado	log1p	RandomForest	57,995	45,706	0,307	100,543	18
4	Optimizado 2	sqrt	XGBoost	56,095	46,262	0,351	117,917	22
5	Búsqueda	log1p	RandomForest	59,182	46,210	0,278	102,304	28
6	Optimizado	log1p	XGBoost	59,524	47,561	0,270	89,739	29
7	Optimizado 2	sqrt	RandomForest	58,120	46,837	0,304	120,756	30
8	Optimizado	sqrt	RandomForest	58,172	46,853	0,303	121,217	34
9	Optimizado	reciprocal	XGBoost	60,726	48,979	0,240	88,833	34
10	Búsqueda	sqrt	RandomForest	58,373	46,986	0,298	121,317	38
11	Búsqueda	sqrt	MLP	62,905	47,836	0,184	93,195	45
12	Optimizado 2	log1p	LinearRegression	62,534	50,106	0,194	105,639	52
13	Búsqueda	log1p	LinearRegression	62,534	50,106	0,194	105,639	52
14	Optimizado	log1p	LinearRegression	62,534	50,106	0,194	105,639	52
15	Búsqueda	reciprocal	MLP	64,785	48,829	0,135	98,451	53
16	Optimizado 2	sqrt	LinearRegression	60,814	50,393	0,238	125,462	57
17	Optimizado	sqrt	XGBoost	63,981	48,421	0,156	114,493	57
18	Búsqueda	sqrt	LinearRegression	61,084	50,393	0,238	125,462	59

- El mejor resultado global corresponde a XGBoost con transformación log1p de la fase Optimizado 2, con el desempeño balanceado y menor calificación de rankings.
- La optimización fue exitosa en términos de ranking, pero no produce dominancia absoluta del Top-5, aunque el primer lugar es de a fase Optimizado 2, el Top-5 integra soluciones de Optimizado 2, Optimizado y Búsqueda, lo que sugiere que el recorte de espacio sí

concentra candidatos competitivos, pero no excluye la existencia de regiones útiles en el espacio amplio de búsqueda.

- La transformación “log1p” domino la zona superior del ranking ocupo las tres primeras posiciones y 4 del Top-5, explicable por una variable objetivo-asimétrica donde “log1p” estabiliza la escala y reduce el impacto de extremos, favoreciendo RMSE/MAE y manteniendo un R^2 competitivo.
- La transformación “sqrt” se comportó como alternativa secundaria, mostrando configuraciones competitivas sin embargo quedan por detrás de “log1p” en el ranking. El comportamiento de “sqrt” conserva variabilidad útil (R^2 razonable) pero no comprime suficientemente la cola para sostener MAPE bajo.
- El algoritmo XGBoost lidera por consistencia y RandomForest se mantiene competitivo como opción robusta, el primero aparece de primero y recurrentemente en el bloque superior, mientras RandomForest + log1p se mantiene en posiciones altas con métricas estables.
- En contraste, LinearRegression queda concentrado en la parte baja del ranking, confirmando que el problema requiere capturar relaciones no lineales e interacciones que un modelo lineal no modela adecuadamente bajo el set actual de variables.
- La recomendación operativa basada en el balance multi-métrica y priorizando el balance global, se recomienda XGBoost + log1p de la fase Optimizado 2 como modelo base.
- Sin embargo, si se prioriza robustez y estabilidad RandomForest + log1p constituye una alternativa sólida.

4.2.4 BayesSearch + Huber

Para ambas fases de optimización todos los modelos tuvieron un recorte en sus espacios, mientras que para la segunda fase si hubo ajuste para cada par transformación-Modelo, ver Tabla 44 y Tabla 45 en Anexos.

A continuación, los resultados comparando la fase de búsqueda y las fases de optimización, en sombreado verde los mejores resultados de cada métrica:

Tabla 23: Mejores resultados fases Búsqueda, Optimización 1 y 2, BayesSearch + Huber campo 2

#	Fase	Transformación	Modelo	RMSE	MAE	R^2	MAPE	Final_Rank
1	Optimizado 2	log1p	XGBoost	54,931	44,958	0,378	101,142	7
2	Optimizado	log1p	XGBoost	54,772	45,336	0,382	102,792	13
3	Búsqueda	log1p	RandomForest	57,102	45,157	0,328	101,502	15
4	Optimizado 2	sqrt	XGBoost	55,237	44,646	0,371	115,601	17

5	Optimizado 2	log1p	RandomForest	57,108	45,177	0,328	101,552	19
6	Búsqueda	log1p	XGBoost	56,134	45,723	0,351	104,910	21
7	Optimizado	log1p	RandomForest	57,123	45,180	0,327	101,556	23
8	Búsqueda	sqrt	XGBoost	57,432	45,922	0,320	118,227	35
9	Optimizado	sqrt	XGBoost	57,456	46,903	0,320	119,455	39
10	Optimizado	sqrt	RandomForest	57,665	47,416	0,315	122,861	44
11	Optimizado 2	sqrt	RandomForest	57,658	47,419	0,315	122,862	46
12	Optimizado	log1p	LinearRegression	62,534	50,106	0,194	105,639	51
13	Búsqueda	sqrt	RandomForest	57,673	47,428	0,314	122,895	51
14	Búsqueda	log1p	LinearRegression	62,534	50,106	0,194	105,639	55
15	Optimizado 2	log1p	LinearRegression	62,534	50,106	0,194	105,639	59
16	Búsqueda	sqrt	LinearRegression	60,814	50,393	0,238	125,462	60
17	Optimizado 2	sqrt	LinearRegression	60,814	50,393	0,238	125,462	64
18	Optimizado	sqrt	MLP	62,575	49,455	0,193	123,833	65

- La optimización fue parcialmente efectiva, si bien el mejor caso global continúa siendo un candidato de Búsqueda, la incorporación de candidatos en el Top-5 de 3 casos optimizados demuestra que el recorte de espacios aumenta la densidad de candidatos competitivos, pero no garantiza superar el óptimo encontrado en búsqueda amplia.
- El mejor desempeño absoluto corresponde al caso de Búsqueda + log1p + XGBoost, destacándose por el mayor R^2 , menor RMSE y menor MAE del conjunto unificado, además, su MAPE es competitivo frente a los mejores, lo que indica que el modelo no solo mejora ajuste global, sino que mantiene controlado el error porcentual.
- La transformación “log1p” domina consistentemente la zona superior del ranking, ocupa las primeras cinco posiciones, lo que refuerza que fue capaz de estabilizar la escala del objetivo y reducir asimetría/heterocedasticidad, facilitando que modelos basados en árboles capturen relaciones no lineales con mayor eficiencia. En contraste, la transformación “sqrt” aparece como alternativa secundaria, concentrándose en posiciones intermedias y mostrando menores calificaciones multi-métrica.
- Los algoritmos XGBoost y RandomForest son los algoritmos más estables para este problema ya que ambos concentran los primeros lugares junto a la transformación “log1p”, con XGBoost liderando por capacidad de ajuste al presentar mejor R^2 y menor RMSE/MAE y RandomForest manteniéndose como alternativa robusta con desempeño competitivo.
- Los algoritmos lineales y MLP quedan relegados en el ranking fusionado con errores absolutos mayores y menor R^2 , confirmando que la estructura de los datos requiere modelos no lineales y capacidad para capturar interacciones.

- El modelo recomendado fue XGBoost + log1p de la fase de Búsqueda por su mejor balance global, seguido por una alternativa robusta la cual fue RandomForest + log1p de ambas fases de optimización.

4.2.5 Análisis de resultados Global fases de búsqueda y optimización

A continuación, los 10 mejores casos obtenidos entre los mejores casos de las diferentes configuración y fases, 72 en total, adicionalmente el caso que obtuvo el menor MAPE:


Tabla 24: Mejores resultados globales fases Búsqueda + Optimización campo 2

#	Configuración	Fase	Transformación	Algoritmo	RMSE	MAE	R ²	MAPE	Final Rank	R ² Train
1	RandomSearch+Huber	Optimizado	log1p	XGBoost	52,839	43,849	0,425	101,284	26	0,711
2	BayesSearch+Medae	Optimizado 2	log1p	XGBoost	55,053	45,377	0,375	97,539	32	0,651
3	BayesSearch+Huber	Optimizado 2	log1p	XGBoost	54,931	44,958	0,378	101,142	33	0,681
4	RandomSearch+Huber	Optimizado	log1p	RandomForest	56,681	44,336	0,338	99,477	40	0,628
5	RandomSearch+Huber	Optimizado 2	log1p	XGBoost	55,539	45,448	0,364	99,149	44	0,666
6	BayesSearch+Huber	Optimizado	log1p	XGBoost	54,772	45,336	0,382	102,792	46	0,675
7	RandomSearch+Huber	Búsqueda	log1p	RandomForest	57,171	44,888	0,326	100,537	53	0,567
8	BayesSearch+Huber	Búsqueda	log1p	RandomForest	57,187	45,234	0,326	102,182	56	0,567
9	BayesSearch+Huber	Optimizado 2	log1p	RandomForest	57,108	45,177	0,328	101,552	60	0,597
10	RandomSearch+MedAE	Optimizado 2	log1p	RandomForest	57,633	45,147	0,315	98,877	62	0,457
22	RandomSearch+Huber	Optimizado 2	reciprocal	XGBoost	59,564	45,741	0,269	68,004	103	0,551

- Las configuraciones con Huber concentran la mayor parte del Top-10 con 9 posiciones, lo que sugiere una mejora sistemática en el balance conjunto de métricas cuando se emplea como métrica de optimización de hiperparametros una pérdida robusta frente a dispersión y outliers.
- El mejor candidato global del ranking ocupa el primer lugar por combinar MAE mínimo, RMSE mínimo y R² más alto, mientras que el segundo lugar logra un mejor MAPE con las demás métricas menos favorables, reflejando una compensación entre ajuste global (R²/RMSE) y error relativo (MAPE). Se observa una compensación directa en el resto del ranking, donde mejoras en el MAPE suelen implicar sacrificios en el ajuste global.
- La transformación “log1p” fue la transformación estructuralmente más robusta, con un dominio total del Top-10, apareciendo en 10 de 10 casos, validando que con una variable objetivo-asimétrica y con colas pesadas, donde la estabilización de escala mejora la relación señal-ruido y facilita el aprendizaje de modelos basados en árboles.

- El algoritmo XGBoost es consistente y sostienen el rendimiento en el Top-10, confirmando que es requerido algoritmos que capturen no linealidad e interacciones.
- El modelo líder presenta un R^2 de entrenamiento de 0,711 frente a un R^2 de prueba de 0,425 lo que indica una capacidad de aprendizaje sólida pero con una brecha de generalización que debe monitorearse.
- Los modelos de RandomForest en los puestos #7, #8, #9 y #10 muestran mayor estabilidad entre entrenamiento y prueba, con valores de R^2 de entrenamiento más bajos y cercanos entre sí con un rango de 0,457 a 0,597 sugiriendo una menor tendencia al sobreajuste que XGBoost en esta configuración específica.
- La transformación “reciprocal” reduce MAPE de forma marcada, pero penaliza R^2 , el mejor MAPE observado fue muy bajo comparado con el resto del ranking, 68.004, sin embargo, su R^2 cayó a 0,269. Esto sugiere que esta transformación comprime agresivamente los extremos, disminuye error relativo, pero puede deteriorar la explicación de varianza global (R^2), especialmente si el modelo pierde capacidad para diferenciar niveles altos del objetivo.
- Modelos lineales quedaron relegados, a pesar de que aparecieron sistemáticamente en posiciones inferiores del ranking global recalculado confirmando que el problema demanda modelos no lineales y que los enfoques lineales no capturan adecuadamente la estructura del fenómeno.
- El modelo principal recomendado fue XGBoost + log1p con Huber, por su estabilidad y rendimiento global en métricas RMSE/MAE/ R^2 , y una alternativa robusta fue RandomForest + log1p con Huber, si se prioriza operatividad y menor sensibilidad al ajuste de hiperparámetros, al tener variaciones ligeras en sus métricas entre diferentes configuraciones.

Figura 17: Grafico de dispersión predicción vs real, tres mejores casos Campo 2



4.3 Resultados Campo 3

4.3.1 RandomSearch + MedAE

Para ambas fases de optimización todos los modelos tuvieron un recorte en sus espacios, con un menor recorte a los casos con el algoritmo MLP, mientras que para la segunda fase si hubo ajuste para cada par transformación-Modelo, ver Tabla 46 y Tabla 47, ver Anexos. A continuación, los resultados comparando la fase de búsqueda y las fases de optimización, en sombreado verde los mejores resultados de cada métrica:

Tabla 25: Mejores resultados fases Búsqueda + Optimización 1 y 2, RandomSearch + MedAE campo 3

#	Fase	Transformación	Modelo	RMSE	MAE	R2	MAPE	Final_Ran k
1	Optimizado	cube	XGBoost	80,193	58,491	0,458	87,551	17
2	Optimizado 2	square	XGBoost	87,061	60,213	0,361	67,479	21
3	Búsqueda	cube	XGBoost	82,420	59,790	0,427	115,934	23
4	Búsqueda	sqrt	XGBoost	91,108	60,683	0,300	60,512	25
5	Búsqueda	square	XGBoost	85,213	60,434	0,388	84,633	25
6	Optimizado	original	XGBoost	89,229	62,674	0,329	60,771	27
7	Optimizado 2	cube	XGBoost	84,395	61,282	0,400	124,928	30
8	Optimizado 2	original	XGBoost	91,562	61,952	0,293	64,211	32
9	Optimizado 2	log1p	XGBoost	95,912	62,263	0,224	58,163	36
10	Optimizado 2	sqrt	XGBoost	91,963	63,428	0,287	64,066	40

11	Optimizado	square	XGBoost	89,878	64,656	0,319	69,521	40
12	Optimizado	sqrt	XGBoost	96,418	62,637	0,216	59,462	42
13	Optimizado	log1p	XGBoost	99,699	62,817	0,162	53,076	46
14	Búsqueda	original	XGBoost	91,685	66,250	0,291	69,563	49
15	Optimizado 2	original	RandomForest	95,156	64,061	0,237	98,281	53
16	Búsqueda	original	RandomForest	95,960	63,874	0,224	100,129	57
17	Optimizado	sqrt	RandomForest	98,886	64,325	0,176	81,228	59
18	Búsqueda	log1p	SVM	100,689	65,636	0,145	69,340	62

- El algoritmo XGBoost se encuentra en 15 de las 18 posiciones del ranking, mientras que RandomForest se ubica en las tres últimas posiciones. Esto sugiere que, con el conjunto actual de variables y el tamaño/estructura del conjunto de datos, el XGBoost ofrece una relación sesgo–varianza más favorable para capturar no linealidades e interacciones.
- Se tuvo un éxito parcial de la optimización, aunque la fase de Búsqueda aporta configuraciones competitivas, por ejemplo square + XGBoost, la optimización sí logra desplazar el primer lugar hacia un caso optimizado y coloca algunas configuraciones dentro del Top-5, con 2 de ellas. Esto respalda que el recorte de espacio y redefinición del espacio por pares transformación-modelo puede incrementar la probabilidad de hallar candidatos de alto desempeño.
- Las transformaciones “cube” y “square” aparecen de forma recurrente en las primeras posiciones cuando se combinan con XGBoost, lo que sugiere que transformaciones tipo potencia contribuyen a representar mejor la no linealidad del fenómeno. Revisando a detalle, “cube” maximiza el ajuste de R^2 y reduce errores absolutos RMSE/MAE, pero penaliza el error relativo MAPE, mientras que “square” ofrece alternativas con MAPE más controlado y un buen desempeño global.
- En la práctica si se prioriza la explicación de varianza y reducción de RMSE/MAE, el candidato preferente es cube + XGBoost, pero si se busca priorizar control del error relativo (MAPE), los candidatos con mejor métrica dentro del Top-10, pueden ser más adecuados, aun con menor R^2 .
- Una nueva optimización focalizada en cube, square y original por transformación-modelo podría dar resultados con mejoras de ser explorado aún más.
- EL algoritmo RandomForest quedó sistemáticamente rezagado, su exploración debería orientarse a verificar si el problema es de capacidad del modelo o de espacio de búsqueda insuficiente.

4.3.2 RandomSearch + Huber

Para ambas fases de optimización todos los modelos tuvieron un recorte en sus espacios, con un menor recorte a los casos con el algoritmo MLP, mientras que para la segunda fase si hubo ajuste para cada par transformación-Modelo, ver Tabla 48 y Tabla 49 en anexos. A continuación, los resultados comparando la fase de búsqueda y las fases de optimización, en sombreado verde los mejores resultados de cada métrica:

Tabla 26: Mejores resultados fases Búsqueda + Optimización RandomSearch + Huber campo 3

#	Fase	Transformación	Modelo	RMSE	MAE	R ²	MAPE	Final Rank
1	Búsqueda	original	XGBoost	89,504	61,520	0,325	87,945	17
2	Optimizado	sqrt	XGBoost	92,815	61,340	0,274	75,576	21
3	Optimizado	original	XGBoost	90,762	60,909	0,306	96,290	23
4	Optimizado 2	sqrt	XGBoost	94,308	63,073	0,250	74,635	27
5	Optimizado	square	XGBoost	89,458	63,943	0,325	104,405	27
6	Optimizado	log1p	XGBoost	94,969	63,146	0,240	60,168	28
7	Búsqueda	sqrt	XGBoost	93,851	63,931	0,257	74,760	30
8	Optimizado 2	original	XGBoost	92,873	63,551	0,273	91,095	32
9	Búsqueda	log1p	XGBoost	97,453	63,207	0,199	54,995	35
10	Optimizado 2	square	XGBoost	89,758	64,065	0,321	116,434	35
11	Búsqueda	square	XGBoost	89,997	64,573	0,317	114,952	39
12	Optimizado 2	original	RandomForest	95,194	64,382	0,236	96,943	47
13	Optimizado	original	RandomForest	95,360	63,977	0,233	98,232	48
14	Optimizado 2	log1p	XGBoost	99,830	64,618	0,160	56,193	51
15	Búsqueda	original	RandomForest	95,967	64,462	0,224	103,827	54
16	Optimizado	sqrt	RandomForest	98,376	64,802	0,184	81,653	55
17	Búsqueda	log1p	SVM	100,941	64,835	0,141	74,276	57
18	Optimizado 2	sqrt	RandomForest	98,541	64,900	0,181	81,270	58

- El algoritmo XGBoost ocupa las primeras 11 posiciones del re-ranking y concentra las soluciones con mejor desempeño global, confirmando que para el conjunto actual de variables se requiere capacidad para modelar no linealidades e interacciones como los ensambles tipo *gradient boosting*.
- El primer lugar corresponde a la configuración original + XGBoost de la fase de Búsqueda, que combina el mayor R² dentro del conjunto, y el segundo mejor RMSE y mantener el equilibrio en las otras dos métricas MAE y MAPE. En términos del ranking agregado, este caso presenta el mejor compromiso entre error absoluto y calidad de ajuste.
- Las fases de optimización no desplazan al mejor caso de Búsqueda, sin embargo, sí incrementaron la densidad de candidatos fuertes en la parte alta del ranking, en el Top-5

aparecen 4 casos de las fases de optimización, lo que indica que el recorte del espacio de hiperparámetros sí generó soluciones competitivas, aunque no produjo el óptimo global.

- El mejor MAPE se obtiene con log1p + XGBoost de la primera fase de optimización, pero este caso reduce el ajuste en términos de R^2 y no mejora RMSE/MAE frente al líder. Esto evidencia un compromiso entre minimizar error relativo (MAPE) y maximizar ajuste global (R^2) / error absoluto (RMSE, MAE), lo cual es coherente con objetivos altamente dispersos o sensibles a escala.
- Las transformaciones “sqrt” y “square” junto con la escala “original” aparecen de forma reiterada entre los primeros puestos, y son las más efectivas en mejorar el ajuste de R^2 indicando que conservar la escala o aplicar transformaciones tipo potencia que mantengan una relación lineal con los predictores pueden ayudar a XGBoost a alcanzar los techos de desempeño.

4.3.3 BayesSearch + MedAE

Para ambas fases de optimización todos los modelos tuvieron un recorte en sus espacios, mientras que para la segunda fase si hubo ajuste para cada par transformación-Modelo, ver Tabla 50 y Tabla 51 en Anexos. A continuación, los resultados comparando la fase de búsqueda y las fases de optimización, en sombreado verde los mejores resultados de cada métrica:

Tabla 27: Mejores resultados fases Búsqueda + Optimización 1 y 2, BayesSearch + MedAE campo 3

#	Fase	Transformación	Modelo	RMSE	MAE	R^2	MAPE	Final Rank
1	Optimizado	square	RandomForest	85,072	58,227	0,390	97,411	20
2	Optimizado	square	XGBoost	85,651	60,672	0,382	85,369	22
3	Búsqueda	original	XGBoost	90,038	63,482	0,317	59,647	23
4	Optimizado	sqrt	RandomForest	91,652	60,218	0,292	60,760	23
5	Búsqueda	square	XGBoost	85,846	61,057	0,379	81,259	24
6	Optimizado	sqrt	XGBoost	90,196	63,229	0,314	63,507	26
7	Optimizado 2	square	XGBoost	86,314	61,719	0,372	79,387	26
8	Búsqueda	sqrt	XGBoost	90,916	58,637	0,303	70,199	27
9	Optimizado 2	sqrt	XGBoost	91,314	63,267	0,297	67,152	33
10	Optimizado 2	log1p	MLP	95,346	63,274	0,234	61,521	39
11	Optimizado	log1p	XGBoost	96,237	63,021	0,219	61,230	41
12	Optimizado 2	original	XGBoost	92,048	65,993	0,286	65,912	41
13	Búsqueda	log1p	XGBoost	95,424	62,963	0,232	67,348	41
14	Búsqueda	original	RandomForest	94,735	64,032	0,243	94,088	51
15	Optimizado 2	original	RandomForest	95,432	64,027	0,232	96,661	57

16	Optimizado 2	log1p	XGBoost	98,854	66,457	0,176	68,607	58
17	Búsqueda	sqrt	SVM	101,061	67,144	0,139	67,919	60

- El algoritmo XGBoost concentró la gran mayoría de configuraciones competitivas con 11 de 17 en el ranking global, lo que evidencia estabilidad del algoritmo ante distintas transformaciones de la variable objetivo y una mayor capacidad para capturar no linealidades e interacciones de este problema.
- El primer lugar del re-ranking multi-métrica corresponde a square + RandomForest de la fase de Búsqueda al presentar el RMSE/MAE más bajos y R^2 más alto del conjunto, siendo entonces el referente de precisión.
- Se observa que la fase de Optimización logra obtener las primeras 3 posiciones del ranking sugiriendo que el refinamiento del modelo y recorte de los espacios de hiperparámetros es importante para maximizar el desempeño de las métricas de error.
- La selección final depende del criterio operativo, si se desea tener el R^2 más sólido, el caso número uno de la fase de búsqueda es la mejor opción por combinar RMSE/MAE bajos con un R^2 sólido de 0,390. Los casos sqrt/original + XGBoost se mantienen como alternativas robustas cuando se busca desempeño balanceado, aunque en general no mejoran simultáneamente RMSE/MAE y R^2 respecto a las primeras dos posiciones.
- La escala “original” y las transformaciones “sqrt” y “square” aparecen de forma repetida entre los primeros lugares, lo que sugiere que mantener la escala original o aplicar transformaciones de potencia facilitaron que XGBoost capturara curvaturas suaves del objetivo, por el contrario “log1p” no domina el Top en este experimento y tiende a desplazar los casos a la zona media baja del ranking.

4.3.4 BayesSearch + Huber

Para ambas fases de optimización todos los modelos tuvieron un recorte en sus espacios, con un menor recorte a los casos con el algoritmo MLP, mientras que para la segunda fase si hubo ajuste para cada par transformación-Modelo, ver Tabla 52 y Tabla 53 en Anexos. A continuación, los resultados comparando la fase de búsqueda y las fases de optimización, en sombreado verde los mejores resultados de cada métrica:

Tabla 28: Mejores resultados fases Búsqueda + Optimización BayesSearch + Huber campo 3

#	Fase	Transformación	Modelo	RMSE	MAE	R^2	MAPE	Final Rank
1	Optimizado 2	original	XGBoost	89,708	61,010	0,322	91,097	22
2	Búsqueda	original	XGBoost	90,025	60,100	0,317	92,262	22
3	Búsqueda	sqrt	XGBoost	90,949	60,216	0,303	67,454	22

4	Optimizado	square	XGBoost	89,100	62,651	0,331	114,471	24
5	Optimizado	original	XGBoost	90,841	60,819	0,304	88,589	26
6	Optimizado	sqrt	XGBoost	91,369	61,582	0,296	77,659	28
7	Optimizado 2	square	XGBoost	89,480	63,288	0,325	123,001	29
8	Optimizado 2	sqrt	XGBoost	92,687	62,288	0,276	78,246	32
9	Búsqueda	log1p	XGBoost	97,576	63,788	0,197	57,163	36
10	Búsqueda	cube	XGBoost	89,669	65,312	0,322	113,918	37
11	Búsqueda	square	XGBoost	90,465	64,369	0,310	117,295	40
12	Optimizado	original	RandomForest	94,641	64,001	0,245	100,026	45
13	Optimizado 2	log1p	XGBoost	98,282	65,076	0,186	66,678	46
14	Optimizado 2	original	RandomForest	95,386	64,270	0,233	97,175	47
15	Optimizado	sqrt	RandomForest	98,270	64,919	0,186	80,797	50
16	Optimizado	log1p	XGBoost	98,318	65,226	0,185	67,372	51
17	Optimizado 2	sqrt	RandomForest	98,345	64,904	0,185	81,409	55

- El mejor desempeño global lo alcanza square + XGBoost de la primera fase Optimizada al ocupar el primer lugar del re-ranking multi-métrica, sugiriendo que la transformación de “square” captura parte de no linealidad del objetivo y permite a XGBoost maximizar simultáneamente desempeño en ajuste y error absoluto al destacarse por un RMSE mínimo y R^2 máximo dentro del conjunto evaluado.
- La fase de optimización fue competitiva y efectiva en cuanto al Top-5, ya que colocó tres configuraciones dentro de este y además obtiene el primer lugar del global. No obstante, el hecho de que Búsqueda también aparezcan en el frente indica que el espacio amplio de búsqueda contenía regiones de buen desempeño y refinamiento de hiperparametros fue exitoso para mejorar la consistencia de los resultados frente a la fase de “Búsqueda” inicial.
- La transformación “log1p” aparece como opción competitiva pero penalizada por el ranking final, ya que tiende a mejorar métricas asociadas a error relativo en algunos casos, pero en esta corrida queda afectada por perdidas en RMSE y/o R^2 frente a las mejores configuraciones con la escala original /square/sqrt. Esto sugiere que, para este conjunto de datos, la compresión logarítmica no es la más eficiente para maximizar simultáneamente error absoluto y capacidad explicativa.
- El algoritmo RandomForest presentó desempeño inferior en el ranking, ingresando únicamente en posiciones con métricas consistentemente por debajo de XGBoost. Esto refuerza que para la naturaleza de los datos de caudal evaluados, el aprendizaje secuencial del boosting es significativamente más competitivo que el promedio de árboles independientes del RandomForest.

- Los valores de R^2 se ubican en rangos moderados y el máximo obtenido fue de 0,331 en el ranking, lo que implica que una fracción relevante de la variabilidad permanece sin explicar, apuntando a limitaciones como ruido, variables omitidas, heterocedasticidad y/o patrones no modelados y justifica futuras iteraciones adicionales centradas en “feature engineering”, incorporación de nuevas variables y estrategias robustas frente a colas pesadas/outliers.

4.3.5 Análisis de resultados Global fases de búsqueda y optimización

A continuación, similar al campo anterior se consolidan los mejores casos obtenidos entre las diferentes fases evaluadas:

Tabla 29: Mejores resultados globales fases Búsqueda + Optimización campo 3


#	Configuración	Fase	Transformación	Algoritmo	RMSE	MAE	R^2	MAPE	Final_Rank	R^2 Train
1	RandomSearch+MedAE	Optimizado 2	square	XGBoost	87,061	60,213	0,361	67,479	47	0,832
2	RandomSearch+MedAE	Optimizado	cube	XGBoost	80,193	58,491	0,458	87,551	47	0,867
3	RandomSearch+MedAE	Optimizado	original	XGBoost	89,229	62,674	0,329	60,771	59	0,999
4	RandomSearch+MedAE	Búsqueda	square	XGBoost	85,213	60,434	0,388	84,633	60	0,852
5	BayesSearch+Medae	Optimizado	square	RandomForest	85,072	58,227	0,390	97,411	63	0,854
6	BayesSearch+Medae	Optimizado	square	XGBoost	85,651	60,672	0,382	85,369	64	0,892
7	BayesSearch+Medae	Búsqueda	square	XGBoost	85,846	61,057	0,379	81,259	66	0,747
8	BayesSearch+Medae	Optimizado 2	square	XGBoost	86,314	61,719	0,372	79,387	71	0,889
9	RandomSearch+MedAE	Búsqueda	cube	XGBoost	82,420	59,790	0,427	115,934	72	0,840
10	RandomSearch+MedAE	Búsqueda	sqrt	XGBoost	91,108	60,683	0,300	60,512	76	0,692
45	RandomSearch+MedAE	Optimizado	log1p	XGBoost	99,699	62,817	0,162	53,076	158	0,800

- El algoritmo XGBoost se consolida como el algoritmo dominante en el Top-10, donde 9 de las 10 configuraciones corresponden a XGBoost, lo que indica un perfil sesgo–varianza más favorable frente a las alternativas evaluadas bajo el mismo conjunto de variables.
- Las transformaciones de potencia, cuadrática y cubica, como la escala original concentran el mejor desempeño global, con 7 casos de “square” y 2 de “cube”, complementadas por casos con la variable objetivo en escala “original” con 1 caso. Esto es consistente con un objetivo con asimetría a la derecha y colas pesadas, donde re escalar mediante potencias mejora la separabilidad del patrón para modelos no lineales basados en árboles.
- Existe un equilibrio competitivo entre los métodos de optimización, BayesSearch y RandomSearch se reparten el Top-10 con 4 y 6 respectivamente, donde RandomSearch logra el R^2 más alto y RMSE/MAPE más bajos mientras BayesSearch consigue el MAE más bajo. Esto sugiere que para este conjunto de datos, ambas estrategias son robustas,

siendo RandomSearch ligeramente más eficiente indicando que la exploración aleatoria fue suficiente para localizar regionales de alto desempeño.

- El RMSE promedio del Top-10 es 85,83 y el R^2 promedio es 0,375 con valores relativamente concentrados sin saltos abruptos entre posiciones. Esto sugiere robustez del conjunto de mejores configuraciones y que, a partir de cierto umbral, la mejora marginal podría depender más de variables adicionales, reducción de ruido o “feature engineering”.
- La estabilidad del R^2 de entrenamiento en el rango de 0,80 – 0,89 parece ser el “punto óptimo” para este dataset, donde el modelo aprende la estructura principal sin caer en la memorización excesiva.
- El Top-10 es una mezcla entre fases con 4 de Búsqueda, 4 en con Optimización 1 y 2 en la optimización 2, indicando que las configuraciones de alto desempeño tienden a reaparecer entre fases, reduciendo la probabilidad de que los mejores resultados se deban únicamente al azar de la exploración.
- La recomendación operativa fue priorizar el caso #2 cube + RandomForest de la configuración RandomSearch+MedAE de la fase 2 de optimización como “modelo base” por su mejor balance conjunto de métricas de error, maximizando R^2 , un RMSE más bajo y un MAE competitivo.

Figura 18: Grafico de dispersión predicción vs real, tres mejores casos Campo 3



5 CONCLUSIONES

El trabajo se planteó, desde el inicio, demostrar que es posible construir un flujo completo de ciencia de datos que permita predecir la producción de crudo de pozos de yacimientos colombianos a partir de la información histórica disponible, combinando análisis exploratorio, selección de variables, transformaciones de la variable objetivo y entrenamiento comparativo de varios algoritmos de aprendizaje automático.

Un primer bloque de resultados tiene que ver con los objetivos asociados al entendimiento de los datos. Se hizo un análisis exploratorio por campo que permitió ver la misma constante en los tres: la variable “bopd” está claramente sesgada a la derecha y contiene valores altos que no pueden descartarse sin perder representatividad, esa observación fue la que justificó después el uso de funciones de pérdida robustas (MedAE y Huber) y la prueba de varias transformaciones del objetivo, de modo que los modelos no aprendieran únicamente el comportamiento de los pozos “promedio”, sino también el de los pozos de alta producción. También se depuró el conjunto de variables usando correlaciones (Pearson/Spearman) y asociación mixta; con eso se evitó entrenar con columnas redundantes y se mantuvieron las variables que los ingenieros de yacimientos reconocen como explicativas.

Un segundo bloque está relacionado con los algoritmos y el modo de entrenarlos, se trabajó con lo que la revisión de la literatura muestra son modelos empleados de manera repetitiva en otras investigaciones para producción de hidrocarburos —Regresión lineal, Random Forest, XGBoost, SVM y MLP— y se sometió ese mismo grupo a dos estrategias de búsqueda de hiperparámetros (RandomSearch y BayesSearch). El hecho de que algunos de los mejores modelos provengan de la fase de búsqueda y no necesariamente de las fases optimizadas indica que el espacio de búsqueda quedó bien planteado y que, para conjuntos de datos del tamaño usado en esta tesis, una búsqueda aleatoria bien informada puede ser tan eficaz como una búsqueda bayesiana más costosa.

A partir de ahí, las conclusiones pueden leerse en dos niveles: por campo y de forma integrada:

a) Conclusiones por campo:

- *Campo 1:* Presento la distribución más problemática con una asimetría positiva marcada y presencia de extremos, el estudio determinó que el algoritmo XGBoost posee la mayor estabilidad para este entorno, logrando posicionarse en el 80% del ranking de los mejores modelos, lo cual hizo que las combinaciones que usaron XGBoost con transformaciones “recíprocal” o “log1p” y pérdidas robustas quedaran arriba del ranking, y al generar las

fases de optimización presento más estabilidad. El algoritmo MLP también resulto competitivo al priorizar MedAE, lo cual confirmó que, cuando se reduce el peso de los extremos en la fase de selección, los modelos sensibles a escala pueden competir.

- *Campo 2:* La transformación que mejor equilibró error y estabilidad fue log1p, sobre ella, XGBoost y RandomForest fueron los algoritmos más constantes en posición de ranking altos. Lo que mostro que en un escenario menos extremo que el del Campo 1, la compresión logarítmica fue suficiente para que los árboles fueran más competitivos. También se observó que Huber y MedAE ayudaron a mantener el MAE en un rango estrecho es decir con menor dispersión pese al tamaño más reducido del conjunto de datos. Se detalla también que las fases de optimización profundizaron las zonas de búsqueda mejorando aún más las métricas de error de estrategias ya evaluadas. Se observó que la optimización dirigida mediante búsquedas bayesianas superó los enfoques genéricos, alcanzando un R^2 de 0.425.
- *Campo 3:* En este campo XGBoost volvió a dominar, pero se observó que una transformación de potencia ya sea cuadrática o cubica presento resultados de métricas competitivas seguido de cerca con la escala original, todas con mejores resultados por encima de la transformación logarítmica. Eso sugiere que la relación entre las variables de entrada y la producción estaba un poco mejor explicada y que el algoritmo pudo capturar la no linealidad sin una transformación tan agresiva.

b) Conclusiones integradas

Vistos juntos, los tres campos confirman tres ideas que atraviesan este proyecto aplicado:

1. No hay una transformación única que sirva para todos los yacimientos, En unos casos gana *reciprocal*, en otros log1p y en otros basta la escala original o una potencia. Lo cual encaja con la línea de pensamiento de la ingeniería de yacimientos de que cada yacimiento y campo presenta una propia mezcla de mecanismos de empuje, historia de producción e intervención, y la transformación termina siendo una forma de “aproximar” esa física distinta en el espacio de los datos.
2. Sí hay, en cambio, un algoritmo que es sistemáticamente competitivo, XGBoost, aparece repetidas veces en los tres campos, soporta bien las seis transformaciones probadas y responde en todas las fases, búsqueda y optimización. RandomForest es el acompañante más sólido, especialmente cuando el conjunto presenta un mayor ruido o un menor tamaño de conjunto de datos, en cuanto a SVM y la regresión lineal presentaron una menor presencia en los Top del ranking, explicado por una relación entrada-salida que no

es lineal.

3. El re-ranking fue necesario y es una metodología simple que permitió diferenciar “empates” entre modelos entrenados con transformaciones diferentes o en fases distintas. El ranking final, que penaliza R^2 negativos y mira simultáneamente RMSE, MAE y MAPE, permitió decir con claridad cuáles combinaciones son preferibles para operativizar los modelos.
4. Las fases de optimización generalizada y focalizadas mostraron mejoras en los tiempos frente a la fase exploratorio y presento mejoras en varias oportunidades en las métricas de desempeño.

En ese sentido, el objetivo general —contar con un procedimiento de ciencia de datos que permita predecir producción de pozos en un contexto colombiano— quedó respaldado por evidencia en los tres campos; y los objetivos específicos —explorar los datos, seleccionar variables, comparar técnicas, implementar modelos y evaluarlos con métricas estándar— se vieron reflejados en cada paso de la investigación. El aporte más visible de este proyecto es el abandono de una idea de tratar el problema como la búsqueda de “un” modelo y lo convirtió en la definición de un protocolo de modelado que otras áreas del negocio pueden repetir con sus propios datos, particularmente valioso para el área de yacimientos porque ofrece una alternativa más rápida, multiplicable internamente entre ingenieros de yacimientos y áreas de negocio y objetiva que los flujos tradicionales de simulación numérica, pero sin romper la lógica de reporte en “bopd”, caudal de producción de crudo, que el usuario final necesita.

6 LIMITACIONES

- Datos y techo predictivo: La calidad y el alcance de los datos disponibles fijan un límite claro: los mejores R^2 quedaron por debajo de 0,5. Ese rango es útil para apoyo a la decisión, pero indica que hay fenómenos —operacionales, de presión, de interacción entre pozos— que no estaban en las tablas y que los modelos no podían aprender.
- Tamaño de muestra por campo: Algunos campos, en especial el segundo, tienen pocos pozos, eso obliga a ser conservadores con la complejidad del modelo y hace que los resultados sean más sensibles a outliers o a ligeros cambios en la partición entrenamiento-prueba.
- Representatividad y ruido: el tamaño muestral y la variabilidad operacional limitan el R^2 alcanzable; parte de la varianza responde a factores no observados en los datos.

- Abstracción física: el enfoque es data-driven; no impone explícitamente balance de materia ni restricciones físico-operativas, lo que puede tensionarse en condiciones extremas no vistas en entrenamiento.
- Estructura espacial: no se modelaron de forma explícita conectividades entre pozos (vecindad/arena), lo que simplifica la interacción inyector–productor.
- Validación principalmente estática: Se trabajó con particiones aleatorias y no con validaciones temporales, para un proceso de producción que es intrínsecamente dinámico, esto es una simplificación.
- Dependencia del contexto: Aunque se trabajó con tres campos distintos, todos pertenecen al mismo entorno operativo; la portabilidad del flujo a campos de otras cuencas debe comprobarse con nuevos datos o conjuntos de datos de la literatura los cuales usualmente son difícil de obtener por la confidencialidad y riesgo empresarial.

7 TRABAJOS FUTUROS

- Implementar *time-series split* o ventanas deslizantes para aproximarse mejor al uso real del modelo, donde las predicciones se hacen con información más antigua sobre periodos posteriores.
- Incorporar secuencias de producción e inyección, relaciones productor-inyector y agregaciones por bloque o arena, esto ataca directamente la fracción de varianza hoy no explicada.
- Modelos híbridos y de gradiente modernos, explorando LightGBM, CatBoost o ensambles ligeros entre XGBoost y RandomForest, y evaluar variantes con restricciones físicas para asegurar coherencia con el comportamiento del yacimiento.
- Repetir el flujo en campos con otros mecanismos de empuje o con pozos horizontales/multilaterales para medir la robustez del protocolo.
- Incorporar intervalos de predicción, de modo que el ingeniero no reciba sólo un punto, sino un rango de producción probable.

6 REFERENCIAS BIBLIOGRÁFICAS

- [1] M. R. Carlson, *Practical Reservoir Simulation: Using, Assessing, and Developing Results*. PennWell, 2003. [En línea]. Disponible en: <https://books.google.com.co/books?id=oi7rPyD4Oy4C>
- [2] A. Tadjer, A. Hong, y R. B. Bratvold, "Machine learning based decline curve analysis for short-term oil production forecast", *Energy Exploration and Exploitation*, vol. 39, núm. 5, pp. 1747–1769, sep. 2021, doi: 10.1177/01445987211011784.
- [3] Y. Pan, L. Deng, P. Zhou, y W. J. Lee, "Laplacian Echo-State Networks for production analysis and forecasting in unconventional reservoirs", *J. Pet. Sci. Eng.*, vol. 207, dic. 2021, doi: 10.1016/j.petrol.2021.109068.
- [4] J. J. Arps, "Analysis of Decline Curves", *Transactions of the AIME*, vol. 160, núm. 01, pp. 228–247, dic. 1945, doi: 10.2118/945228-G.
- [5] M. J. Fetkovich, "Decline Curve Analysis Using Type Curves", *Journal of Petroleum Technology*, vol. 32, núm. 06, pp. 1065–1077, jun. 1980, doi: 10.2118/4629-PA.
- [6] J. McCarthy, "WHAT IS ARTIFICIAL INTELLIGENCE?", 2007. [En línea]. Disponible en: <http://www-formal.stanford.edu/jmc/>
- [7] IBM, "Artificial Intelligence". Consultado: el 7 de diciembre de 2023. [En línea]. Disponible en: www.ibm.com/topics/artificial-intelligence
- [8] IBM, "Machine Learning". Consultado: el 7 de diciembre de 2023. [En línea]. Disponible en: www.ibm.com/mx-es/topics/machine-learning
- [9] M. W. B. Azlinah, M. Bee, y W. Yap, *Supervised and Unsupervised Learning for Data Science*. en *Unsupervised and Semi-Supervised Learning*. Cham: Springer International Publishing, 2020. doi: 10.1007/978-3-030-22475-2.
- [10] L. Song, C. Wang, C. Lu, S. Yang, C. Tan, y X. Zhang, "Machine Learning Model of Oilfield Productivity Prediction and Performance Evaluation", en *Journal of Physics: Conference Series*, Institute of Physics, 2023. doi: 10.1088/1742-6596/2468/1/012084.
- [11] S. Tong, F. Wang, H. Gao, y W. Zhu, "A machine learning-based method for analyzing factors influencing production capacity and production forecasting in fractured tight oil reservoirs", *Int. J. Hydrogen Energy*, vol. 70, pp. 136–145, jun. 2024, doi: 10.1016/j.ijhydene.2024.05.036.
- [12] S. Pan *et al.*, "Oil well production prediction based on CNN-LSTM model with self-attention mechanism", *Energy*, vol. 284, p. 128701, dic. 2023, doi: 10.1016/j.energy.2023.128701.
- [13] Z. Guo, H. Wang, X. Kong, L. Shen, y Y. Jia, "Machine learning-based production prediction model and its application in duvernay formation", *Energies (Basel)*, vol. 14, núm. 17, sep. 2021, doi: 10.3390/en14175509.
- [14] U. Osah y J. Howell, "Predicting oil field performance using machine learning programming: a comparative case study from the UK continental shelf", *Petroleum Geoscience*, vol. 29, núm. 1, feb. 2023, doi: 10.1144/petgeo2022-071.
- [15] C. S. W. Ng, A. Jahanbani Ghahfarokhi, y M. Nait Amar, "Well production forecast

- in Volve field: Application of rigorous machine learning techniques and metaheuristic algorithm”, *J. Pet. Sci. Eng.*, vol. 208, ene. 2022, doi: 10.1016/j.petrol.2021.109468.
- [16] U. C. Amaechi, P. M. Ikpeka, M. Xianlin, y J. O. Ugwu, “Application of machine learning models in predicting initial gas production rate from tight gas reservoirs”, *Rudarsko Geolosko Naftni Zbornik*, vol. 34, núm. 3, pp. 29–40, 2019, doi: 10.17794/rgn.2019.3.4.
- [17] W. Bejjar, “Oil Production Prediction of Multi-fractured Horizontal Wells Using Data Science Techniques”, Montanuniversität Leoben, Leoben, 2021.
- [18] M. Fang, H. Shi, H. Li, y T. Liu, “Application of Machine Learning for Productivity Prediction in Tight Gas Reservoirs”, *Energies (Basel)*, vol. 17, núm. 8, abr. 2024, doi: 10.3390/en17081916.
- [19] M. S. Thesis, J. Kaninda, y M. Nicosia, “DEPARTMENT OF PETROLEUM AND NATURAL GAS ENGINEERING ANALYSIS AND PERFORMANCE PREDICTION OF SHALE WELLS USING DATA ANALYTICS AND MACHINE LEARNING”, 2023.
- [20] Q. Li, K. Guo, X. Gao, S. Zhang, Y. Jin, y J. Liu, “Productivity Prediction Model of Tight Oil Reservoir Based on Particle Swarm Optimization–Back Propagation Neural Network”, *Processes*, vol. 12, núm. 9, p. 1890, sep. 2024, doi: 10.3390/pr12091890.
- [21] R. Huang *et al.*, “Quantitative Analysis of the Main Controlling Factors of Oil Saturation Variation”, *Geofluids*, vol. 2021, 2021, doi: 10.1155/2021/6515846.
- [22] A. Lawal, Y. Yang, H. He, y N. L. Baisa, “Machine Learning in Oil and Gas Exploration: A Review”, *IEEE Access*, vol. 12, pp. 19035–19058, 2024, doi: 10.1109/ACCESS.2023.3349216.
- [23] J. Zhang, J. Zhang, y S. Huang, “Research Progress on the Application of Machine Learning in Oil and Gas Exploration and Development”, 2024.
- [24] W. P. Bai, S. Q. Cheng, X. Y. Guo, Y. Wang, Q. Guo, y C. D. Tan, “Oilfield analogy and productivity prediction based on machine learning: Field cases in PL oilfield, China”, *Pet. Sci.*, vol. 21, núm. 4, pp. 2554–2570, ago. 2024, doi: 10.1016/j.petsci.2024.02.018.
- [25] C. Zhao, Y. Jia, Y. Qu, W. Zheng, S. Hou, y B. Wang, “Forecasting Gas Well Classification Based on a Two-Dimensional Convolutional Neural Network Deep Learning Model”, *Processes*, vol. 12, núm. 5, may 2024, doi: 10.3390/pr12050878.
- [26] N. M. Ibrahim *et al.*, “Well Performance Classification and Prediction: Deep Learning and Machine Learning Long Term Regression Experiments on Oil, Gas, and Water Production”, *Sensors*, vol. 22, núm. 14, jul. 2022, doi: 10.3390/s22145326.
- [27] R. de O. Werneck *et al.*, “Data-driven deep-learning forecasting for oil production and pressure”, *J. Pet. Sci. Eng.*, vol. 210, p. 109937, mar. 2022, doi: 10.1016/j.petrol.2021.109937.
- [28] D. Han y S. Kwon, “Application of machine learning method of data-driven deep learning model to predict well production rate in the shale gas reservoirs”, *Energies (Basel)*, vol. 14, núm. 12, jun. 2021, doi: 10.3390/en14123629.
- [29] F. Song, H. Ding, Y. Wang, S. Zhang, y J. Yu, “A Well Production Prediction Method

- of Tight Reservoirs Based on a Hybrid Neural Network”, *Energies (Basel)*, vol. 16, núm. 6, mar. 2023, doi: 10.3390/en16062904.
- [30] A. Alalimi, L. Pan, M. A. A. Al-qaness, A. A. Ewees, X. Wang, y M. Abd Elaziz, “Optimized Random Vector Functional Link network to predict oil production from Tahe oil field in China”, *Oil & Gas Science and Technology – Revue d’IFP Energies nouvelles*, vol. 76, p. 3, dic. 2021, doi: 10.2516/ogst/2020081.
- [31] Y. Jin, K. Guo, X. Gao, y Q. Li, “Tight Oil Well Productivity Prediction Model Based on Neural Network”, *Processes*, vol. 12, núm. 10, oct. 2024, doi: 10.3390/pr12102088.
- [32] E. Du, Y. Liu, L. Xue, X. Zhu, y L. Song, “A data-driven model for production prediction of strongly heterogeneous reservoir under uncertainty”, *Geoenergy Science and Engineering*, vol. 223, p. 211542, abr. 2023, doi: 10.1016/j.geoen.2023.211542.
- [33] R. Andrais y J. Rubin, “Probabilistic Oil and Gas Production Forecasting using Machine Learning”, 2021.
- [34] K. Fawagreh, M. M. Gaber, y E. Elyan, “Random forests: From early developments to recent advancements”, *Systems Science and Control Engineering*, vol. 2, núm. 1, pp. 602–609, 2014, doi: 10.1080/21642583.2014.956265.
- [35] Sana Fatima, Ayan Hussain, Sohaib Bin Amir, Muhammad Gulraiz Zahid Awan, Syed Haseeb Ahmed, y Syed Muhammad Huzaiifa Aslam, “XGBoost and Random Forest Algorithms: An in Depth Analysis”, *Pakistan Journal of Scientific Research*, vol. 3, núm. 1, pp. 26–31, jul. 2023, doi: 10.57041/vol3iss1pp26-31.
- [36] Y. Yang y H. Wang, “Random Forest-Based Machine Failure Prediction: A Performance Comparison”, *Applied Sciences (Switzerland)*, vol. 15, núm. 16, ago. 2025, doi: 10.3390/app15168841.
- [37] S. Alam, M. S. Kabir, Md. N. Hossain, Q. R. Hasnaine, y Md. G. Rabiul Alam, “Classification Accuracy Comparison between Machine Learning Algorithms and a Deep Learning Algorithm in Predicting Hand Gestures”, en *2022 32nd Conference of Open Innovations Association (FRUCT)*, IEEE, nov. 2022, pp. 22–29. doi: 10.23919/FRUCT56874.2022.9953843.
- [38] M. W. B. Azlinah, M. Bee, y W. Yap, *Supervised and Unsupervised Learning for Data Science*. en *Unsupervised and Semi-Supervised Learning*. Cham: Springer International Publishing, 2020. doi: 10.1007/978-3-030-22475-2.
- [39] M. S. Chowdhury, “Comparison of accuracy and reliability of random forest, support vector machine, artificial neural network and maximum likelihood method in land use/cover classification of urban setting”, *Environmental Challenges*, vol. 14, ene. 2024, doi: 10.1016/j.envc.2023.100800.
- [40] Y. Li, C. Stasinakis, y W. M. Yeo, “A Hybrid XGBoost-MLP Model for Credit Risk Assessment on Digital Supply Chain Finance”, *Forecasting*, vol. 4, núm. 1, pp. 184–207, mar. 2022, doi: 10.3390/forecast4010011.
- [41] M. C. Be *et al.*, “Comparative Analysis of Machine Learning Algorithms for Object-Based Crop Classification Using Multispectral Imagery”, *Drones*, vol. 9, núm. 11,

- nov. 2025, doi: 10.3390/drones9110763.
- [42] geeksforgeeks, “Implementation of XGBoost (eXtreme Gradient Boosting)”.
 - [43] Z. Lei y G. Daihong, “New Model for Predicting Production Capacity of Horizontal Well Volume Fracturing in Tight Reservoirs”, *ACS Omega*, vol. 9, núm. 10, pp. 11806–11819, mar. 2024, doi: 10.1021/acsomega.3c09051.
 - [44] O. Q. Alharbi y S. A. Alarifi, “Productivity Index Prediction for Single-Lateral and Multilateral Oil Horizontal Wells Using Machine Learning Techniques”, *ACS Omega*, vol. 8, núm. 7, pp. 7201–7210, feb. 2023, doi: 10.1021/acsomega.3c00289.
 - [45] N. R. K. Tatsipie y J. J. Sheng, “Deep learning-based sensitivity analysis of the effect of completion parameters on oil production”, *J. Pet. Sci. Eng.*, vol. 209, feb. 2022, doi: 10.1016/j.petrol.2021.109906.
 - [46] E. D. Attanasi, P. A. Freeman, y T. C. Coburn, “Well predictive performance of play-wide and Subarea Random Forest models for Bakken productivity”, *J. Pet. Sci. Eng.*, vol. 191, ago. 2020, doi: 10.1016/j.petrol.2020.107150.
 - [47] A. Tadjer, A. Hong, y R. Bratvold, “Bayesian Deep Decline Curve Analysis: A New Approach for Well Oil Production Modeling and Forecasting”, *SPE Reservoir Evaluation & Engineering*, vol. 25, núm. 03, pp. 568–582, ago. 2022, doi: 10.2118/209616-PA.
 - [48] S. M. Razak, J. Cornelio, Y. Cho, H.-H. Liu, R. Vaidya, y B. Jafarpour, “Transfer Learning with Recurrent Neural Networks for Long-Term Production Forecasting in Unconventional Reservoirs”, 2022. [En línea]. Disponible en: <http://onepetro.org/SJ/article-pdf/27/04/2425/2860035/spe-209594-pa.pdf/1>

7 ANEXOS

7.1 ESPACIOS DE HIPERPARAMETROS

Tabla 30: Espacio de hiperparametros fase de búsqueda versus Optimizado 1 RandomSearch + MedAE Campo 1

Algoritmo	Hiperparametros	Espacio Búsqueda	Espacio Optimizado 1
RandomForest	n_estimators	(200, 3000)	(350, 2936)
	max_depth	(3, 40)	(5, 39)
	min_samples_split	(2, 50)	(2, 49)
	min_samples_leaf	(1, 20)	(1, 20)
	max_features	['sqrt', 'log2']	['sqrt', 'log2']
	max_samples	(0.3, 0.7)	(0.324, 0.655)
XGBoost	n_estimators	(200, 3000)	(400, 2911)
	max_depth	(2, 30)	(3, 29)
	learning_rate	(1e-4, 3e-1)	(6.22e-4, 1.95e-1)
	subsample	(0.30–1.0)	(0.328, 0.637)
	colsample_bytree	(0.30, 0.70)	(0.383, 0.600)
	min_child_weight	(1e-3, 5,0)	(1.792e-3, 2.720)
	gamma	(1e-5, 1,0)	(2.396e-5, 6.990e-1)
	reg_lambda	(1e-3, 1e2)	(4.122e-3, 6.767e1)
SVM	reg_alpha	(1e-5, 1e1)	(2.901e-5, 1.286)
	kernel	['rbf', 'linear']	['rbf', 'linear']
	C	(1e-2, 1e3)	(2.405e-2, 5.402e2)
	epsilon	(1e-4, 1e-1)	(1.480e-4, 7.306e-2)
MLP	gamma	(1e-6, 1.0)	(2.12e-6, 6.943e-1)
	hidden_layer_sizes	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]	(100,), (150,), (100, 50), (200, 100)
	activation	['relu', 'tanh']	['tanh']
	solver	['adam']	['adam']
	alpha	(1e-6, 1e-1)	(1.8e-6, 7.906e-2)
	learning_rate_init	(1e-4, 1e-1)	(1.03e-4, 9.299e-2)
	learning_rate	['adaptive']	['adaptive']
	batch_size	[32, 64, 128, 256]	[32, 64, 128, 256]
	early_stopping	[True]	[True]
	validation_fraction	[0.15]	(0.12, 0.06)
LinearRegression	n_iter_no_change	[10, 40]	[10, 40]
	—	sin búsqueda ({})	sin búsqueda ({})

Tabla 31: Espacio de hiperparametros Optimizado 2 RandomSearch + MedAE Campo 1

Algoritmo	Hiperparámetros	Original	Log1p	sqrt	square	cube	reciprocal
Random Forest	n_estimators	[379, 2007]	[991, 2935]	[447, 2851]	[573, 2552]	[350, 2826]	[534, 2751]
	max_depth	[6, 35]	[5, 35]	[5, 38]	[11, 36]	[7, 36]	[7, 36]
	min_samples_split	[10, 40]	[4, 46]	[31, 48]	[4, 27]	[2, 18]	[4, 29]

	min_samples_leaf	[1, 8]	[1, 19]	[4, 15]	[5, 17]	[1, 5]	[2, 17]
	max_features	'sqrt'	'sqrt'	'log2'	'log2'	'sqrt'	'log2'
	max_samples	[0.48, 0.93]	[0.35, 0.82]	[0.32, 0.47]	[0.50, 0.97]	[0.49, 0.95]	[0.65, 0.96]
XGBoost	n_estimators	[766, 2639]	[633, 2637]	[641, 2716]	[550, 2762]	[550, 2720]	[400, 2910]
	max_depth	[4, 27]	[4, 24]	[6, 27]	[3, 27]	[4, 27]	[5, 28]
	learning_rate	[0.002, 0.14]	[0.0006, 0.09]	[0.003, 0.19]	[0.002, 0.02]	[0.001, 0.03]	[0.0009, 0.10]
	subsample	[0.32, 0.84]	[0.41, 0.91]	[0.55, 0.96]	[0.32, 0.85]	[0.43, 0.96]	[0.38, 0.94]
	colsample_bytree	[0.56, 0.98]	[0.38, 0.73]	[0.41, 0.97]	[0.45, 0.89]	[0.47, 0.85]	[0.40, 0.85]
	min_child_weight	[0.002, 1.20]	[0.002, 0.66]	[0.002, 0.54]	[0.002, 1.27]	[0.001, 0.95]	[0.002, 2.71]
	gamma	[2.8e-5, 0.58]	[4.3e-5, 0.04]	[1.1e-4, 0.15]	[2.3e-5, 0.69]	[7.7e-5, 0.54]	[3.8e-5, 0.005]
	reg_lambda	[0.006, 67.6]	[0.004, 6.88]	[0.008, 67.6]	[0.11, 67.6]	[0.06, 60.5]	[0.004, 41.4]
	reg_alpha	[7.5e-5, 0.12]	[0.0001, 1.28]	[0.0003, 0.38]	[4.3e-5, 0.82]	[0.0001, 1.03]	[2.9e-5, 0.15]
SVM	kernel	'rbf'	'rbf'	'rbf'	'rbf'	'linear'	'linear'
	C	[0.37, 8.59]	[0.02, 0.66]	[0.04, 1.10]	[3.27, 540.2]	[42.6, 260.3]	[0.04, 218.7]
	epsilon	[1.4e-4, 0.06]	[5.0e-4, 0.07]	[2.2e-4, 0.07]	[2.6e-4, 0.05]	[2.7e-4, 0.03]	[0.02, 0.03]
	gamma	[0.004, 0.33]	[2.1e-6, 0.69]	[0.002, 0.34]	[2.2e-5, 0.37]	[3.8e-6, 0.21]	[3.5e-6, 0.17]
MLP	hidden_layer_sizes	Default	Default	Default	Default	Default	Default
	activation	'tanh'	'tanh'	'tanh'	'tanh'	'tanh'	'tanh'
	solver	'adam'	'adam'	'adam'	'adam'	'adam'	'adam'
	alpha	[4.8e-6, 0.01]	[4.8e-6, 0.07]	[2.2e-6, 0.01]	[1.7e-6, 0.02]	[6.4e-6, 0.04]	[3.1e-6, 0.07]
	learning_rate_init	[0.0001, 0.003]	[0.0001, 0.03]	[0.0001, 0.01]	[0.001, 0.01]	[0.01, 0.09]	[0.0001, 0.04]
	learning_rate	'adaptive'	'adaptive'	'adaptive'	'adaptive'	'adaptive'	'adaptive'
	batch_size	[32, 256]	[32, 256]	[60, 256]	[60, 256]	[32, 256]	[32, 256]
	early_stopping	True	True	True	True	True	True
	validation_fraction	[0.12, 0.18]	[0.12, 0.18]	[0.12, 0.18]	[0.12, 0.18]	[0.12, 0.18]	[0.12, 0.18]
	n_iter_no_change	[10, 40]	[10, 40]	[10, 40]	[10, 40]	[10, 40]	[10, 40]
LinearReg.	—	No Params					

Tabla 32: Espacio de hiperparametros fase de búsqueda versus Optimizado 1 RandomSearch + Huber Campo 1

Algoritmo	Hiperparametros	Espacio Búsqueda	Espacio Optimizado
RandomForest	n_estimators	(200, 3000)	(430, 2830)
	max_depth	(3, 40)	(7, 39)
	min_samples_split	(2, 50)	(2, 20)
	min_samples_leaf	(1, 20)	(1, 15)
	max_features	['sqrt', 'log2']	['sqrt']
	max_samples	(0.3, 0.7)	(0.476, 0.478)
XGBoost	n_estimators	(200, 3000)	(400, 2810)
	max_depth	(2, 30)	(2, 28)
	learning_rate	(1e-4, 3e-1)	(8.4e-4, 8.7e-2)

	subsample	(0.30–1.0)	(0.33, 0.59)
	colsample_bytree	(0.30, 0.70)	(0.37, 0.56)
	min_child_weight	(1e-3, 5,0)	(1.9e-3, 3,0)
	gamma	(1e-5, 1,0)	(1.8e-5, 6.93e-1)
	reg_lambda	(1e-3, 1e2)	(1.5e-3, 6.8e1)
	reg_alpha	(1e-5, 1e1)	(5.0e-5, 7,2)
SVM	kernel	['rbf', 'linear']	['rbf', 'linear']
	C	(1e-2, 1e3)	(1.7e-2, 8.6e2)
	epsilon	(1e-4, 1e-1)	(1.8e-4, 7.2e-2)
	gamma	(1e-6, 1,0)	(3.0e-6, 4.3e-1)
MLP	hidden_layer_sizes	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]
	activation	['relu', 'tanh']	['relu', 'tanh']
	solver	['adam']	['adam']
	alpha	(1e-6, 1e-1)	(3.2e-6, 7.6e-2)
	learning_rate_init	(1e-4, 1e-1)	(1.2e-4, 8.4e-2)
	learning_rate	['adaptive']	['adaptive']
	batch_size	[32, 64, 128, 256]	[32, 64, 128, 256]
	early_stopping	[True]	[True]
	validation_fraction	[0.15]	(0.12, 0.06)
	n_iter_no_change	[10, 40]	[10, 40]
LinearRegression	—	sin búsqueda ({})	sin búsqueda ({})

Tabla 33: Espacio de hiperparametros Optimizado 2 RandomSearch + Huber Campo 1

Algoritmo	Parámetro	Original	Log1p	Sqrt	Square	Cube	Reciprocal
Random Forest	n_estimators	[665, 2627]	[435, 2632]	[637, 2632]	[1050, 2627]	[669, 2562]	[435, 2826]
	max_depth	[12, 37]	[7, 38]	[7, 37]	[8, 34]	[8, 37]	[7, 38]
	min_samples_split	[2, 13]	[2, 15]	[2, 13]	[2, 19]	[2, 13]	[2, 17]
	min_samples_leaf	[3, 9]	[1, 5]	[2, 7]	[5, 14]	[2, 8]	[1, 4]
	max_features	'sqrt'	'sqrt'	'sqrt'	'sqrt'	'sqrt'	'sqrt'
	max_samples	[0.47, 0.95]	[0.47, 0.95]	[0.48, 0.95]	[0.53, 0.95]	[0.49, 0.95]	[0.49, 0.95]
XGBoost	n_estimators	[335, 2762]	[661, 2716]	[424, 2719]	[424, 2804]	[424, 2804]	[768, 2716]
	max_depth	[3, 27]	[2, 26]	[3, 25]	[4, 27]	[4, 25]	[4, 27]
	learning_rate	[0.001, 0.024]	[0.002, 0.087]	[0.002, 0.032]	[0.0008, 0.024]	[0.0008, 0.010]	[0.003, 0.064]
	subsample	[0.35, 0.83]	[0.36, 0.81]	[0.36, 0.87]	[0.32, 0.85]	[0.33, 0.91]	[0.36, 0.86]
	colsample_bytree	[0.40, 0.85]	[0.44, 0.89]	[0.40, 0.85]	[0.40, 0.85]	[0.36, 0.85]	[0.43, 0.92]
	min_child_weight	[0.003, 1.29]	[0.002, 0.40]	[0.002, 0.97]	[0.003, 1.29]	[0.003, 1.29]	[0.001, 2.96]
	gamma	[7.6e-5, 0.57]	[8.9e-5, 0.58]	[3.6e-5, 0.57]	[7.6e-5, 0.69]	[6.2e-5, 0.55]	[1.8e-5, 0.002]
	reg_lambda	[5.13, 67.67]	[0.001, 26.74]	[0.05, 53.21]	[8.33, 67.67]	[8.03, 60.58]	[0.003, 7.97]
	reg_alpha	[4.8e-5, 1.00]	[4.8e-5, 3.38]	[0.0001, 7.11]	[6.9e-5, 1.15]	[0.0001, 2.40]	[4.1e-5, 0.11]
SVM	kernel	'rbf'	'rbf'	'rbf'	'rbf'	'linear'	'rbf'

	C	[1.95, 191.82]	[0.16, 5.55]	[0.62, 13.29]	[16.9, 857.2]	[204.8, 672.4]	[0.01, 124.1]
	epsilon	[0.0002, 0.04]	[0.0001, 0.06]	[0.0001, 0.06]	[0.0003, 0.02]	[0.0001, 0.07]	[0.0002, 0.01]
	gamma	[0.005, 0.22]	[0.007, 0.16]	[0.004, 0.14]	[0.001, 0.29]	[3.2e-6, 0.42]	[3.6e-6, 0.15]
MLP	activation	'tanh'	'tanh'	'tanh'	'tanh'	'relu'	'tanh'
	solver	'adam'	'adam'	'adam'	'adam'	'adam'	'adam'
	alpha	[4.3e-6, 0.005]	[3.8e-6, 0.05]	[4.9e-6, 0.05]	[9.7e-6, 0.03]	[3.2e-6, 0.03]	[1.0e-5, 0.07]
	learning_init	[0.0002, 0.03]	[0.0002, 0.06]	[0.0001, 0.02]	[0.003, 0.03]	[0.012, 0.08]	[0.0001, 0.02]
	batch_size	[32, 256]	[32, 128]	[32, 256]	[32, 256]	[32, 256]	[32, 256]
	n_iter_change	[10, 40]	[10, 40]	[10, 40]	[10, 40]	[10, 40]	[10, 40]

Tabla 34: Espacio de hiperparametros fase de búsqueda versus Optimizado 1 BayesSearch + MedAE Campo 1

Algoritmo	Hiperparametros	Espacio Búsqueda	Espacio Optimizado
RandomForest	n_estimators	(200, 3000)	(235, 2219)
	max_depth	(3, 40)	(4, 39)
	min_samples_split	(2, 50)	(6, 36)
	min_samples_leaf	(1, 20)	(1, 19)
	max_features	['sqrt', 'log2']	['sqrt', 'log2']
	max_samples	(0.3, 0.7)	(0.3, 0.7)
XGBoost	n_estimators	(200, 3000)	(484, 2947)
	max_depth	(2, 30)	(7, 30)
	learning_rate	(1e-4, 3e-1)	(6.99e-4, 1.418e-1)
	subsample	(0.30, 1.0)	(0.314, 0.988)
	colsample_bytree	(0.30, 1.0)	(0.325, 0.982)
	min_child_weight	(1e-3, 5,0)	(1.349e-3, 3.016)
	gamma	(1e-5, 1,0)	(1.829e-5, 2.595e-1)
	reg_lambda	(1e-3, 1e2)	(2.265e-3, 9.725e+1)
	reg_alpha	(1e-5, 1e1)	(1.6e-5, 2.657)
SVM	kernel	['rbf', 'linear']	['rbf', 'linear']
	C	(1e-2, 1e3)	(2.335e-1, 1.817e+1)
	epsilon	(1e-4, 1e-1)	(1.4e-4, 6.17e-2)
	gamma	(1e-6, 1.0)	(5.0e-4, 7.003e-1)
MLP	hidden_layer_sizes	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]
	activation	['relu', 'tanh']	['relu', 'tanh']
	solver	['adam']	['adam']
	alpha	(1e-6, 1e-1)	(1.55e-6, 6.53e-2)
	learning_rate_init	(1e-4, 1e-1)	(1.50e-4, 8.46e-2)
	learning_rate	['adaptive']	['adaptive']
	batch_size	[32, 64, 128, 256]	[32, 64, 128, 256]
	early_stopping	[True]	[True]
	validation_fraction	[0.15]	[0.15]
	n_iter_no_change	[10, 40]	[10, 40]
LinearRegression	—	sin búsqueda ({})	sin búsqueda ({})

Tabla 35: Espacio de hiperparametros Optimizado 2 BayesSearch + MedAE Campo 1

Algoritmo	Parámetro	Original	Log1p	Sqrt	Square	Cube	Reciprocal
Random Forest	n_estimators	[741, 1464]	[639, 1188]	[235, 1430]	[1870, 2176]	[711, 2219]	[711, 2219]
	max_depth	[4, 39]	[15, 37]	[4, 6]	[4, 10]	[7, 23]	[7, 23]
	min_samples_split	[33, 36]	[6, 10]	[19, 26]	[25, 28]	[12, 30]	[12, 30]
	min_samples_leaf	[5, 9]	[1, 2]	[2, 3]	[6, 10]	[5, 19]	[5, 19]
	max_features	'log2'	'log2'	'sqrt'	'log2'	'sqrt'	'sqrt'
XGBoost	n_estimators	[659, 2035]	[1290, 2947]	[816, 2627]	[1922, 2873]	[484, 1111]	[484, 1111]
	learning_rate	[0.01, 0.04]	[0.0007, 0.001]	[0.01, 0.11]	[0.01, 0.03]	[0.001, 0.14]	[0.001, 0.14]
	max_depth	[7, 29]	[18, 30]	[8, 28]	[7, 27]	[13, 27]	[13, 27]
	subsample	[0.50, 0.96]	[0.34, 0.81]	[0.78, 0.98]	[0.31, 0.41]	[0.77, 0.81]	[0.77, 0.81]
	colsample_bytree	[0.91, 0.98]	[0.32, 0.56]	[0.87, 0.98]	[0.70, 0.93]	[0.52, 0.73]	[0.52, 0.73]
	reg_lambda	[63.6, 93.6]	[0.002, 0.30]	[58.7, 95.2]	[65.7, 97.2]	[0.01, 13.4]	[0.01, 13.4]
	reg_alpha	[1.6e-5, 0.87]	[2.9e-5, 0.41]	[1.6e-5, 0.05]	[7.4e-5, 2.65]	[0.0006, 0.05]	[0.0006, 0.05]
SVM	kernel	'rbf'	'rbf'	'rbf'	'linear'	'linear'	'linear'
	C	[1.02, 2.15]	[0.23, 0.27]	[0.32, 0.35]	[0.49, 18.1]	[0.49, 18.1]	[0.49, 18.1]
	epsilon	[0.002, 0.06]	[0.0006, 0.02]	[0.0001, 0.0007]	[0.003, 0.01]	[0.003, 0.01]	[0.003, 0.01]
	gamma	[0.03, 0.18]	[0.57, 0.70]	[0.11, 0.12]	[0.0005, 0.31]	[0.0005, 0.31]	[0.0005, 0.31]
MLP	activation	'tanh'	'tanh'	'relu'	'tanh'	'relu'	'tanh'
	alpha	[2.1e-6, 0.008]	[1.5e-6, 0.02]	[1.5e-5, 0.06]	[1.6e-5, 0.02]	[4.4e-6, 0.02]	[1.9e-6, 0.02]
	learning_rate_init	[0.0001, 0.01]	[0.0002, 0.02]	[0.0001, 0.04]	[0.0009, 0.01]	[0.01, 0.08]	[0.005, 0.05]
	batch_size	[60, 256]	[32, 256]	[32, 256]	[32, 256]	[32, 256]	[32, 256]

Tabla 36: Espacio de hiperparametros fase de búsqueda versus Optimizado 1 BayesSearch + Huber Campo 1

Algoritmo	Hiperparametros	Espacio Búsqueda	Espacio Optimizado
RandomForest	n_estimators	(200, 3000)	(200, 2600)
	max_depth	(3, 40)	(5, 30)
	min_samples_split	(2, 50)	(2, 30)
	min_samples_leaf	(1, 20)	(1, 20)
	max_features	['sqrt', 'log2']	['sqrt', 'log2']
	max_samples	(0.3, 0.7)	(0.3, 0.7)
XGBoost	n_estimators	(200, 3000)	(400, 3000)
	max_depth	(2, 30)	(4, 30)
	learning_rate	(1e-4, 3e-1)	(1e-3, 2.5e-1)
	subsample	(0.30, 1.0)	(0.30, 0.85)
	colsample_bytree	(0.30, 1.0)	(0.40, 0.95)
	min_child_weight	(1e-3, 5.0)	(1e-3, 3.5)

	gamma	(1e-5, 1,0)	(1e-5, 6e-1)
	reg_lambda	(1e-3, 1e2)	(1e-3, 1e2)
	reg_alpha	(1e-5, 1e1)	(1e-5, 8.0)
SVM	kernel	['rbf', 'linear']	['rbf', 'linear']
	C	(1e-2, 1e3)	(3e-1, 3e1)
	epsilon	(1e-4, 1e-1)	(1e-4, 1e-1)
	gamma	(1e-6, 1.0)	(1e-5, 3.5e-1)
MLP	hidden_layer_sizes	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]	(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)
	activation	['relu', 'tanh']	['relu', 'tanh']
	solver	['adam']	['adam']
	alpha	(1e-6, 1e-1)	(1e-6, 5e-2)
	learning_rate_init	(1e-4, 1e-1)	(1e-4, 8e-2)
	learning_rate	['adaptive']	['adaptive']
	batch_size	[32, 64, 128, 256]	(32, 257)
	early_stopping	[True]	[True]
	validation_fraction	[0.15]	(0.12, 0.06)
	n_iter_no_change	[10, 40]	(10, 41)
LinearRegression	—	sin búsqueda ({})	sin búsqueda ({})

Tabla 37: Espacio de hiperparametros Optimizado 2 BayesSearch + Huber Campo 1

Algoritmo	Parámetro	Original	Log1p	Sqrt	Square	Cube	Reciprocal
Random Forest	n_estimators	[1399, 1657]	[262, 2100]	[202, 450]	[492, 1786]	[913, 2577]	[711, 2219]
	max_depth	[5, 30]	[5, 7]	[5, 29]	[6, 29]	[7, 13]	[7, 23]
	min_split	[2, 14]	[2, 3]	[2, 6]	[4, 12]	[2, 3]	[12, 30]
	min_leaf	[5, 9]	[1, 2]	[2, 3]	[5, 6]	[1, 2]	[5, 19]
	max_features	'sqrt'	'log2'	'log2'	'sqrt'	'log2'	'sqrt'
XGBoost	n_estimators	[662, 2880]	[1163, 2944]	[1445, 2793]	[732, 2136]	[484, 1111]	[484, 1111]
	learning_rate	[0.006, 0.04]	[0.01, 0.23]	[0.002, 0.01]	[0.005, 0.02]	[0.001, 0.14]	[0.001, 0.14]
	max_depth	[4, 30]	[14, 30]	[10, 28]	[8, 29]	[13, 27]	[13, 27]
	subsample	[0.31, 0.42]	[0.33, 0.60]	[0.33, 0.48]	[0.30, 0.42]	[0.77, 0.81]	[0.77, 0.81]
	reg_lambda	[47.5, 96.2]	[0.003, 9.46]	[0.001, 1.12]	[25.8, 89.5]	[0.01, 13.4]	[0.01, 13.4]
	reg_alpha	[1.5e-5, 0.76]	[2.47, 4.04]	[4.24, 7.43]	[1.3e-5, 0.66]	[0.0006, 0.05]	[0.0006, 0.05]
SVM	kernel	'rbf'	'rbf'	'rbf'	'linear'	'linear'	'linear'
	C	[12.8, 17.3]	[0.49, 1.18]	[1.70, 4.45]	[20.0, 20.1]	[0.49, 18.1]	[0.49, 18.1]
	epsilon	[0.0003, 0.08]	[0.01, 0.07]	[0.0001, 0.07]	[0.0001, 0.07]	[0.003, 0.01]	[0.003, 0.01]
	gamma	[0.07, 0.09]	[0.05, 0.10]	[0.04, 0.08]	[8.2e-6, 0.13]	[0.0005, 0.31]	[0.0005, 0.31]
MLP	activation	'tanh'	'tanh'	'tanh'	'tanh'	'relu'	'tanh'
	alpha	[1.6e-6, 0.02]	[2.6e-6, 0.02]	[2.4e-6, 0.01]	[2.2e-6, 0.03]	[3.0e-6, 0.04]	[1.5e-6, 0.06]
	learning_init	[0.0005, 0.04]	[0.0002, 0.01]	[0.0002, 0.04]	[0.001, 0.01]	[0.004, 0.08]	[0.01, 0.06]
	batch_size	[32, 256]	[32, 141]	[32, 256]	[32, 256]	[32, 256]	[32, 256]

Tabla 38: Espacio de hiperparametros fase de búsqueda versus Optimizado 1 RandomSearch + MedAE Campo 2

Algoritmos	Hiperparametros	Espacio Búsqueda	Espacio Optimizado
RandomForest	n_estimators	(200, 3000)	(432, 2899)
	max_depth	(3, 40)	(5, 39)
	min_samples_split	(2, 50)	(3, 25)
	min_samples_leaf	(1, 20)	(1, 10)
	max_features	['sqrt', 'log2']	['sqrt', 'log2']
	max_samples	(0.3, 0.7)	(0.44167, 0.54402)
XGBoost	n_estimators	(200, 3000)	(482, 2842)
	max_depth	(2, 30)	(3, 29)
	learning_rate	(1e-4, 3e-1)	(0.00112, 0.17597)
	subsample	(0.30, 1.0)	(0.34534, 0.61976)
	colsample_bytree	(0.30, 0.70)	(0.34681, 0.63239)
	min_child_weight	(1e-3, 5.0)	(0.00179, 4.61583)
	gamma	(1e-5, 1.0)	(1.57302e-05, 0.57526)
	reg_lambda	(1e-3, 1e2)	(0.00269, 64.70695)
	reg_alpha	(1e-5, 1e1)	(3.28836e-05, 1.61785)
SVM	kernel	['rbf', 'linear']	['rbf', 'linear']
	C	(1e-2, 1e3)	(0.08759, 944.81344)
	epsilon	(1e-4, 1e-1)	(0.00019, 0.071023)
	gamma	(1e-6, 1.0)	(3.21797e-06, 0.42441)
MLP	hidden_layer_sizes	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]
	activation	['relu', 'tanh']	['relu', 'tanh']
	solver	['adam']	['adam']
	alpha	(1e-6, 1e-1)	(1.93691e-06, 0.048755)
	learning_rate_init	(1e-4, 1e-1)	(0.00016, 0.08874)
	learning_rate	['adaptive']	['adaptive']
	batch_size	[32, 64, 128, 256]	(32, 257)
	early_stopping	[True]	[True]
	validation_fraction	[0.15]	(0.12, 0.06)
LinearRegression	n_iter_no_change	[10, 40]	(0, 41)
	—	sin búsqueda ({})	sin búsqueda ({})

Tabla 39: Espacio de hiperparametros Optimizado 2 RandomSearch + MedAE Campo 2

Algoritmo	Parámetro	Original	Log1p	Sqrt	Square	Cube	Reciprocal
Random Forest	n_estimators	[444, 2475]	[432, 2468]	[444, 2632]	[435, 2899]	[614, 2316]	[432, 2617]
	max_depth	[7, 36]	[6, 38]	[7, 38]	[7, 36]	[5, 34]	[7, 38]
	min_samples_split	[3, 14]	[3, 17]	[3, 17]	[3, 19]	[4, 24]	[3, 18]
	min_samples_leaf	[1, 6]	[1, 4]	[1, 5]	[2, 8]	[3, 9]	[1, 4]

	max_features	'sqrt'	'log2'	'sqrt'	'log2'	'log2'	'log2'
	max_samples	[0.47, 0.95]	[0.44, 0.95]	[0.47, 0.95]	[0.70, 0.98]	[0.70, 0.98]	[0.47, 0.95]
XGBoost	n_estimators	[756, 2678]	[482, 2744]	[643, 2559]	[1118, 2841]	[751, 2727]	[806, 2785]
	max_depth	[4, 25]	[4, 23]	[5, 27]	[5, 27]	[5, 27]	[3, 28]
	learning_rate	[0.008, 0.16]	[0.001, 0.17]	[0.003, 0.08]	[0.002, 0.17]	[0.001, 0.04]	[0.001, 0.10]
	subsample	[0.44, 0.86]	[0.35, 0.84]	[0.34, 0.77]	[0.63, 0.90]	[0.60, 0.96]	[0.36, 0.92]
	colsample_bytree	[0.49, 0.95]	[0.36, 0.89]	[0.34, 0.92]	[0.56, 0.97]	[0.47, 0.97]	[0.43, 0.84]
	min_child_weight	[0.001, 4.38]	[0.03, 4.42]	[0.002, 3.01]	[0.004, 4.61]	[0.001, 0.53]	[0.002, 2.96]
	gamma	[7.0e-5, 0.35]	[4.2e-5, 0.40]	[4.2e-5, 0.57]	[3.1e-5, 0.11]	[3.7e-5, 0.15]	[1.5e-5, 5e-4]
	reg_lambda	[0.005, 16.8]	[0.003, 20.1]	[0.008, 64.7]	[0.002, 9.25]	[0.003, 15.6]	[0.003, 42.5]
	reg_alpha	[0.0003, 1.2]	[8.6e-5, 0.5]	[4.5e-5, 1.2]	[3.2e-5, 0.8]	[3.7e-5, 1.6]	[3.4e-5, 0.1]
SVM	kernel	'rbf'	'linear'	'linear'	'linear'	'linear'	'linear'
	C	[2.2, 944.8]	[2.2, 203.8]	[3.8, 89.1]	[204.8, 672.4]	[204.8, 672.4]	[0.08, 545.5]
	epsilon	[0.0002, 0.04]	[0.0005, 0.06]	[0.0005, 0.04]	[0.0001, 0.07]	[0.0001, 0.07]	[0.0002, 0.003]
	gamma	[1.0e-5, 0.07]	[7.5e-6, 0.07]	[0.0001, 0.10]	[3.2e-6, 0.42]	[3.2e-6, 0.42]	[1.6e-5, 0.13]
MLP	activation	'tanh'	'tanh'	'relu'	'tanh'	'relu'	'relu'
	solver	'adam'	'adam'	'adam'	'adam'	'adam'	'adam'
	alpha	[4.9e-6, 0.04]	[6.3e-6, 0.04]	[1.9e-6, 0.003]	[2.2e-6, 0.04]	[8.7e-6, 0.04]	[1.1e-5, 0.04]
	learning_init	[0.001, 0.06]	[0.0001, 0.01]	[0.0005, 0.04]	[0.01, 0.08]	[0.01, 0.08]	[0.001, 0.06]
	batch_size	[32, 256]	[32, 256]	[32, 256]	[32, 141]	[32, 256]	[32, 256]
	n_iter_no_change	[10, 40]	[10, 40]	[10, 40]	[10, 40]	[10, 40]	[10, 40]
LinearReg.	—	No Parametros					

Tabla 40: Espacio de hiperparametros fase de búsqueda versus Optimizado RandomSearch + Huber Campo 2

Modelo	Hiperparametros	Espacio Búsqueda	Espacio Optimizado
RandomForest	n_estimators	(200, 3000)	(400, 2900)
	max_depth	(3, 40)	(7, 39)
	min_samples_split	(2, 50)	(2, 17)
	min_samples_leaf	(1, 20)	(1, 8)
	max_features	['sqrt', 'log2']	['sqrt']
	max_samples	(0.3, 0.7)	(0.49, 0.49)
XGBoost	n_estimators	(200, 3000)	(450, 2900)
	max_depth	(2, 30)	(2, 28)

	learning_rate	(1e-4, 3e-1)	(1.5e-3, 7e-2)
	subsample	(0.30, 1.0)	(0.35, 0.614)
	colsample_bytree	(0.30, 0.70)	(0.334, 0.561)
	min_child_weight	(1e-3, 5,0)	(2.0e-3, 4.5)
	gamma	(1e-5, 1,0)	(1.5e-5, 5.8e-1)
	reg_lambda	(1e-3, 1e2)	(2.0e-3, 7.0e1)
	reg_alpha	(1e-5, 1e1)	(3.0e-5, 4.2)
SVM	kernel	['rbf', 'linear']	['rbf', 'linear']
	C	(1e-2, 1e3)	(1.0e-2, 9.0e2)
	epsilon	(1e-4, 1e-1)	(1.0e-4, 8.0e-2)
	gamma	(1e-6, 1.0)	(3.0e-6, 4.5e-1)
MLP	hidden_layer_sizes	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]
	activation	['relu', 'tanh']	['relu', 'tanh']
	solver	['adam']	['adam']
	alpha	(1e-6, 1e-1)	(1.0e-6, 5.0e-2)
	learning_rate_init	(1e-4, 1e-1)	(4.0e-4, 9.0e-2)
	learning_rate	['adaptive']	['adaptive']
	batch_size	[32, 64, 128, 256]	[32, 64, 128, 256]
	early_stopping	[True]	[True]
	validation_fraction	[0.15]	(0.12, 0.06)
	n_iter_no_change	[10, 40]	(10, 41)
LinearRegression	—	sin búsqueda ({})	sin búsqueda ({})

Tabla 41: Espacio de hiperparametros Optimizado 2 RandomSearch + Huber Campo 2

Modelo	Parámetro	Original	Log1p	Sqrt	Square	Cube	Reciprocal
Random Forest	n_estimators	[444, 2632]	[435, 2632]	[432, 2632]	[370, 2632]	[660, 2632]	[435, 2632]
	max_depth	[7, 38]	[7, 38]	[7, 38]	[7, 38]	[10, 37]	[7, 38]
	min_samples_split	[2, 14]	[2, 14]	[2, 14]	[2, 14]	[3, 14]	[2, 16]
	min_samples_leaf	[1, 5]	[1, 5]	[1, 5]	[2, 6]	[2, 7]	[1, 5]
	max_features	'sqrt'	'sqrt'	'sqrt'	'sqrt'	'sqrt'	'sqrt'
	max_samples	[0.49, 0.96]	[0.477, 0.959]	[0.49, 0.959]	[0.584, 0.981]	[0.691, 0.985]	[0.49, 0.953]
XGBoost	n_estimators	[859, 2892]	[555, 2817]	[745, 2892]	[481, 2707]	[550, 2762]	[500, 2705]
	max_depth	[3, 23]	[2, 27]	[2, 24]	[3, 25]	[3, 25]	[9, 26]
	learning_rate	[0.002, 0.014]	[0.002, 0.063]	[0.002, 0.017]	[0.002, 0.021]	[0.001, 0.025]	[0.001, 0.067]
	subsample	[0.368, 0.958]	[0.35, 0.836]	[0.353, 0.897]	[0.49, 0.92]	[0.487, 0.962]	[0.381, 0.964]
	colsample_bytree	[0.401, 0.891]	[0.334, 0.895]	[0.355, 0.794]	[0.366, 0.895]	[0.365, 0.893]	[0.348, 0.820]
	min_child_weight	[0.002, 4.27]	[0.002, 3.58]	[0.002, 4.13]	[0.002, 3.67]	[0.002, 1.66]	[0.002, 1.19]
	gamma	[3.6e-5, 0.455]	[2.0e-5, 0.333]	[1.6e-5, 0.565]	[3.6e-5, 0.578]	[3.3e-5, 0.558]	[2.6e-5, 0.001]
	reg_lambda	[0.863, 59.0]	[0.017, 59.06]	[0.286, 29.14]	[5.86, 67.67]	[1.81, 58.69]	[0.002, 21.92]
	reg_alpha	[3.3e-5, 1.38]	[0.0003, 2.50]	[4.6e-5, 4.11]	[4.1e-5, 1.00]	[6.9e-5, 1.46]	[3.5e-5, 0.137]
SVM	kernel	'rbf'	'linear'	'linear'	'linear'	'linear'	'rbf'

	C	[9.67, 871.6]	[0.135, 36.83]	[0.486, 159.6]	[90.6, 672.4]	[204.8, 672.4]	[0.014, 13.59]
	epsilon	[0.0003, 0.069]	[0.0001, 0.012]	[0.0001, 0.067]	[0.0001, 0.068]	[0.0001, 0.071]	[0.0001, 0.004]
	gamma	[0.001, 0.152]	[2.1e-5, 0.047]	[8.9e-6, 0.075]	[3.5e-6, 0.424]	[3.2e-6, 0.424]	[2.7e-6, 0.011]
MLP	activation	'tanh'	'tanh'	'tanh'	'relu'	'relu'	'relu'
	alpha	[2.3e-6, 0.004]	[1.0e-5, 0.018]	[1.4e-6, 0.007]	[3.9e-6, 0.023]	[2.8e-6, 0.045]	[2.0e-6, 0.042]
	learning_init	[0.003, 0.029]	[0.0005, 0.017]	[0.0006, 0.042]	[0.011, 0.065]	[0.012, 0.086]	[0.0004, 0.073]
	batch_size	[32, 256]	[32, 256]	[32, 256]	[32, 256]	[32, 256]	[32, 256]
	val_fraction	[0.12, 0.18]	[0.12, 0.18]	[0.12, 0.18]	[0.12, 0.18]	[0.12, 0.18]	[0.12, 0.18]

Tabla 42: Espacio de hiperparametros fase de búsqueda versus Optimizado 1 BayesSearch + MedAE Campo 2

Algoritmo	Hiperparametros	Espacio Búsqueda	Espacio Optimizado
RandomForest	n_estimators	(200, 3000)	(269, 2918)
	max_depth	(3, 40)	(4, 39)
	min_samples_split	(2, 50)	(2, 23)
	min_samples_leaf	(1, 20)	(1, 9)
	max_features	['sqrt', 'log2']	['sqrt', 'log2']
	max_samples	(0.3, 0.7)	(0.3, 0.7)
XGBoost	n_estimators	(200, 3000)	(238, 2903)
	max_depth	(2, 30)	(2, 30)
	learning_rate	(1e-4, 3e-1)	(9.7e-4, 0.1936)
	subsample	(0.30, 1.0)	(0.315, 0.966)
	colsample_bytree	(0.30, 0.70)	(0.347, 0.979)
	min_child_weight	(1e-3, 5,0)	(1e-3, 4.85)
	gamma	(1e-5, 1,0)	(2.6e-08, 0.546)
	reg_lambda	(1e-3, 1e2)	(0.00148, 93.2)
SVM	reg_alpha	(1e-5, 1e1)	(1.4e-05, 1.58)
	kernel	['rbf', 'linear']	['rbf', 'linear']
	C	(1e-2, 1e3)	(1e-2, 6e2)
	epsilon	(1e-4, 1e-1)	(1e-4, 0.085)
MLP	gamma	(1e-6, 1.0)	(1e-6, 0.65)
	hidden_layer_sizes	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]
	activation	['relu', 'tanh']	['relu', 'tanh']
	solver	['adam']	['adam']
	alpha	(1e-6, 1e-1)	(1e-6, 1e-1)
	learning_rate_init	(1e-4, 1e-1)	(1e-4, 1e-1)
	learning_rate	['adaptive']	['adaptive']
	batch_size	[32, 64, 128, 256]	[32, 64, 128, 256]
	early_stopping	[True]	[True]
	validation_fraction	[0.15]	[0.12, 0.15, 0.18]
LinearRegression	n_iter_no_change	[10, 40]	[10, 20, 40]
	—	sin búsqueda ({})	sin búsqueda ({})

Tabla 43: Espacio de hiperparametros Optimizado 2 BayesSearch + MedAE Campo 2

Algoritmo	Parámetro	Original	Log1p	Sqrt	Square	Cube	Reciprocal
Random Forest	n_estimators	[1480,2163]	[269,368]	[343,1290]	[1272,1486]	[329,2918]	[297,403]
	max_depth	[7,39]	[7,37]	[4,37]	[10,39]	[8,38]	[8,39]
	min_split	[12,20]	[15,20]	[14,17]	[2,9]	[21,23]	[9,11]
	min_leaf	[2,4]	[1,2]	[1,4]	[3,5]	[5,9]	[1,2]
	max_features	log2	log2	sqrt	log2	log2	sqrt
XGBoost	n_estimators	[238,2244]	[675,2753]	[299,1604]	[1629,2818]	[1627,2903]	[1693,2856]
	max_depth	[2,3]	[11,27]	[6,29]	[5,22]	[6,29]	[9,30]
	learning_rate	[0.02,0.09]	[0.001,0.01]	[0.01,0.09]	[0.003,0.18]	[0.001,0.19]	[0.03,0.13]
	subsample	[0.55,0.86]	[0.59,0.84]	[0.31,0.45]	[0.73,0.92]	[0.93,0.96]	[0.64,0.80]
	colsample_bytree	[0.84,0.97]	[0.36,0.84]	[0.34,0.79]	[0.86,0.97]	[0.83,0.97]	[0.76,0.97]
	min_child_weight	[0.002,1.40]	[3.20,4.85]	[0.001,0.47]	[0.002,0.16]	[0.003,0.92]	[0.001,0.14]
	gamma	5.7e-8 a 0.02	2.8e-8 a 0.006	3.1e-8 a 0.28	4.8e-8 a 0.08	3.5e-4 a 0.54	2.6e-8 a 7.3e-6
	reg_lambda	[0.001,0.58]	[0.002,2.66]	[43.8,93.1]	[0.001,0.004]	[0.01,0.20]	[0.002,0.57]
SVM	reg_alpha	[2e-5,0.38]	[1.4e-5,0.48]	[2.2e-5,0.21]	[4.5e-5,1.58]	[3.4e-5,1.45]	[0.09,0.17]
	kernel	rbf	rbf	rbf	linear	linear	linear
	C	[106.1,126.7]	[6.60,8.36]	[3.65,6.15]	[341.2,355.5]	[563.9,566.6]	[0.01,590.6]
	epsilon	[4e-4,0.04]	[0.009,0.04]	[1e-4,0.05]	[0.001,0.07]	[1e-4,0.08]	[1e-4,0.001]
MLP	gamma	[0.043,0.046]	[0.007,0.009]	[0.030,0.039]	[4.1e-6,0.64]	[2.4e-6,0.02]	[1.8e-6,0.15]
	activation	relu	tanh	tanh	tanh	relu	tanh
	alpha	1.9e-6 a 0.02	2.6e-6 a 0.06	2.6e-6 a 0.03	1.6e-6 a 0.02	2.3e-6 a 0.02	2.4e-6 a 0.01
	lr_init	[0.0006,0.05]	[0.0002,0.04]	[0.0002,0.03]	[0.005,0.09]	[0.01,0.08]	[0.008,0.07]
	batch_size	[32,256]	[32,256]	[32,256]	[32,256]	[32,256]	[32,256]
	val_fraction	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]
LinearReg.	n_iter_change	[10,40]	[10,40]	[10,40]	[10,40]	[10,40]	[10,40]
	—	No Params					

Tabla 44: Espacio de hiperparametros fase de búsqueda versus Optimizado BayesSearch + Huber Campo 2

Modelo	Hiperparametros	Espacio búsqueda	Espacio Optimizado
RandomForest	n_estimators	(200, 3000)	(700, 2991)
	max_depth	(3, 40)	(5, 39)
	min_samples_split	(2, 50)	(2, 30)
	min_samples_leaf	(1, 20)	(2, 19)
	max_features	['sqrt', 'log2']	['sqrt', 'log2']
	max_samples	(0.3, 0.7)	(0.3, 0.7)
XGBoost	n_estimators	(200, 3000)	(484, 2696)
	max_depth	(2, 30)	(2, 30)
	learning_rate	(1e-4, 3e-1)	(1e-3, 0.15)

	subsample	(0.30, 1.0)	(0.309, 0.959)
	colsample_bytree	(0.30, 0.70)	(0.322, 0.964)
	min_child_weight	(1e-3, 5,0)	(0.0069, 4.9)
	gamma	(1e-5, 1,0)	(2.1e-08, 0.40)
	reg_lambda	(1e-3, 1e2)	(0.013, 94.46)
	reg_alpha	(1e-5, 1e1)	(3.4e-05, 6.60)
SVM	kernel	['rbf', 'linear']	['rbf', 'linear']
	C	(1e-2, 1e3)	(0.17, 205.8)
	epsilon	(1e-4, 1e-1)	(1e-4, 5.6e-2)
	gamma	(1e-6, 1.0)	(6.4e-06, 0.317)
MLP	hidden_layer_sizes	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]
	activation	['relu', 'tanh']	['relu', 'tanh']
	solver	['adam']	['adam']
	alpha	(1e-6, 1e-1)	(1.3e-6, 4.63e-2)
	learning_rate_init	(1e-4, 1e-1)	(3.0e-4, 9.2e-2)
	learning_rate	['adaptive']	['adaptive']
	batch_size	[32, 64, 128, 256]	(32, 257)
	early_stopping	[True]	[True]
	validation_fraction	[0.15]	(0.12, 0.06)
	n_iter_no_change	[10, 40]	(10, 41)
LinearRegression	—	sin búsqueda ({})	sin búsqueda ({})

Tabla 45: Espacio de hiperparametros Optimizado 2 BayesSearch + Huber Campo 2

Algoritmo	Parámetro	Original	Log1p	Sqrt	Square	Cube	Reciprocal
Random Forest	n_estimators	[2101,2985]	[2884,2991]	[1039,2979]	[435,2899]	[2745,2969]	[2682,2986]
	max_depth	[5,39]	[10,39]	[6,37]	[9,39]	[17,38]	[15,38]
	min_split	[2,8]	[2,6]	[2,8]	[2,5]	[12,30]	[12,30]
	min_leaf	[3,4]	[2,4]	[3,5]	[3,4]	[5,19]	[5,19]
	max_features	sqrt	log2	sqrt	log2	log2	sqrt
XGBoost	n_estimators	[722,2111]	[564,2000]	[115,2159]	[469,2353]	[2039,2898]	[484,1111]
	max_depth	[4,30]	[2,29]	[4,6]	[4,21]	[5,27]	[13,27]
	learning_rate	[0.02,0.04]	[0.004,0.01]	[0.01,0.08]	[0.003,0.20]	[0.001,0.18]	[0.001,0.14]
	subsample	[0.35,0.84]	[0.31,0.50]	[0.31,0.48]	[0.72,0.92]	[0.93,0.96]	[0.77,0.81]
	colsample_bytree	[0.62,0.96]	[0.35,0.94]	[0.35,0.79]	[0.84,0.98]	[0.88,0.97]	[0.53,0.74]
	min_child_weight	[7.54,19.4]	[0.007,4.35]	[0.001,0.38]	[0.002,0.17]	[0.001,0.05]	[0.59,3.01]
	gamma	1.9e-6 a 0.52	2.1e-8 a 0.35	3.1e-8 a 0.28	4.8e-8 a 0.09	7.1e-8 a 0.05	0.002 a 0.01
	reg_lambda	[22.3,84.9]	[2.03,11.1]	[40.9,86.2]	[0.001,0.005]	[0.003,17.5]	[0.01,13.4]
	reg_alpha	[1e-4,6.6]	[3e-5,0.20]	[1e-5,0.32]	[4e-5,2.09]	[1e-4,2.93]	[6e-4,0.05]
SVM	kernel	rbf	rbf	rbf	linear	linear	linear
	C	[73.7,95.6]	[5.05,8.57]	[3.97,6.17]	[309.8,347.2]	[357.7,367.7]	[382.5,402.2]
	epsilon	[0.003,0.04]	[0.001,0.04]	[1e-4,0.06]	[0.001,0.08]	[0.001,0.09]	[0.002,0.10]
	gamma	[0.036,0.041]	[0.009,0.01]	[0.030,0.040]	[4e-6,0.62]	[7e-8,2.94]	[1e-7,5.37]

MLP	activation	tanh	tanh	tanh	tanh	tanh	tanh
	alpha	1.9e-6 a 0.02	2.1e-6 a 0.01	2.6e-6 a 0.03	1.6e-6 a 0.02	2.6e-6 a 0.02	1.3e-6 a 0.01
	lr_init	[0.001,0.05]	[0.0003,0.06]	[0.0002,0.03]	[0.005,0.09]	[0.003,0.07]	[0.01,0.07]
	batch_size	[32,256]	[32,256]	[32,256]	[32,256]	[32,256]	[32,256]
	val_fraction	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]
	n_iter_change	[10,40]	[10,40]	[10,40]	[10,40]	[10,40]	[10,40]

Tabla 46: Espacio de hiperparametros fase de búsqueda versus Optimizado 1 RandomSearch + MedAE Campo 3

Modelo	Hiperparametros	Espacio búsqueda	Espacio Optimizado
RandomForest	n_estimators	(200, 3000)	(635, 2900)
	max_depth	(3, 40)	(8, 39)
	min_samples_split	(2, 50)	(2, 27)
	min_samples_leaf	(1, 20)	(1, 8)
	max_features	['sqrt', 'log2']	['sqrt']
	max_samples	(0.3, 0.7)	(0.462, 0.495)
XGBoost	n_estimators	(200, 3000)	(515, 2772)
	max_depth	(2, 30)	(3, 29)
	learning_rate	(1e-4, 3e-1)	1.973e-3, 1.955e-1)
	subsample	(0.30, 1.0)	(0.352, 0.621)
	colsample_bytree	(0.30, 0.70)	(0.403, 0.576)
	min_child_weight	(1e-3, 5,0)	(1.792e-3, 4.558)
	gamma	(1e-5, 1,0)	(1.739e-5, 6.577e-1)
	reg_lambda	(1e-3, 1e2)	(2.21e-3, 6.331e1)
SVM	reg_alpha	(1e-5, 1e1)	(2.57e-5, 3.402)
	kernel	['rbf', 'linear']	['rbf', 'linear']
	C	(1e-2, 1e3)	(4.198e-2, 9.449e2)
	epsilon	(1e-4, 1e-1)	(1.37e-4, 7.11e-2)
MLP	gamma	(1e-6, 1.0)	(2.68e-6, 4.800e-1)
	hidden_layer_sizes	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]
	activation	['relu', 'tanh']	['relu', 'tanh']
	solver	['adam']	['adam']
	alpha	(1e-6, 1e-1)	(3.16e-6, 5.869e-2)
	learning_rate_init	(1e-4, 1e-1)	(1.172e-4, 8.475e-2)
	learning_rate	['adaptive']	['adaptive']
	batch_size	[32, 64, 128, 256]	[32, 64, 128, 256]
	early_stopping	[True]	[True]
LinearRegression	validation_fraction	[0.15]	(0.12, 0.06)
	n_iter_no_change	[10, 40]	[10, 40]
LinearRegression		—	sin búsqueda ({})

Tabla 47: Espacio de hiperparametros Optimizado 2 RandomSearch + MedAE Campo 3

Modelo	Parámetro	Original	Log1p	Sqrt	Square	Cube	Reciprocal
Random Forest	n_estimators	[638,2632]	[635,2826]	[635,2632]	[637,2633]	[674,2826]	[674,2899]
	max_depth	[10,38]	[8,36]	[8,38]	[10,35]	[10,38]	[10,38]
	min_split	[3,17]	[2,21]	[2,17]	[2,14]	[2,26]	[4,26]
	min_leaf	[1,5]	[1,6]	[1,5]	[2,7]	[2,7]	[1,6]
	max_features	sqrt	sqrt	sqrt	sqrt	sqrt	sqrt
	max_samples	[0.50,0.96]	[0.48,0.95]	[0.48,0.95]	[0.46,0.93]	[0.49,0.95]	[0.48,0.91]
XGBoost	n_estimators	[713,2639]	[553,2672]	[515,2412]	[737,2771]	[772,2536]	[636,2713]
	max_depth	[4,24]	[3,27]	[6,27]	[6,28]	[6,27]	[6,27]
	learning_rate	[0.003,0.09]	[0.002,0.07]	[0.004,0.20]	[0.004,0.15]	[0.002,0.06]	[0.002,0.13]
	subsample	[0.35,0.95]	[0.46,0.96]	[0.45,0.94]	[0.64,0.97]	[0.44,0.97]	[0.38,0.86]
	colsample_bytree	[0.56,0.97]	[0.40,0.72]	[0.55,0.97]	[0.47,0.98]	[0.45,0.98]	[0.44,0.89]
	min_child_weight	[0.004,4.52]	[0.003,1.28]	[0.007,4.56]	[0.002,3.67]	[0.003,0.54]	[0.006,2.98]
	gamma	3.1e-5 a 0.47	1.1e-4 a 0.66	2.4e-5 a 0.12	6.4e-5 a 0.51	6.5e-5 a 0.47	1.7e-5 a 3e-4
	reg_lambda	[0.003,8.51]	[0.005,28.8]	[0.004,12.2]	[0.002,59.0]	[0.004,34.3]	[0.005,63.3]
	reg_alpha	3.0e-5 a 1.35	2.9e-5 a 3.40	5.4e-5 a 1.55	2.6e-5 a 0.46	7.0e-5 a 1.35	2.9e-5 a 0.04
SVM	kernel	rbf	rbf	rbf	linear	rbf	rbf
	C	[0.37,8.60]	[0.70,540.2]	[0.90,869.1]	[204.9,672.4]	[0.04,12.8]	[0.03,108.8]
	epsilon	[1e-4,0.06]	[3e-4,0.06]	[2e-4,0.04]	[2e-4,0.07]	[2e-4,0.05]	[1e-4,0.005]
	gamma	[0.004,0.34]	[0.004,0.09]	[0.003,0.26]	[3e-6,0.42]	[3e-6,0.21]	[5e-4,0.48]
MLP	activation	tanh	tanh	tanh	tanh	relu	tanh
	alpha	4.7e-6 a 0.08	7.9e-6 a 0.02	2.7e-5 a 0.06	3.2e-6 a 0.007	6.8e-6 a 0.01	5.3e-6 a 0.03
	lr_init	[0.001,0.01]	[0.0001,0.007]	[0.0002,0.01]	[0.003,0.06]	[0.006,0.08]	[0.0005,0.05]
	batch_size	[32,256]	[32,256]	[32,256]	[32,256]	[32,256]	[32,141]
	val_fraction	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]
	n_iter_change	[10,40]	[10,40]	[10,40]	[10,40]	[10,40]	[10,40]
LinearReg.	—	No Params					

Tabla 48: Espacio de hiperparametros fase de búsqueda versus Optimizado RandomSearch + Huber Campo 3

Modelo	Hiperparametros	Espacio búsqueda	Espacio Optimizado
RandomForest	n_estimators	(200, 3000)	(638, 2830)
	max_depth	(3, 40)	(8, 39)

	min_samples_split	(2, 50)	(2, 18)
	min_samples_leaf	(1, 20)	(1, 8)
	max_features	['sqrt', 'log2']	['sqrt']
	max_samples	(0.3, 0.7)	(0.481, 0.478)
XGBoost	n_estimators	(200, 3000)	(336, 2793)
	max_depth	(2, 30)	(4, 29)
	learning_rate	(1e-4, 3e-1)	(1.20e-3, 2.1316e-1)
	subsample	(0.30, 1.0)	(0.317, 0.638)
	colsample_bytree	(0.30, 0.70)	(0.375, 0.492)
	min_child_weight	(1e-3, 5,0)	(2.09e-3, 4.36)
	gamma	(1e-5, 1,0)	(1.62e-5, 5.7845e-1)
	reg_lambda	(1e-3, 1e2)	(2.19e-3, 6.058e1)
	reg_alpha	(1e-5, 1e1)	(2.25e-5, 2.4016)
	kernel	['rbf', 'linear']	['rbf', 'linear']
	C	(1e-2, 1e3)	(1.43e-2, 9.448e2)
	epsilon	(1e-4, 1e-1)	(1.30e-4, 7.102e-2)
SVM	gamma	(1e-6, 1.0)	(2.63e-6, 4.244e-1)
	hidden_layer_sizes	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]	[(50,), (100,), (200,), (300,), (50,50), (100,50), (100,100), (200,100)]
	activation	['relu', 'tanh']	['relu', 'tanh']
	solver	['adam']	['adam']
MLP	alpha	(1e-6, 1e-1)	(1.7e-6, 6.644e-2)
	learning_rate_init	(1e-4, 1e-1)	(1.64e-4, 8.465e-2)
	learning_rate	['adaptive']	['adaptive']
	batch_size	[32, 64, 128, 256]	[32, 64, 128, 256]
	early_stopping	[True]	[True]
	validation_fraction	[0.15]	(0.12, 0.06)
	n_iter_no_change	[10, 40]	[10, 40]
	LinearRegression	—	sin búsqueda ({})
		sin búsqueda ({})	sin búsqueda ({})

Tabla 49: Espacio de hiperparametros Optimizado 2 RandomSearch + Huber Campo 3

Modelo	Parámetro	Original	Log1p	Sqrt	Square	Cube	Reciprocal
Random Forest	n_estimators	[638,2632]	[635,2826]	[635,2632]	[637,2633]	[681,2633]	[670,2827]
	max_depth	[10,38]	[8,36]	[8,38]	[10,35]	[10,38]	[8,39]
	min_split	[3,17]	[2,21]	[2,17]	[2,14]	[2,15]	[2,18]
	min_leaf	[1,5]	[1,6]	[1,5]	[2,7]	[2,8]	[1,5]
	max_features	sqrt	sqrt	sqrt	sqrt	sqrt	sqrt
	max_samples	[0.50,0.96]	[0.48,0.95]	[0.48,0.95]	[0.46,0.93]	[0.48,0.96]	[0.48,0.95]
XGBoost	n_estimators	[713,2639]	[553,2672]	[515,2412]	[737,2771]	[424,2606]	[463,2714]
	max_depth	[4,24]	[3,27]	[6,27]	[6,28]	[4,28]	[6,29]
	learning_rate	[0.003,0.09]	[0.002,0.07]	[0.004,0.20]	[0.004,0.15]	[0.001,0.02]	[0.002,0.21]
	subsample	[0.35,0.95]	[0.46,0.96]	[0.45,0.94]	[0.64,0.97]	[0.43,0.91]	[0.38,0.92]
	colsample_bytree	[0.56,0.97]	[0.40,0.72]	[0.55,0.97]	[0.47,0.98]	[0.40,0.87]	[0.38,0.82]

	min_child_weight	[0.004,4.52]	[0.003,1.28]	[0.007,4.56]	[0.002,3.67]	[0.003,1.30]	[0.002,1.47]
	gamma	3.1e-5 a 0.47	1.1e-4 a 0.66	2.4e-5 a 0.12	6.4e-5 a 0.51	6.2e-5 a 0.34	1.7e-5 a 2.9e-4
	reg_lambda	[0.003,8.51]	[0.005,28.8]	[0.004,12.2]	[0.002,59.0]	[8.04,60.6]	[0.002,49.1]
	reg_alpha	3.0e-5 a 1.35	2.9e-5 a 3.40	5.4e-5 a 1.55	2.6e-5 a 0.46	1.7e-4 a 1.47	2.3e-5 a 0.03
SVM	kernel	rbf	rbf	rbf	linear	linear	rbf
	C	[0.37,8.60]	[0.70,540.2]	[0.90,869.1]	[204.9,672.4]	[204.9,672.4]	[0.03,108.8]
	epsilon	[1e-4,0.06]	[3e-4,0.06]	[2e-4,0.04]	[2e-4,0.07]	[2e-4,0.07]	[1e-4,0.005]
	gamma	[0.004,0.34]	[0.004,0.09]	[0.003,0.26]	[3e-6,0.42]	[3e-6,0.42]	[5e-4,0.48]
MLP	activation	tanh	tanh	tanh	tanh	relu	tanh
	alpha	4.7e-6 a 0.08	7.9e-6 a 0.02	2.7e-5 a 0.06	3.2e-6 a 0.007	3.2e-6 a 0.04	1.1e-5 a 0.08
	lr_init	[0.001,0.01]	[0.0001,0.007]	[0.0002,0.01]	[0.003,0.06]	[0.01,0.08]	[0.0001,0.02]
	batch_size	[32,256]	[32,256]	[32,256]	[32,256]	[32,257]	[32,141]
	val_fraction	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]
	n_iter_change	[10,40]	[10,40]	[10,40]	[10,40]	[10,40]	[10,40]
LinearReg.	—	No Params					

Tabla 50: Espacio de hiperparametros fase de búsqueda versus Optimizado BayesSearch + MedAE Campo 3

Modelo	Hiperparametros	Espacio búsqueda	Espacio Optimizado
RandomForest	n_estimators	(200, 3000)	(200, 2600)
	max_depth	(3, 40)	(7, 40)
	min_samples_split	(2, 50)	(2, 30)
	min_samples_leaf	(1, 20)	(1, 19)
	max_features	['sqrt', 'log2']	['sqrt', 'log2']
	max_samples	(0.3, 0.7)	(0.3, 0.7)
XGBoost	n_estimators	(200, 3000)	(350, 2900)
	max_depth	(2, 30)	(2, 30)
	learning_rate	(1e-4, 3e-1)	(1e-4, 1.5e-1)
	subsample	(0.30, 1.0)	(0.30, 1.00)
	colsample_bytree	(0.30, 0.70)	(0.38, 0.99)
	min_child_weight	(1e-3, 5,0)	(1e-3, 30.0)
	gamma	(1e-5, 1,0)	(1e-8, 5.0)
	reg_lambda	(1e-3, 1e2)	(1e-3, 50.0)
	reg_alpha	(1e-5, 1e1)	(1e-5, 8.0)
SVM	kernel	['rbf', 'linear']	['rbf', 'linear']
	C	(1e-2, 1e3)	(1.0, 1500)
	epsilon	(1e-4, 1e-1)	(1e-4, 1e-1)
	gamma	(1e-6, 1.0)	(1e-6, 3.5e-1)
MLP	hidden_layer_sizes	[(50,),(100,),(200,),(300,),(50,50),(100,50),(100,100),(200,100)]	[(50,),(100,),(200,),(300,),(50,50),(100,50),(100,100),(200,100)]

	activation	['relu', 'tanh']	['relu', 'tanh']
	solver	['adam']	['adam']
	alpha	(1e-6, 1e-1)	(1e-6, 7e-2)
	learning_rate_init	(1e-4, 1e-1)	(1e-4, 9e-2)
	learning_rate	['adaptive']	['adaptive']
	batch_size	[32, 64, 128, 256]	[32, 64, 128, 256]
	early_stopping	[True]	[True]
	validation_fraction	[0.15]	(0.12–0.18)
	n_iter_no_change	[10, 40]	(10, 41)
LinearRegression	—	sin búsqueda ({})	sin búsqueda ({})

Tabla 51: Espacio de hiperparametros Optimizado 2 BayesSearch + MedAE Campo 3

Modelo	Parámetro	Original	Log1p	Sqrt	Square	Cube	Reciprocal
Random Forest	n_estimators	[1578,2583]	[262,2100]	[849,1520]	[1870,2176]	[711,2219]	[222,625]
	max_depth	[1,8]	[5,7]	[6,14]	[4,10]	[7,23]	[1,2]
	min_split	[6,7]	[2,3]	[12,23]	[15,20]	[12,30]	[2,3]
	min_leaf	[1,2]	[1,2]	[6,10]	[7,19]	[5,19]	[1,2]
	max_features	log2	log2	log2	sqrt	sqrt	log2
	max_samples	[0.48,0.95]	[0.48,0.95]	[0.48,0.95]	[0.48,0.95]	[0.48,0.95]	[0.48,0.95]
XGBoost	n_estimators	[976,2878]	[1163,2944]	[1922,2873]	[816,2627]	[484,1111]	[898,1672]
	max_depth	[15,24]	[14,30]	[7,27]	[8,28]	[13,27]	[15,24]
	learning_rate	[7e-4,0.03]	[0.018,0.23]	[0.015,0.03]	[0.010,0.11]	[0.001,0.14]	[0.05,0.12]
	subsample	[0.74,0.84]	[0.33,0.60]	[0.31,0.41]	[0.79,0.99]	[0.77,0.81]	[0.13,0.96]
	colsample_bytree	[0.21,0.93]	[0.42,0.95]	[0.70,0.94]	[0.88,0.98]	[0.53,0.74]	[0.11,0.95]
	min_child_weight	[0.037,8.19]	[0.003,0.57]	[0.001,0.75]	[0.02,1.16]	[0.59,3.02]	[7e-4,0.09]
	gamma	[6e-4,0.03]	[2e-5,0.02]	[3e-4,0.26]	[8e-5,0.002]	[0.02,0.07]	[1e-4,0.97]
	reg_lambda	[3e-4,0.04]	[0.003,9.46]	[65.7,97.2]	[58.7,95.2]	[0.01,13.4]	[0.03,0.09]
SVM	reg_alpha	[1e-5,0.26]	[2.47,4.04]	[7e-5,2.66]	[1e-5,0.06]	[6e-4,0.05]	[6e-5,3e-4]
	kernel	rbf	rbf	linear	rbf	linear	rbf
	C	[0.33,0.36]	[0.23,0.27]	[0.49,18.2]	[0.47,0.73]	[0.49,18.2]	[0.31,0.62]
	epsilon	[1e-4,7e-4]	[6e-4,0.02]	[0.003,0.01]	[0.001,0.01]	[0.003,0.01]	[4e-4,0.005]
MLP	gamma	[0.11,0.12]	[0.58,0.70]	[0.001,0.32]	[0.005,0.007]	[0.001,0.32]	[0.06,0.17]
	activation	relu	tanh	tanh	tanh	relu	tanh
	alpha	[1e-5,0.06]	[4e-6,0.03]	[1e-6,0.02]	[1e-6,0.02]	[3e-6,0.04]	[2e-4,0.008]
	lr_init	[1e-4,0.04]	[0.002,0.06]	[2e-4,0.005]	[2e-4,0.005]	[0.005,0.08]	[0.006,0.08]
	batch_size	[32,257]	[32,257]	[32,257]	[32,257]	[32,257]	[32,142]
	val_fraction	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]
Linear Regression	n_iter_change	[10,41]	[10,41]	[10,41]	[10,41]	[10,41]	[10,41]
	—	No Parámetros					

Tabla 52: Espacio de hiperparametros fase de búsqueda versus Optimizado BayesSearch +

Huber Campo 3

Modelo	Hiperparametros	Espacio búsqueda	Espacio Optimizado
RandomForest	n_estimators	(200, 3000)	(204, 2871)
	max_depth	(3, 40)	(7, 40)
	min_samples_split	(2, 50)	(2, 14)
	min_samples_leaf	(1, 20)	(1, 5)
	max_features	['sqrt', 'log2']	['sqrt']
	max_samples	(0.3, 0.7)	(0.3, 0.7)
XGBoost	n_estimators	(200, 3000)	(220, 2822)
	max_depth	(2, 30)	(4, 30)
	learning_rate	(1e-4, 3e-1)	(1.02e-3, 1.4185e-1)
	subsample	(0.30, 1.0)	(0.30, 0.92)
	colsample_bytree	(0.30, 0.70)	(0.35, 0.99)
	min_child_weight	(1e-3, 5,0)	(1.85e-3, 26.5)
	gamma	(1e-5, 1,0)	(1e-8, 3.0)
	reg_lambda	(1e-3, 1e2)	(3e-3, 87.0)
	reg_alpha	(1e-5, 1e1)	(1.8e-5, 4.9)
SVM	kernel	['rbf', 'linear']	['rbf', 'linear']
	C	(1e-2, 1e3)	(9.4e-2, 1e4)
	epsilon	(1e-4, 1e-1)	(1e-4, 9e-2)
	gamma	(1e-6, 1.0)	(4.8e-6, 0.7)
MLP	hidden_layer_sizes	[(50,), (100,), (200,), (300,)], (50,50), (100,50), (100,100), (200,100)]	[(50,), (100,), (200,), (300,)], (50,50), (100,50), (100,100), (200,100)]
	activation	['relu', 'tanh']	['relu', 'tanh']
	solver	['adam']	['adam']
	alpha	(1e-6, 1e-1)	(2.46e-6, 6.78e-2)
	learning_rate_init	(1e-4, 1e-1)	(1.8e-4, 8.18e-2)
	learning_rate	['adaptive']	['adaptive']
	batch_size	[32, 64, 128, 256]	[32, 64, 128, 256]
	early_stopping	[True]	[True]
	validation_fraction	[0.15]	[0.15]
	n_iter_no_change	[10, 40]	[10, 40]
LinearRegression	—	sin búsqueda ({}))	sin búsqueda ({}))

Tabla 53: Espacio de hiperparametros Optimizado 2 BayesSearch + Huber Campo 3

Modelo	Parámetro	Original	Log1p	Sqrt	Square	Cube	Reciprocal
--------	-----------	----------	-------	------	--------	------	------------

Random Forest	n_estimators	[213,362]	[247,2500]	[326,819]	[320,355]	[204,324]	[377,2871]
	max_depth	[13,32]	[14,31]	[17,38]	[10,39]	[7,35]	[12,40]
	min_split	[2,4]	[2,4]	[2,4]	[2,8]	[2,9]	[2,14]
	min_leaf	[1,3]	[1,2]	[1,3]	[3,5]	[3,5]	[1,2]
	max_features	sqrt	sqrt	sqrt	sqrt	sqrt	sqrt
XGBoost	n_estimators	[1185,2137]	[1341,2729]	[404,2822]	[558,2470]	[220,2698]	[484,1111]
	max_depth	[8,29]	[7,29]	[5,29]	[6,29]	[4,30]	[13,27]
	learning_rate	[0.001,0.002]	[0.002,0.008]	[0.001,0.009]	[0.002,0.016]	[0.002,0.045]	[0.001,0.14]
	subsample	[0.30,0.45]	[0.31,0.40]	[0.31,0.46]	[0.31,0.43]	[0.35,0.91]	[0.77,0.81]
	colsample_bytree	[0.71,0.97]	[0.35,0.89]	[0.63,0.97]	[0.74,0.97]	[0.78,0.98]	[0.53,0.74]
	min_child_weight	[2.84,9.50]	[0.003,9.41]	[3.54,9.66]	[0.002,3.12]	[0.008,3.60]	[5.15,26.3]
	gamma	6e-8 a 2.94	3e-7 a 0.97	1e-8 a 1.74	3e-8 a 1.06	4e-6 a 1.72	[0.01,0.08]
	reg_lambda	[0.006,3.46]	[0.09,2.87]	[0.003,0.50]	[13.0,42.5]	[14.8,86.7]	[0.01,13.4]
	reg_alpha	8e-5 a 4.87	1e-4 a 0.50	6e-5 a 2.31	1e-5 a 3.26	4e-5 a 3.24	6e-4 a 0.05
SVM	kernel	rbf	rbf	linear	linear	linear	linear
	C	[79.4,336.8]	[0.49,1.19]	[0.09,2979]	[465.8,506.9]	[9987,9998]	[1.11,84.5]
	epsilon	[3e-4,0.08]	[0.01,0.08]	[1e-4,0.09]	[2e-4,0.06]	[1e-4,0.09]	[0.003,0.01]
	gamma	[0.02,0.09]	[0.05,0.10]	[1e-5,0.69]	[4e-6,0.56]	[3e-6,0.22]	[5e-4,0.31]
MLP	activation	relu	tanh	relu	tanh	relu	tanh
	alpha	7e-6 a 0.02	6e-5 a 0.04	5e-5 a 0.06	2e-6 a 0.02	3e-6 a 0.01	2e-6 a 0.03
	lr_init	[0.002,0.04]	[2e-4,0.007]	[2e-4,0.02]	[1e-4,0.08]	[0.006,0.06]	[5e-4,0.03]
	batch_size	[32,257]	[32,129]	[32,257]	[32,129]	[32,257]	[32,142]
	val_fraction	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]	[0.12,0.18]
	n_iter_change	[10,41]	[10,41]	[10,41]	[10,41]	[10,41]	[10,41]
LinearReg.	—	No Params					